



Del Tecnicismo a la Claridad en Informes Médicos



AUTOR: LOGOS



Tabla de contenidos

1. Introducción	1
1.1. Propósito principal	2
1.2. Motivación	2
1.3. Hipótesis principal	3
1.4. Objetivos	4
1.5. Contribución a los Objetivos de Desarrollo Sostenible (ODS)	5
1.6. Estructura de la memoria	7
1.7. Planificación y costes	8
2. Antecedentes	11
2.1. Procesamiento del Lenguaje Natural	11
2.2. Modelos de lenguaje aplicados al texto clínico	12
2.2.1. Modelos de propósito general	12
2.2.2. Modelos especializados en salud	13
2.2.3. Técnicas de ajuste y personalización	15
2.3. Simplificación automática de texto	17
2.3.1. Evolución y enfoques actuales	17
2.3.2. Métricas de evaluación	18
2.4. Simplificación de documentos médicos	19
2.4.1. Informe de alta	19
2.4.2. Sistemas existentes	19
3. Definición de la propuesta	21

3.1. Elección de LLMs	21
3.1.1. Justificación del uso de modelos de lenguaje	21
3.1.2. Modelo utilizado	22
3.2. Hipótesis de trabajo	24
3.2.1. Hipótesis 1: La división por secciones mejora la calidad de la simplificación	25
3.2.2. Hipótesis 2: El manejo correcto de abreviaciones médicas mejora la comprensión	26
3.2.3. Hipótesis 3: La explicación del tratamiento incrementa la accesibilidad del informe	28
3.3. Arquitectura general del sistema	30
3.3.1. Entrada y preprocesamiento	30
3.3.2. Módulo de tratamiento de abreviaciones	31
3.3.3. Módulo de tratamiento de medicamentos	31
3.3.4. Flujo de simplificación	33
4. Diseño experimental	35
4.1. Descripción del corpus	35
4.1.1. Origen de los informes	35
4.1.2. Características del corpus	37
4.2. Simplificación general vs. por secciones (Hipótesis 1)	42
4.2.1. Enfoque 1: Simplificación global del informe	42
4.2.2. Enfoque 2: Simplificación por secciones con <i>prompts</i> especializados	43
4.2.3. Consideraciones generales de diseño	44
4.3. Tratamiento de abreviaciones (Hipótesis 2)	46
4.3.1. Detección de abreviaciones	46
4.3.2. Búsqueda de posibles significados	48
4.3.3. Contextualización en el informe clínico	49
4.4. Tratamiento de la medicación (Hipótesis 3)	51
4.4.1. Reconocimiento de medicamentos y principios activos	51

4.4.2. Generación de explicaciones terapéuticas	52
4.4.3. Búsqueda de la explicación terapéutica	53
4.5. Tecnologías utilizadas	56
4.5.1. Python	56
4.5.2. Hugging Face	57
4.5.3. vLLM	57
4.5.4. Git y GitHub	57
4.6. Evaluación de la simplificación	58
4.6.1. Evaluación global de la redacción simplificada	58
4.6.2. Evaluación de las subtarefas asociadas	60
5. Resultados	63
5.1. Resultados cuantitativos	63
5.1.1. Identificación de abreviaciones	63
5.1.2. Identificación de medicamentos y principios activos	64
5.1.3. Evaluación manual realizada por expertos	64
5.2. Análisis de errores	66
5.2.1. Módulo de tratamiento de abreviaciones	66
5.2.2. Módulo de tratamiento de medicamentos	68
5.2.3. Simplificación global	70
5.3. Resultados cualitativos: ejemplos ilustrativos	72
5.3.1. Hipótesis 1: La división por secciones mejora la calidad de la simplificación	72
5.3.2. Hipótesis 2: El manejo correcto de abreviaciones médicas mejo- ra la comprensión	74
5.3.3. Hipótesis 3: La explicación del tratamiento incrementa la accesi- bilidad del informe	75
6. Plataforma de demostración	79
6.1. Objetivos de la plataforma	79
6.2. Análisis	80

6.2.1. Público Objetivo	80
6.2.2. Requisitos de la plataforma	81
6.3. Diseño de la Interfaz	82
6.3.1. Principios de Diseño	82
6.3.2. Wireframes	83
6.4. Visualización de la implementación	84
6.5. Integración del backend	86
6.6. Limitaciones y mejoras futuras	86
6.6.1. Limitaciones	87
6.6.2. Mejoras futuras	87
7. Conclusiones	89
7.1. Resumen de los hallazgos	89
7.2. Principales contribuciones	90
7.3. Trabajo futuro	91
Bibliografía	VI
A. Análisis Visual y de Complejidad del Corpus Médico	VII
B. Especificaciones de <i>prompts</i> utilizados	XIII
B.1. <i>Prompt</i> utilizado en la estrategia de simplificación global	XIII
B.2. Estructura instruccional de los <i>prompts</i> por sección	XIV
B.3. <i>Prompt</i> de anotación de abreviaciones clínicas	XIV
B.4. <i>Prompt</i> de anotación de medicamentos y principios activos	XVI
B.5. <i>Prompt</i> de extracción de información terapéutica	XVIII
C. Evaluaciones de Cardiólogos Expertos	XXI
C.1. Evaluación del Experto 1	XXII
C.1.1. Evaluaciones Específicas	XXIII
C.2. Evaluación del Experto 2	XXVI
C.2.1. Evaluaciones Específicas	XXVII

Lista de figuras

1.1. Objetivos de Desarrollo Sostenible relacionados con el proyecto. Fuente: https://www.pactomundial.org/que-puedes-hacer-tu/ods/	7
1.2. Planificación temporal del TFG mostrando las nueve fases principales del proyecto: desde la revisión bibliográfica hasta el análisis de resultados, con una duración total estimada de 7 meses.	9
2.1. Esquema de la arquitectura <i>Transformer</i> , introducida por Vaswani et al. [1]. El modelo se compone de codificadores (encoders) y decodificadores (decoders) que emplean mecanismos de atención multi-cabeza y capas <i>feed-forward</i>	13
3.1. Comparación del proceso de expansión de abreviaciones	27
3.2. Ejemplo de simplificación funcional de prescripciones médicas	29
3.3. Captura de pantalla del Diccionario de Siglas Médicas de la Sociedad Española de Documentación Médica (SEDOM). Fuente: http://diccionario.sedom.es/	32
3.4. Captura de la sección sobre farmacovigilancia en la web de la AEMPS. Fuente: https://www.aemps.gob.es/	33

3.5. Esquema general del sistema de simplificación de informes clínicos. El flujo parte de la izquierda con la entrada de un informe clínico en formato PDF, que pasa por un módulo de preprocesamiento, encargado de limpiar y dividir el texto en secciones. El contenido se dirige al centro del sistema, donde un modelo de lenguaje simplifica cada sección individual. Este modelo está asistido por dos módulos especializados: el de tratamiento de abreviaciones, que consulta el diccionario oficial de la SEDOM, y el de tratamiento de medicamentos, que accede a información terapéutica de la AEMPS. Finalmente, a la derecha, el sistema produce una salida simplificada y comprensible para pacientes, con énfasis en claridad y accesibilidad. Fuente: elaboración propia.	34
4.1. Primera página de un informe de alta hospitalaria cedido por el Hospital [REDACTED], utilizado con fines de investigación en el procesamiento del lenguaje clínico. Todos los datos han sido anonimizados para preservar la confidencialidad del paciente por parte del hospital.	36
4.2. Distribución de longitud de secciones - Explica que es un diagrama de cajas con escala logarítmica mostrando mediana, cuartiles y valores atípicos.	38
4.3. frecuencia de aparición de secciones - Describe el gráfico de barras con frecuencias normalizadas y su relevancia para identificar secciones obligatorias vs. opcionales.	39
4.4. Matriz de coocurrencias - Caracteriza el mapa de calor de términos clínicos y su relación con protocolos diagnósticos.	40
4.5. Comparación de vocabulario - Explica la comparación léxica entre ambos corpus (MLSM e informes de alta cardiológicos) y su significado en términos de especialización terminológica	41
4.6. <i>Prompt</i> utilizado para la simplificación automática de informes de alta de cardiología	43
4.7. Error en la detección automática de abreviaciones mediante expresiones regulares. La expresión regular utilizada proporciona una buena aproximación para la detección de abreviaciones, pero comete errores cuando el texto se encuentra completamente en mayúsculas, identificando erróneamente palabras comunes como «DE» y «SU» como posibles abreviaciones médicas.	47
4.8. Métricas de entrenamiento del modelo LLaMA 3B 3.2 especializado en detección de abreviaciones	48

4.9. Ejemplo de búsqueda de la abreviatura “HTA” (hipertensión arterial) en el diccionario de siglas médicas de la Sociedad Española de Documentación Médica (SEDOM). Fuente: http://diccionario.sedom.es/ . Consultado el 18 de junio de 2025.	50
4.10. Métricas de entrenamiento del modelo LLaMA 3B 3.2 especializado en detección de medicamentos y principios activos	52
4.11. Fragmento de la ficha técnica del medicamento <i>Paracetamol Tecnigen 1 g comprimidos EFG</i> , publicada por la AEMPS. Fuente: https://cima.aemps.es/cima/dochtml/ft/75994/FT_75994.html	54
4.12. Fragmento del prospecto del medicamento <i>Paracetamol Tecnigen 1 g comprimidos EFG</i> , disponible en el sitio web de la AEMPS. Fuente: https://cima.aemps.es/cima/dochtml/p/75994/P_75994.html	54
4.13. Matriz de distancia de Levenshtein para la comparación entre las cadenas “paracitamol” (entrada con error ortográfico) y “paracetamol” (nombre genérico de referencia). Fuente propia.	55
4.14. Logos de las principales tecnologías utilizadas en el desarrollo del proyecto. Fuentes: Python (https://www.python.org/), Git (https://git-scm.com/), GitHub (https://github.com/), vLLM (https://github.com/vllm-project/vllm), Hugging Face (https://huggingface.co/).	58
4.15. Ejemplos de evaluación de casos clínicos: comparación entre una evaluación incorrecta (caso 82) y una evaluación adecuada (caso 85)	60
5.1. Error de desambiguación de la abreviación HTP en el módulo de tratamiento de abreviaciones. El sistema interpretó incorrectamente HTP como «hipertensión portal» en lugar de «hipertensión pulmonar», que es el significado correcto en el contexto cardiológico del ecocardiograma.	67
5.2. Error en el módulo de reconocimiento de medicamentos. El sistema identificó incorrectamente la finalidad del medicamento combinado Olmesartán/Amlodipino/Hidroclorotiazida, atribuyendo su uso solo al tratamiento de edemas en lugar de su verdadero propósito: el control de la hipertensión arterial.	69

5.3. Error conceptual grave en la explicación del Síndrome de Tako-Tsubo tipo 1. El sistema interpretó incorrectamente este síndrome como una infección bacteriana, cuando según la Sociedad Española de Cardiología se trata de una miocardiopatía por estrés emocional, también conocida como "síndrome del corazón roto".	71
6.1. Wireframe de la pantalla de subida de archivo	83
6.2. Wireframe de la pantalla de visualización comparativa	84
6.3. Implementación final de la pantalla de subida de archivo	85
6.4. Implementación final de la pantalla de visualización comparativa	85
A.1. Nube de palabras - Sección Revisiones	VII
A.2. Nube de palabras - Sección Evolución y curso clínico	VIII
A.3. Nube de palabras - Sección Tratamiento	VIII
A.4. Nube de palabras - Sección Pruebas complementarias	VIII
A.5. Nube de palabras - Sección Enfermedad actual	IX
A.6. Nube de palabras - Sección Antecedentes	IX
A.7. Nube de palabras - Sección Juicio Clínico	IX
A.8. Nube de palabras - Sección Motivo de ingreso	X
A.9. Nube de palabras - Sección Plan de actuación	X
A.10. Nube de palabras - Sección Intervención/Procedimientos quirúrgicos	X
A.11. Análisis de complejidad léxica por sección mediante gráfico radar. Las tres dimensiones evaluadas son: longitud media de palabra, frases por texto y diversidad léxica (TTR).	XI

Lista de tablas

2.1. Comparativa de ajuste fino y <i>prompting</i> en modelos clínicos	16
4.1. Configuración detallada de hiperparámetros para el <i>fine-tuning</i> del mo- delo LLaMA 3.2-1B Instruct	49
5.1. Resultados de la identificación de abreviaciones.	63
5.2. Resultados de identificación para diferentes categorías SLM	64
5.3. Tabla de valoraciones por informe	65
B.1. Elementos instructivos adicionales por sección (todos los <i>prompts</i> inclu- yen [1–5, 9–13] por defecto).	xv

Capítulo 1

Introducción

La comunicación médica efectiva ha de ser intrínseca a la relación entre profesionales sanitarios y pacientes. Sin embargo, los informes de alta hospitalaria presentan frecuentemente un lenguaje técnico especializado que dificulta su comprensión por parte de los pacientes y sus familias. Esta barrera comunicativa deriva en una falta de comprensión que no solo genera incertidumbre, sino que puede comprometer la adherencia al tratamiento y el seguimiento médico posterior, lo que puede afectar negativamente a su recuperación.

En este contexto, el avance de las tecnologías de Procesamiento de Lenguaje Natural (PLN) y el desarrollo de grandes modelos de lenguaje (*Large Language Models*, LLMs) abren nuevas posibilidades para abordar este problema como una alternativa novedosa con resultados potencialmente prometedores. Estas herramientas son capaces de transformar textos complejos manteniendo su contenido preciso, y adaptan el registro y la complejidad del lenguaje según las necesidades del receptor.

El presente Trabajo de Fin de Grado propone SimpliMed, un sistema automatizado diseñado para transformar informes de alta hospitalaria en versiones accesibles y comprensibles para los pacientes. Mediante la implementación de técnicas avanzadas de PLN y la experimentación con diferentes métodos de redacción automática, se busca desarrollar una solución que preserve la integridad de la información médica mientras facilita su interpretación, contribuyendo así al fortalecimiento de la comunicación en el ámbito sanitario.

1.1. Propósito principal

El propósito general de este proyecto es desarrollar un enfoque basado en técnicas avanzadas de PLN que explore la simplificación de los informes de alta hospitalaria con el fin de lograr una mayor accesibilidad y comprensión por parte de los pacientes. Esto se centra en adaptar el contenido clínico, habitualmente cargado de tecnicismos, a un lenguaje claro y comprensible para personas sin formación médica, consiguiendo así garantizar el derecho del paciente a entender la información relativa a su salud.

1.2. Motivación

La dificultad inherente de ciertos textos escritos ha provocado que la sociedad exija textos más transparentes y accesibles. Esto ha dado lugar a varios movimientos, como el movimiento de Lenguaje Claro (*Plain Language*, PL)¹ y el movimiento de Lectura Fácil (*Easy-to-Read*, E2R)².

En este contexto, el objetivo de la simplificación de informes de alta médicos es clarificar estos textos complejos mediante su formulación y diseño de manera que sean comprensibles y lleguen correctamente al paciente. Se busca transformar el lenguaje especializado en un lenguaje claro, es decir, un lenguaje que use una sintaxis correcta, concisa y clara, y un léxico comprensible y no enrevesado, sin renunciar nunca a la precisión y al rigor.

Sin embargo, el proceso de adaptación de textos al Lenguaje Claro continúa siendo mayoritariamente manual, lo que lo convierte en una tarea laboriosa, lenta y costosa. Esta dificultad se agrava en el ámbito sanitario, donde el escaso tiempo disponible para la atención al paciente dificulta que los profesionales redacten informes adaptados. Ante esta situación, la Inteligencia Artificial (IA), y en particular los avances en PLN, ofrece una solución prometedora al automatizar estos procesos de simplificación textual.

La necesidad de facilitar la comprensión de los textos no es un asunto menor. Aunque todos los ciudadanos tienen derecho a comprender las comunicaciones oficiales, la escritura médica suele contener terminología compleja y estructuras enrevesadas que la hacen inaccesible para la mayoría de las personas. Este problema resulta especialmente preocupante en España, donde, según el último informe de competencias de la OCDE (2023)², el 31 % de los adultos obtuvo una puntuación en el nivel 1 o inferior en competencia lectora, lo que indica un nivel bajo. En este nivel, las personas pueden

¹<https://www.plainlanguage.gov/resources/articles/beyond-a-movement/>

²<https://www.inclusion-europe.eu/easy-to-read/>

comprender textos breves y listas organizadas cuando la información está claramente indicada, mientras que quienes están por debajo de este nivel apenas comprenden frases cortas y sencillas. Por el contrario, solo un 4 % alcanzó los niveles 4 o 5, lo que implica la capacidad de comprender textos largos y densos, captar significados complejos y utilizar conocimientos previos para completar tareas. Esta situación evidencia una brecha significativa de comprensión lectora en la población adulta, que se agrava aún más en el caso de las personas con discapacidades cognitivas, quienes enfrentan barreras adicionales para acceder a los contenidos textuales. En este sentido, existe un conjunto de directrices publicadas por la UNE (AENOR, 2018)^[3], que establece los principios y normas para hacer que un texto sea fácil de leer en español. Estas directrices sirven como referencia para adaptar textos desde la variedad estándar a versiones más accesibles, garantizando así el derecho a comprender y facilitando una toma de decisiones informada e inclusiva por parte de toda la ciudadanía.

De hecho, en España, la recientemente promulgada “*Ley Orgánica 5/2024, de 11 de noviembre, del Derecho de Defensa*”^[3] establece que “los actos procesales y las comunicaciones se redactarán en lenguaje claro, de forma sencilla y universalmente accesible, de manera que permitan a sus destinatarios conocer el objeto y las consecuencias del acto procesal comunicado”. Esta ley convierte la adaptación de textos en una tarea obligatoria en el ámbito judicial que probablemente en un futuro se traslade a otros dominios como puede ser el médico. En última instancia, los principales beneficiarios de estas tecnologías serán los ciudadanos, que dejarán de tener dificultades al leer y comprender documentos oficiales que los encontrarán adaptados a su nivel y necesidades ^[4].

1.3. Hipótesis principal

La hipótesis principal de este proyecto propone que la aplicación de herramientas fundamentadas en inteligencia artificial, especialmente, los grandes modelos de lenguaje y métodos de aprendizaje automático, facilitará la creación de informes de alta médica en un lenguaje comprensible en el campo de la cardiología de forma más eficaz. Se anticipa que el uso de métodos sofisticados de simplificación textual permitirá convertir el informe inicial en un documento escrito en un lenguaje comprensible, lo que simplificará la interpretación y el acceso del paciente a la información médica.

³https://www.boe.es/diario_boe/txt.php?lang=eu&id=BOE-A-2024-23630

1.4. Objetivos

El presente Trabajo de Fin de Grado tiene como propósito principal contribuir a la mejora de la comprensión de los informes de alta hospitalaria mediante técnicas de Procesamiento del Lenguaje Natural (PLN), enfocándose en el dominio clínico-cardiológico.

Para ello, se establece el siguiente objetivo general:

- **Objetivo general:** Realizar una experimentación exhaustiva con diferentes estrategias y modelos de PLN aplicados a la simplificación de lenguaje clínico, con el fin de desarrollar un sistema capaz de transformar automáticamente informes de alta hospitalaria en cardiología, preservando la precisión médica, la intención comunicativa original y adaptando el lenguaje a un nivel comprensible para pacientes sin formación técnica.

A partir de este objetivo general, se plantean los siguientes objetivos específicos:

1. Investigar distintas estrategias de simplificación textual en el ámbito clínico, valorando enfoques extractivos y controlados mediante instrucciones o *prompts*.
2. Experimentar con diversos modelos de lenguaje (ligeros y avanzados), evaluando su capacidad para simplificar sin pérdida de información crítica.
3. Analizar la efectividad de distintos tipos de *prompting*, incluyendo instrucciones personalizadas por sección del informe (anamnesis, tratamiento, etc.), y variantes que expliciten abreviaciones o detalles de medicamentos.
4. Diseñar y desarrollar una plataforma web interactiva que sirva como demostrador funcional del sistema propuesto, permitiendo subir informes y visualizar su simplificación.
5. Construir un diccionario personalizado de abreviaciones clínicas adaptado al corpus disponible, e integrarlo en el sistema como apoyo a la interpretación.
6. Validar las hipótesis propuestas (división por secciones, tratamiento de abreviaciones y explicación farmacológica) mediante evaluación cualitativa y cuantitativa de los resultados obtenidos.
7. Redactar una memoria completa del proyecto, justificando las decisiones técnicas adoptadas, los resultados obtenidos y su impacto potencial en la práctica médica y la comunicación médico-paciente.

1.5. Contribución a los Objetivos de Desarrollo Sostenible (ODS)

El proyecto contribuye directamente a varios Objetivos de Desarrollo Sostenible (ODS) establecidos por la Organización de las Naciones Unidas (ONU) en la Agenda 2030⁴. Esta sección describe cómo el sistema propuesto se alinea con los ODS y sus metas específicas:

ODS 3: Salud y Bienestar

“Garantizar una vida sana y promover el bienestar para todos en todas las edades.”

SimpliMED contribuye a la **Meta 3.8**, que establece la necesidad de lograr la cobertura sanitaria universal, incluido el acceso a servicios de salud esenciales de calidad. Al traducir informes clínicos complejos a un lenguaje comprensible, el sistema:

- Mejora la alfabetización en salud
- Promueve la adherencia terapéutica
- Reduce errores por mala interpretación
- Fomenta una atención centrada en el paciente

ODS 4: Educación de Calidad

“Garantizar una educación inclusiva, equitativa y de calidad y promover oportunidades de aprendizaje durante toda la vida.”

Este proyecto responde a la **Meta 4.7**, que promueve el acceso a conocimientos teóricos y prácticos relacionados con el desarrollo sostenible, incluidos los vinculados con la salud y el bienestar. SimpliMED promueve la educación para la salud al facilitar la comprensión de conceptos médicos, empoderando así a los ciudadanos en la toma de decisiones informadas sobre su salud.

ODS 10: Reducción de las Desigualdades

“Reducir la desigualdad en y entre los países.”

⁴<https://www.un.org/sustainabledevelopment/es/objetivos-de-desarrollo-sostenible/>

El sistema está directamente relacionado con la **Meta 10.2**, que busca empoderar y promover la inclusión social, económica y política de todas las personas, especialmente aquellas en situación de vulnerabilidad. Al eliminar las barreras del lenguaje técnico, SimpliMED favorece la equidad en el acceso a la información sanitaria, especialmente entre:

- Personas con bajo nivel educativo
- Individuos con dificultades cognitivas
- Personas con conocimiento limitado del idioma

ODS 16: Paz, Justicia e Instituciones Sólidas

“Promover sociedades justas, pacíficas e inclusivas.”

Este proyecto apoya la **Meta 16.10**, que busca garantizar el acceso público a la información. SimpliMED fomenta el derecho a comprender la propia información clínica, reforzando la transparencia institucional y el principio de lenguaje claro, en consonancia con las directrices legales nacionales e internacionales sobre derechos de los pacientes.

ODS 17: Alianzas para Lograr los Objetivos

“Revitalizar la Alianza Mundial para el Desarrollo Sostenible.”

La naturaleza interdisciplinar de SimpliMED se alinea con la **Meta 17.17**, que promueve alianzas eficaces entre el sector público, privado y sociedad civil. El desarrollo de soluciones como esta requiere la colaboración entre profesionales de múltiples disciplinas:

- Ingeniería y tecnología
- Medicina y ciencias de la salud
- Lingüística y comunicación
- Diseño centrado en el usuario

En resumen, SimpliMED no sólo representa un avance técnico en el ámbito del procesamiento del lenguaje natural, sino que también constituye una propuesta con impacto social tangible, en consonancia con los valores de equidad, accesibilidad, justicia e inclusión que inspiran la Agenda 2030.



Figura 1.1: Objetivos de Desarrollo Sostenible relacionados con el proyecto. Fuente: <https://www.pactomundial.org/que-puedes-hacer-tu/ods/>

1.6. Estructura de la memoria

La estructura del presente trabajo está organizada en los siguientes capítulos:

Capítulo 1. Introducción: Se establece el marco general del proyecto, definiendo el propósito principal de SimpliMED como sistema de simplificación de informes médicos. Se presenta la motivación que impulsa este trabajo, la hipótesis principal sobre la mejora de la comprensión de textos médicos mediante inteligencia artificial, y los objetivos específicos a alcanzar. Además, se incluye la planificación temporal y el análisis de costes del proyecto. En este capítulo también se aborda la relación del proyecto con los Objetivos de Desarrollo Sostenible (ODS), destacando cómo SimpliMED contribuye a mejorar la salud y el bienestar, así como la educación inclusiva y de calidad.

Capítulo 2. Antecedentes: Se proporciona una revisión exhaustiva del estado del arte en simplificación de textos médicos y procesamiento de lenguaje natural aplicado al ámbito sanitario. Se analizan las investigaciones previas, las limitaciones de los enfoques existentes y se contextualiza la necesidad de desarrollar herramientas específicas para la simplificación de informes médicos.

Capítulo 3. Definición de la propuesta: Se detalla la propuesta técnica del sistema SimpliMED, incluyendo la justificación y selección de los modelos de lenguaje utilizados. Se formulan las tres hipótesis de trabajo principales: la mejora mediante división por secciones, el impacto del manejo de abreviaciones médicas, y el valor añadido de la explicación de tratamientos. Se presenta la arquitectura general del sistema, describiendo los módulos de preprocesamiento, tratamiento de abreviaciones, manejo de medicamentos y el flujo de simplificación.

Capítulo 4. Diseño experimental: Se describe la metodología experimental empleada para validar las hipótesis planteadas. Se caracteriza el corpus de informes médicos utilizado, detallando su origen y propiedades. Se establecen los criterios y métricas de evaluación para cada una de las hipótesis, incluyendo la comparación entre simplificación general versus por secciones, el sistema de detección y expan-

sión de abreviaciones, y la evaluación del tratamiento de medicación y generación de explicaciones terapéuticas.

Capítulo 5. Resultados: En este capítulo se presenta un análisis manual de los resultados obtenidos tras aplicar el sistema SimpliMED sobre un conjunto representativo de informes médicos del ámbito de la cardiología. El análisis ha sido realizado por profesionales del entorno clínico con el objetivo de valorar de forma cualitativa la utilidad y claridad de los textos simplificados. No se incluyen en esta fase métricas automáticas, ya que no existen métricas de calidad para evaluar correctamente la simplificación en un dominio médico. Se realiza la validación cuantitativa de las distintas subtarefas planteadas en la propuesta se desarrollará en etapas posteriores como la detección de abreviaciones o medicamentos.

Capítulo 6. Plataforma de demostración: Se presenta el desarrollo de una plataforma web interactiva que permite demostrar el funcionamiento del sistema SimpliMED en tiempo real. Se describe la arquitectura de la plataforma, incluyendo el diseño del frontend, la implementación del backend y la integración con los módulos de simplificación. Se detallan las tecnologías utilizadas, la interfaz de usuario diseñada para facilitar la carga de informes médicos y la visualización de resultados, así como las consideraciones de usabilidad y accesibilidad implementadas.

Capítulo 7. Conclusiones: Se recapitulan los hallazgos principales del trabajo, se discuten las implicaciones de los resultados obtenidos y se evalúa el cumplimiento de los objetivos establecidos. Se identifican las limitaciones del sistema desarrollado y se proponen futuras líneas de investigación para mejorar la simplificación automática de textos médicos.

Con esta estructura, se espera proporcionar una comprensión integral de los métodos y tecnologías utilizados en el desarrollo de SimpliMED, así como una evaluación rigurosa de su efectividad para mejorar la accesibilidad de los informes médicos.

1.7. Planificación y costes

El objetivo de la planificación es estructurar y organizar el desarrollo del proyecto de forma eficiente, permitiendo establecer estimaciones temporales razonables para cada fase. Esta planificación ha sido diseñada de forma flexible para adaptarse a imprevistos y se representa mediante un diagrama de Gantt, como puede verse en la Figura 1.2.

Las fases planificadas son las siguientes: revisión del estado del arte, obtención y análisis de informes clínicos, preprocesamiento de textos clínicos, definición de la metodología de simplificación, desarrollo del módulo de abreviaciones, desarrollo del




Figura 1.2: Planificación temporal del TFG mostrando las nueve fases principales del proyecto: desde la revisión bibliográfica hasta el análisis de resultados, con una duración total estimada de 7 meses.

módulo de medicamentos, entrenamiento y ajuste de modelos, evaluación manual por expertos clínicos y análisis de resultados y errores.

A continuación se describen los recursos empleados y su valoración económica aproximada.

Costes de hardware: 2.200 €

- Ordenador personal con CPU AMD Ryzen y 16 GB de RAM: 700 €
- Acceso a GPU NVIDIA Tesla de 32 GB para entrenamiento: 1.500 € (valor estimado por uso académico intensivo)

Costes de software: 0 €

- Ubuntu
- Python
- Visual Studio Code
- Transformers, PyTorch y otras librerías open source

Coste de personal: 2.923,14 €

Se ha seguido el convenio del BOE núm. 92, de 16 de abril de 2025⁵, considerando el Área 4, grupo C, nivel 2, con un salario anual de 26.308,29 €. Se estima una dedicación de un noveno del año, equivalente a tres meses de trabajo a jornada parcial:

$$\frac{26,308,29}{9} \approx 2,923,14$$

Coste de evaluación externa: 240 €

La evaluación fue realizada por dos cardiólogos expertos durante una mañana completa (4 horas en total), con una tarifa estimada de 30 €/hora por persona:

$$2 \times 4 \times 30 = 240$$

Coste total estimado: 5.363,14 €

⁵<https://www.boe.es/boe/dias/2025/04/16/pdfs/B0E-S-2025-92.pdf>

Capítulo 2

Antecedentes

2.1. Procesamiento del Lenguaje Natural

El Procesamiento del Lenguaje Natural es una rama de la inteligencia artificial que se ocupa de la interacción entre el lenguaje humano y las máquinas. A lo largo de las últimas décadas, ha evolucionado desde enfoques basados en reglas lingüísticas hasta modelos estadísticos y, más recientemente, arquitecturas de aprendizaje profundo. El desarrollo de representaciones distribuidas como *word2vec* [5] y *GloVe* [6] marcó una transición clave hacia métodos más contextuales, que culminó en la aparición de los modelos de tipo *transformer* como BERT [7], capaces de captar relaciones semánticas complejas dentro del texto.

El uso de grandes cantidades de texto para entrenar modelos de lenguaje ha permitido avances significativos en tareas como el análisis sintáctico, la generación automática de texto o la traducción automática. Esta línea de investigación se consolidó con el trabajo de Howard y Ruder, quienes introdujeron ULMFiT (*Universal Language Model Fine-tuning*), mostrando que un modelo entrenado de forma no supervisada sobre grandes corpus puede ser afinado con pocos ejemplos para diversas tareas de PLN [8].

En los últimos años, la tendencia ha girado hacia los modelos fundacionales, capaces de realizar múltiples tareas con un solo entrenamiento base. Una referencia clave en este ámbito es el trabajo de Brown et al., quienes presentaron GPT-3, un modelo con 175 mil millones de parámetros, demostrando capacidades sorprendentes en comprensión, generación y razonamiento lingüístico sin necesidad de entrenamiento adicional específico [9]. Estos avances han redefinido los límites del PLN y plantean nuevas oportunidades, así como retos en cuanto a eficiencia, equidad y uso responsable.

2.2. Modelos de lenguaje aplicados al texto clínico

2.2.1. Modelos de propósito general

La implementación de modelos de lenguaje de propósito general en el ámbito clínico ha demostrado su eficacia en diversas tareas sobre texto clínico no estructurado, como extracción de conceptos, inferencia y generación de resúmenes.

Estos modelos se basan principalmente en la arquitectura *transformer*, introducida por Vaswani et al. en su influyente trabajo “*Attention is All You Need*” [1], que eliminó por completo la necesidad de recurrencias y convoluciones mediante un mecanismo de atención auto-regresiva escalable. Esta arquitectura ha sido la base de modelos ampliamente utilizados como BERT, RoBERTa o GPT, los cuales han marcado un hito en el procesamiento de lenguaje natural (véase la Figura 2.1).

Por ejemplo, Xi Yang et al. exploraron modelos tipo BERT (incluyendo variantes como RoBERTa, ALBERT y ELECTRA) para la extracción de conceptos clínicos en datasets públicos (i2b2 2010/2012¹, n2c2 2018²), constatando mejoras de entre 4 % y 6 % en F1 respecto a modelos LSTM-CRF; en particular, RoBERTa-MIMIC alcanzó $F1 \approx 0,90$ en varios conjuntos [10][11].

Además, en el contexto de la inferencia textual clínica, un BERT entrenado en 75 millones de notas de alta del UCSF (aproximadamente 75 M documentos) alcanzó rendimientos parejos a los modelos biomédicos públicos, y superó significativamente a los modelos que usan vocabularios generales al evaluarse en tareas de reconocimiento de conceptos, extracción de relaciones y asignación de códigos diagnósticos [12].

Otro enfoque relevante es el uso de modelos transformadores ligeros, creados por técnicas como distilación y aprendizaje continuo, que reducen drásticamente el número de parámetros (de 15 M a 65 M) sin sacrificar rendimiento respecto a BioBERT y ClinicalBERT preexistentes, logrando resultados competitivos en tareas como inferencia, extracción de relaciones, NER y clasificación de secuencias [13].

En cuanto al análisis de similitud semántica, modelos tipo XLNet y RoBERTa preentrenados sobre datos clínicos fueron evaluados en el desafío n2c2 (2019), obteniendo alta correlación (Pearson $\sim 0,89$ a $0,91$) en la medición de similitud entre frases clínicas, lo que resulta útil para deduplicación o resumen de texto médico [14].

Recientemente, se ha avanzado hacia esquemas text-to-text: el modelo generativo GatorTronGPT (aproximadamente 20 B parámetros), basado en arquitectura GPT-3 y afinado mediante *prompt-tuning*, demostró superioridad (+3 % en extracción de con-

¹<https://www.i2b2.org/NLP/DataSets/>

²<https://portal.dbmi.hms.harvard.edu/projects/n2c2-nlp/>

ceptos, +7 % en extracción de relaciones) respecto a modelos específicos por tarea en siete tareas clínicas comunes [11].

2.2.2. Modelos especializados en salud

En los últimos años han surgido modelos de lenguaje entrenados específicamente para el dominio clínico o biomédico, optimizados según el tipo de dato (texto libre, registros electrónicos) y tarea (extracción, predicción, generación).




Figura 2.1: Esquema de la arquitectura *Transformer*, introducida por Vaswani et al. [1]. El modelo se compone de codificadores (encoders) y decodificadores (decoders) que emplean mecanismos de atención multi-cabeza y capas *feed-forward*.

MT-Clinical BERT es un modelo multitarea basado en BERT entrenado desde cero con datos clínicos para ocho tareas simultáneas, que incluyen extracción de entidades, detección de información de salud protegida (PHI), entailment e inferencia semántica. Entrega resultados comparables a modelos específicos para cada tarea, con ventajas de eficiencia en inferencia) [15].

Clinical-Longformer y Clinical-BigBird adaptan variantes de atención dispersa (Longformer, BigBird) a secuencias clínicas de hasta 4096 tokens, superando consistentemente a ClinicalBERT en tareas como NER, respuesta a preguntas y clasificación de documentos [16].

Med-BERT extiende BERT al dominio de registros electrónicos estructurados (EHR), preentrenándose con datos de más de 28 millones de pacientes. Al afinarlo en tareas clínicas como predicción de insuficiencia cardíaca o cáncer de páncreas, mejora el AUC entre 2 % y 7 % y alcanza la misma precisión que modelos entrenados con conjuntos 10 veces mayores [17].

CEHR-BERT incorpora explícitamente información temporal (tokens de tiempo, edad, tipo de visita) en su arquitectura y se entrena con datos de 2.4 millones de pacientes. Supera a otras adaptaciones basadas en BERT en múltiples tareas predictivas como hospitalización, muerte o readmisión, y mantiene ventaja incluso con muy pocos datos de entrenamiento (solo 5 %) [18].

Otros modelos destacados incluyen:

ChestXRayBERT, diseñado para resumir informes de radiología de tórax, mostrando mejoras en abstracción de sumarios clínicos [19].

PathologyBERT, preentrenado sobre corpus de texto patológico para tareas específicas de patología, incrementando precisión en reconocimiento y extracción de hallazgos clínicos [20].

Modelos como RadBERT, BioBERT, PubMedBERT o Clinical XLNet, adaptados preentrenando sobre artículos biomédicos o notas clínicas, han demostrado mejor desempeño que sus equivalentes generales en tareas de extracción de entidades, inferencia y clasificación [21].

En contraste, estudios recientes sugieren que los modelos generales de embeddings pueden superar a modelos especializados en tareas de búsqueda semántica clínica de contexto corto, posiblemente debido a su entrenamiento en datos más variados y robustos.

2.2.3. Técnicas de ajuste y personalización

El ajuste y la personalización de modelos de lenguaje para el dominio clínico suelen abordarse mediante dos enfoques principales: *fine-tuning de parámetros* y *prompting*, cada uno con características y aplicaciones específicas (ver Tabla 2.1).

Ajuste fino de modelos. Consiste en continuar el entrenamiento de un modelo de propósito general usando corpus clínicos o biomédicos, adaptando pesos y vocabularios a la terminología específica. Por ejemplo, Tinn et al. demostraron que congelar capas inferiores y aplicar decaimiento de tasa de aprendizaje por capa mejora la estabilidad y el rendimiento de modelos BERT y ELECTRA en tareas clínicas [22]. Además, el *parameter-efficient fine-tuning* (PEFT) permite insertar adaptadores intermedios para ajustar solo una fracción de los parámetros, reduciendo recursos computacionales sin sacrificar precisión. Gema et al. aplicaron PEFT a modelos LLaMA clínicos, logrando mejoras de 4–5 % en AUROC en tareas de clasificación y predicción [23].

Otra estrategia frecuente es el *pre-entrenamiento continuo*, donde se entrena el modelo con grandes volúmenes de texto clínico adicional antes de realizar el fine-tuning en tareas específicas. Christophe et al. evaluaron esta técnica junto con *instruct tuning* y confirmaron que la combinación potencia la generación de texto clínico coherente y contextualizado [24].

Técnicas de prompting. Frente al ajuste de parámetros, el *prompting* explota el modelo congelado formulando instrucciones o ejemplos que guían su salida. Esta estrategia se ha consolidado gracias a modelos fundacionales robustos y la técnica de *prompt tuning*, que entrena pequeños vectores de *embeddings de prompt* manteniendo el resto del modelo fijo. Esto reduce drásticamente el coste computacional. En el ámbito clínico, el proyecto Chronosig mostró que el *prompting* con ClinicalBERT alcanza rendimientos comparables o superiores al fine-tuning tradicional usando hasta 1000 veces menos parámetros ajustables [25]. Además, enfoques de *in-context learning* permiten a grandes LLMs adaptarse a tareas clínicas sin entrenamiento adicional, solo mediante la formulación de ejemplos y preguntas específicas, como se evidencia en estudios recientes con GPT-3 y GPT-4 [9].

En conjunto, la selección de técnica depende de la disponibilidad de datos y recursos: el fine-tuning profundo es más potente cuando se dispone de corpus extensos y tiempo de entrenamiento; el *prompting* resulta ideal para escenarios de pocos datos o cuando se requiere adaptar rápidamente un modelo generalista a tareas clínicas específicas sin modificar su arquitectura interna.

Aspecto	Ajuste fino (Fine-tuning)	<i>Prompting</i>
Modificación del modelo	Modifica pesos internos y/o introduce adaptadores (LoRA, QLoRA).	Mantiene pesos congelados; ajusta instrucciones o <i>embeddings de prompt</i> .
Requerimientos de datos	Necesita corpus clínico extenso (miles de ejemplos) para buen desempeño.	Eficaz incluso con pocos ejemplos (<i>few-shot learning</i>).
Coste computacional	Alto – Entrenamiento prolongado, requiere GPUs potentes.	Bajo – Ajuste de vectores pequeños o solo ingeniería de <i>prompts</i> .
Flexibilidad	Alta especialización para tareas específicas, menor transferibilidad.	Alta versatilidad para múltiples tareas sin reentrenar.
Casos de uso recomendados	■ Sistemas clínicos robustos ■ Tareas críticas (predicción, clasificación) ■ Aplicaciones de producción	■ Prototipos rápidos ■ Tareas exploratorias ■ Generación interactiva ■ Investigación inicial
Interpretabilidad	Menor transparencia debido a modificaciones internas del modelo.	Mayor transparencia; cambios visibles en las instrucciones.
Tiempo de implementación	semanas/meses – Requiere experimentación extensa.	Horas/días – Implementación inmediata.

Tabla. 2.1: Comparativa de ajuste fino y *prompting* en modelos clínicos

2.3. Simplificación automática de texto

2.3.1. Evolución y enfoques actuales

La simplificación automática de texto ha experimentado una evolución significativa en las últimas décadas, impulsada por los avances en procesamiento del lenguaje natural y el desarrollo de grandes corpus paralelos de textos complejos y sus versiones simplificadas.

Etapas inicial basada en reglas. En sus orígenes, la simplificación se abordaba mediante sistemas de reglas lingüísticas explícitas, diccionarios de sinónimos y transformaciones sintácticas definidas manualmente. Estos sistemas eran altamente dependientes del dominio y poco escalables a otros contextos [26]. Herramientas pioneras como PSET [27] demostraron la viabilidad de aplicar reglas para reescribir oraciones complejas en versiones más simples, pero su rigidez limitaba la cobertura lingüística.

Transición a modelos estadísticos. A partir de la década de 2000, la disponibilidad de corpus paralelos como Wikipedia Simple motivó el enfoque de tratar la simplificación como un problema de traducción monolingüe. Modelos de traducción estadística (SMT) alineaban fragmentos complejos con sus equivalentes simplificados, optimizando la probabilidad de generar frases más sencillas manteniendo la coherencia semántica [28].

Modelos neuronales y aprendizaje profundo. La revolución de las redes neuronales secuenciales y, posteriormente, de los Transformers, supuso un salto cualitativo. Arquitecturas *sequence-to-sequence* (Seq2Seq) con atención, como BART o T5, superaron los límites de los SMT al modelar dependencias de largo alcance y producir simplificaciones más fluidas y coherentes [29]. Además, se ha explorado la generación controlable mediante tokens de nivel de simplicidad, permitiendo ajustar el grado de reescritura según el público objetivo [30].

Actualmente, la línea de investigación dominante se centra en integrar el *prompting* y el aprendizaje por instrucciones. Grandes modelos fundacionales como GPT-3 y GPT-4 pueden generar simplificaciones de alta calidad mediante indicaciones bien diseñadas, sin necesidad de entrenamiento adicional exhaustivo [31]. Esta tendencia abre nuevas vías para simplificar texto clínico y técnico de forma flexible y personalizable, con menor coste computacional y mayor adaptabilidad.

2.3.2. Métricas de evaluación

La evaluación de sistemas de simplificación automática de texto requiere medir de forma simultánea la fluidez gramatical, la preservación del significado y el nivel de simplicidad logrado. A diferencia de la traducción automática o el resumen, la simplificación puede implicar múltiples soluciones válidas, lo que dificulta usar métricas de coincidencia directa sin un corpus paralelo de referencia [32]. La calidad de la evaluación automática depende, por tanto, de disponer de textos originales alineados con versiones simplificadas de calidad humana.

Métricas automáticas tradicionales. Las métricas basadas en coincidencia de n-gramas, como BLEU [33] y ROUGE [34], se utilizan ampliamente para evaluar traducción y resumen, respectivamente, y se han adaptado para simplificación. Sin embargo, ambas pueden penalizar transformaciones sintácticas válidas que no coincidan superficialmente con la referencia. Para abordar esta limitación, se introdujo SARI [35], diseñada específicamente para simplificación: compara la salida del sistema con el texto original y las referencias, evaluando de forma separada adiciones, eliminaciones y preservaciones.

Más recientemente, se han empleado métricas basadas en embeddings contextuales, como BERTScore [36], que calcula la similitud semántica entre la salida y la referencia utilizando representaciones extraídas de modelos preentrenados. Estas métricas capturan mejor la conservación del contenido en simplificaciones más creativas, pero requieren potencia de cómputo adicional.

Métricas de legibilidad. Complementariamente, se aplican índices clásicos como FKGL (Flesch-Kincaid Grade Level) o FRE (Flesch Reading Ease) [37], que estiman la dificultad del texto en función de la longitud de palabras y oraciones. Aunque son útiles como indicador rápido, no garantizan la fidelidad semántica.

Evaluación humana. Dada la complejidad de la tarea, la evaluación manual sigue siendo imprescindible. Se suele solicitar a expertos o usuarios finales que puntúen la fluidez, adecuación y simplicidad mediante escalas de Likert o tareas de comprensión lectora [38]. Cada vez más, se exploran evaluadores automáticos basados en LLMs como jueces proxy.

2.4. Simplificación de documentos médicos

2.4.1. Informe de alta

El informe de alta hospitalaria es uno de los documentos más importantes en la práctica clínica, ya que recoge de forma resumida y organizada toda la información clave sobre el ingreso de un paciente. Suele incluir desde el motivo de hospitalización hasta la evolución, los procedimientos realizados, el tratamiento administrado y las recomendaciones para continuar la atención en casa o en consultas externas [39].

Su función principal es doble: por un lado, sirve como registro oficial y herramienta de comunicación entre médicos de distintos niveles asistenciales; por otro, debería ser un documento comprensible para el propio paciente y sus familiares, quienes necesitan conocer claramente los siguientes pasos en su recuperación [40]. No obstante, en la práctica, gran parte de estos informes están redactados con abundante terminología técnica, abreviaturas y estructuras complejas que dificultan su comprensión, sobre todo para personas sin conocimientos médicos [41].

Ante esta realidad, la simplificación automática de informes de alta se ha convertido en un reto interesante para el Procesamiento del Lenguaje Natural aplicado a la salud. El objetivo no es solo sustituir palabras complicadas por términos más simples, sino también reorganizar y aclarar la información para que cualquier paciente pueda entender qué le ha pasado, qué tratamiento debe seguir y cuándo acudir a una revisión [42]. Abordar este reto de forma efectiva podría mejorar la adherencia al tratamiento, reducir errores e instruir a los pacientes en el cuidado de su propia salud.

2.4.2. Sistemas existentes

En los últimos años han surgido diversas iniciativas y sistemas orientados a facilitar la comprensión de documentos médicos mediante técnicas automáticas de simplificación. Aunque gran parte de la investigación se ha centrado en textos médicos en inglés, cada vez se dispone de más recursos y corpus específicos para el español, lo que abre nuevas posibilidades de desarrollo y evaluación.

Uno de los ejemplos más destacados en el ámbito hispanohablante es el proyecto **CLARA-Med**, impulsado por el CSIC en colaboración con la UNED y la Universidad Complutense de Madrid, bajo la coordinación de Leonardo Campillo. Este proyecto se centra en la simplificación de informes médicos y ha desarrollado un corpus que incluye versiones originales de frases clínicas junto con su versión simplificada a nivel léxico y sintáctico [43]. Además, CLARA-Med pone a disposición una guía de estilo

que detalla los criterios seguidos para realizar la simplificación de forma coherente y controlada, lo que lo convierte en un recurso de referencia para futuros sistemas automáticos. El corpus está disponible públicamente a través del portal de datos abiertos del gobierno de España.³

A nivel europeo, destaca también el proyecto **DataTools4Heart**, una iniciativa internacional que reúne a varios socios con el objetivo de mejorar la interoperabilidad, reutilización y privacidad de los datos cardiológicos. Entre sus múltiples líneas de trabajo, se encuentra la creación de varios corpus multilingües (incluido el español) específicamente centrados en informes clínicos del ámbito cardiovascular. Estos recursos buscan facilitar el entrenamiento y la evaluación de modelos de simplificación automática y otras aplicaciones de PLN biomédico.⁴

El desarrollo de estos recursos supone un paso fundamental para entrenar modelos robustos y evaluar su rendimiento de manera fiable. Disponer de corpus paralelos, donde cada informe cuenta con su versión original y su correspondiente versión simplificada, permite aplicar tanto métricas automáticas como evaluaciones humanas, y garantiza que la simplificación mantenga la precisión clínica necesaria.

³<https://datos.gob.es/es/catalogo/ea0020951-clara-med-simplified-sentences>

⁴<https://www.datatools4heart.eu/>, <https://github.com/DataTools4Heart>

Capítulo 3

Definición de la propuesta

En este capítulo se presenta la propuesta metodológica desarrollada para abordar el problema de la simplificación de informes de cardiología mediante el uso de LLMs. Se detalla la elección de la tecnología empleada, justificando las decisiones tomadas en base a las características específicas del dominio médico.

3.1. Elección de LLMs

La selección de modelos de lenguaje de gran escala para la simplificación de informes cardiológicos requiere una evaluación cuidadosa de múltiples factores, incluyendo la capacidad de procesamiento del lenguaje natural especializado, la precisión en la interpretación de terminología médica, y la viabilidad computacional para su implementación práctica.

3.1.1. Justificación del uso de modelos de lenguaje

Los modelos de lenguaje de gran escala han demostrado capacidades excepcionales en tareas de procesamiento de lenguaje natural, especialmente en dominios especializados como el médico. Su aplicación en la simplificación de informes cardiológicos se justifica por las siguientes razones fundamentales:

3.1.1.1. Capacidad de generación y adaptación textual

Los LLMs poseen una capacidad inherente para generar texto coherente y contextualmente apropiado, adaptándose a diferentes niveles de complejidad según las necesidades del receptor. Esta característica es especialmente relevante en el contexto

médico, donde la misma información clínica debe ser comunicada de manera diferente según el destinatario sea un especialista médico, un médico de atención primaria, o un paciente [44].

La flexibilidad de estos modelos permite mantener la precisión médica mientras se simplifica la presentación de la información, un equilibrio crítico en la comunicación sanitaria. Estudios recientes han demostrado que los LLMs pueden preservar la integridad de la información médica mientras adaptan el registro lingüístico [45].

3.1.1.2. Potencial para traducir contenido médico técnico a lenguaje natural claro

Una de las principales ventajas de los LLMs en el contexto de la simplificación de informes médicos es su capacidad para actuar como “traductores” entre el lenguaje técnico especializado y el lenguaje natural comprensible para audiencias más amplias. Esta capacidad se basa en su entrenamiento en grandes corpus de texto que incluyen tanto terminología médica especializada como explicaciones en lenguaje común.

La literatura científica ha documentado casos exitosos de aplicación de LLMs en la traducción de terminología médica compleja a explicaciones accesibles, manteniendo la precisión diagnóstica mientras mejora significativamente la comprensibilidad [46]. Esta característica es fundamental para el desarrollo de herramientas que faciliten la comunicación entre profesionales sanitarios y pacientes.

Además, los LLMs han demostrado capacidad para identificar y explicar conceptos médicos complejos, proporcionando contexto adicional cuando es necesario para la comprensión completa del mensaje [47].

3.1.2. Modelo utilizado

Tras realizar una evaluación exhaustiva de diferentes arquitecturas y modelos disponibles, se seleccionó **LLaMA 3.2 8B Instruct** como modelo base para el desarrollo de la solución propuesta. Esta elección se fundamenta en un análisis comparativo de rendimiento y viabilidad técnica [46] [48].

3.1.2.1. Proceso de evaluación preliminar

Para la selección del modelo más adecuado, se llevó a cabo una serie de pruebas preliminares sistemáticas empleando diferentes arquitecturas de LLMs, midiendo

manualmente al cohesión y coherencia textual. El proceso de evaluación incluyó los siguientes modelos:

- **Familia LLaMA (modelos menores de 10B parámetros):** Se evaluaron versiones como LLaMA 2 y LLaMA 3, en configuraciones de 1B, 3B y 8B parámetros. Se analizó su capacidad para comprender terminología cardiológica y generar simplificaciones textuales adecuadas al contexto clínico.
- **Familia Mistral:** Se probaron modelos de código abierto como Mistral 7B, reconocido por su eficiencia computacional y buen rendimiento en tareas de procesamiento de lenguaje natural especializado.
- **Otros modelos open-source relevantes:** Se incluyeron modelos como Gemma 7B y **Phi-2**, que han demostrado buen rendimiento general en tareas de comprensión y generación de texto, incluyendo aplicaciones biomédicas básicas.
- **Familia OpenAI (GPT):** Se realizaron pruebas exploratorias mediante la API oficial de OpenAI¹ con el objetivo de establecer benchmarks cualitativos en tareas de simplificación clínica. Los modelos evaluados incluyen:
 - GPT-3 (text-davinci-003): Evaluado por su capacidad de razonamiento y generación fluida.
 - GPT-3.5 (gpt-3.5-turbo): Utilizado como baseline conversacional con buena relación rendimiento/coste.
 - GPT-4 (gpt-4 y gpt-4-0613): Evaluado por su comprensión avanzada y fidelidad terminológica.
 - GPT-4 Turbo (gpt-4-1106-preview, gpt-4-0125-preview): Versiones optimizadas con contexto expandido, útiles para tareas de largo recorrido.
 - GPT-4o (omni): Última versión multimodal de OpenAI, evaluado por su generación textual centradas en precisión semántica.

Limitaciones por privacidad y sensibilidad de datos: Debido a la naturaleza sensible de los datos médicos utilizados, todas las pruebas y despliegues reales se realizaron en recursos locales, evitando el uso de servicios en la nube o externos para garantizar la seguridad y confidencialidad de la información. Por este motivo, aunque se exploraron las capacidades de los modelos de OpenAI en fases exploratorias, no se utilizaron para la inferencia directa sobre informes clínicos reales. Esta restricción impuso además un límite en la capacidad computacional disponible, condicionando la selección de modelos a arquitecturas de menos de 70B parámetros.

¹<https://openai.com/api/>

3.1.2.2. Características del modelo LLaMA 3.2 8B Instruct

La selección final de LLaMA 3.2 8B Instruct se basó en la evaluación de sus características específicas y su rendimiento en las pruebas preliminares:

Sensibilidad al contexto: El modelo demostró una capacidad excepcional para mantener la coherencia contextual a lo largo de informes médicos extensos, preservando las relaciones entre diferentes secciones del informe durante el proceso de simplificación. Esta característica es crucial en el contexto cardiológico, donde la interpretación correcta de un hallazgo puede depender de información presentada en otras secciones del informe [24].

Razonamiento clínico básico: LLaMA 3.2 8B Instruct mostró capacidades de razonamiento clínico que, aunque no alcanzan el nivel de un especialista médico, son suficientes para identificar relaciones causales básicas entre síntomas, hallazgos diagnósticos, y recomendaciones terapéuticas. Esta capacidad permite que el modelo genere simplificaciones que no solo traducen la terminología, sino que también explican las implicaciones clínicas de los hallazgos reportados [49].

Eficiencia computacional: El modelo ofrece un equilibrio óptimo entre capacidad de procesamiento y eficiencia computacional, permitiendo su implementación en entornos con recursos limitados sin comprometer significativamente la calidad de las simplificaciones generadas. Esta característica es especialmente relevante para la viabilidad práctica de la solución en entornos clínicos reales.

La combinación de estas características, junto con su rendimiento superior en las pruebas comparativas realizadas, consolidó la elección de LLaMA 3.2 8B Instruct como el modelo base más adecuado para el desarrollo de la solución propuesta en este trabajo.

3.2. Hipótesis de trabajo

Como se ha mencionado previamente, los informes de alta hospitalaria en el ámbito de la cardiología plantea una serie de retos relacionados con la preservación del significado clínico, la adecuación del lenguaje al destinatario y la interpretación correcta de conceptos especializados. Para abordar esta problemática, se proponen tres hipótesis principales que fundamentan la estrategia metodológica planteada en este trabajo.

En primer lugar, se considera que la estructura seccional de los informes clínicos puede aprovecharse para mejorar la calidad de la simplificación. En lugar de tratar el informe como un bloque textual único, se plantea que su división en secciones temáti-

cas, junto con el uso de instrucciones adaptadas a cada una, permite guiar al modelo de lenguaje hacia una producción más precisa y coherente.

En segundo lugar, se formula la hipótesis de que el tratamiento adecuado de abreviaciones médicas —frecuentes en el lenguaje clínico profesional— es clave para mejorar la comprensión de los textos simplificados. La presencia de siglas y acrónimos no explicados es una de las causas principales de malinterpretaciones por parte de pacientes o personal no médico. La interpretación contextual y semántica de estas abreviaciones es una capacidad que los modelos de lenguaje podrían abordar de forma más eficaz que los métodos tradicionales basados en patrones o listas fijas.

Por último, se contempla que el uso de un modelo de lenguaje especializado, ya sea entrenado con datos clínicos o adaptado al español médico, puede contribuir significativamente a la calidad de las simplificaciones, al ofrecer una mayor sensibilidad terminológica, gramatical y estilística para el dominio.

3.2.1. Hipótesis 1: La división por secciones mejora la calidad de la simplificación

La primera hipótesis que sustenta esta propuesta es la siguiente:

La división del informe de alta en secciones y el tratamiento individualizado de cada una mediante prompts específicos mejora la calidad de la simplificación generada por el modelo de lenguaje.

Esta hipótesis se basa en la premisa de que los informes clínicos siguen una estructura modular, en la que cada sección responde a una función comunicativa concreta dentro del conjunto del documento. Por ejemplo, el “Motivo de ingreso” introduce el episodio clínico que justifica la hospitalización, mientras que la “Evolución clínica” describe cronológicamente los eventos médicos durante la estancia hospitalaria respondiendo de esta forma tanto a convenciones institucionales como a la necesidad de comunicar con precisión diferentes dimensiones del proceso asistencial.

En este contexto, se plantea que un enfoque monolítico —en el que todo el informe es tratado como una única entrada textual para el modelo— puede diluir el contexto específico de cada sección, dificultando la generación de simplificaciones que mantengan tanto la fidelidad semántica como la claridad expositiva. En cambio, al dividir el informe en sus secciones constituyentes y formular *prompts* diseñados específicamente para cada una de ellas, se facilita que el modelo identifique con mayor precisión el

tipo de información contenida, su función comunicativa y el nivel de detalle necesario para su reformulación [9][50].

El razonamiento que sustenta esta hipótesis se apoya en principios de procesamiento del lenguaje natural y comprensión textual, según los cuales la segmentación temática y el contexto dirigido permiten una interpretación más precisa del contenido. En este caso, cada sección se convierte en una unidad autónoma, con un enfoque específico en cuanto a qué aspectos deben mantenerse, simplificarse o explicarse. Por ejemplo, un *prompt* asociado a la sección de “Pruebas complementarias” puede solicitar al modelo que reformule los resultados de forma comprensible, explicando brevemente los términos técnicos utilizados; mientras que otro *prompt* asociado a la “Plan de Actuación” puede enfatizar la importancia del cumplimiento terapéutico o de los signos de alarma.

Como expectativa derivada de esta hipótesis, se prevé que el tratamiento seccional contribuya a mejorar la fidelidad semántica del texto simplificado (es decir, que preserve correctamente la información médica esencial), la claridad del lenguaje (evitando tecnicismos innecesarios o confusos) y la coherencia contextual dentro de cada segmento del informe. A su vez, esta estrategia también puede facilitar el desarrollo de futuras adaptaciones del sistema a distintos perfiles de usuario, como pacientes, cuidadores o personal sanitario no especializado.

3.2.2. Hipótesis 2: El manejo correcto de abreviaciones médicas mejora la comprensión

La segunda hipótesis que fundamenta esta propuesta es la siguiente:

El tratamiento adecuado de las abreviaciones médicas, mediante su detección y expansión contextualizada, mejora significativamente la comprensión de los informes clínicos simplificados generados por modelos de lenguaje.

Esta hipótesis parte del reconocimiento de que los informes médicos, y en particular los informes de alta hospitalaria, hacen un uso intensivo de abreviaciones, siglas y acrónimos como medio de condensación terminológica. Estas formas abreviadas, aunque eficaces para la comunicación entre profesionales sanitarios, suponen una barrera considerable para personas no especializadas, dificultando la interpretación del contenido clínico. La presencia de abreviaciones mal interpretadas, no desarrolladas o empleadas fuera de contexto es una fuente habitual de malentendidos, lo que puede comprometer la utilidad del informe simplificado.

En este sentido, se plantea que un sistema de simplificación que no contemple un tratamiento específico de estas unidades lingüísticas corre el riesgo de generar salidas que mantengan la forma abreviada —y por tanto opaca— o, peor aún, que propongan una expansión incorrecta basada en una interpretación errónea del contexto clínico. Esto último no solo afecta a la claridad del texto, sino que puede introducir ambigüedad o información médica inexacta.

Frente a esta problemática, se defiende que la incorporación de un mecanismo explícito para la gestión de abreviaciones —ya sea mediante detección automatizada, recursos terminológicos, o un componente previo al proceso de simplificación— permite que el modelo LLM genere textos más comprensibles, informativos y seguros para el usuario final. A diferencia de enfoques más rígidos como las expresiones regulares, los modelos de lenguaje son capaces de interpretar abreviaciones con mayor flexibilidad, considerando el contexto semántico y el entorno gramatical en que aparecen. Esta capacidad ha sido destacada en estudios recientes sobre simplificación en dominios especializados, donde se ha observado que la pérdida de información se asocia frecuentemente a la presencia de siglas no resueltas o mal entendidas [50].




Figura 3.1: Comparación del proceso de expansión de abreviaciones

El ejemplo de la Figura 3.1 muestra cómo la ampliación de siglas facilita una interpretación correcta y completa del contenido médico por parte del paciente o de un lector no especializado. Sin este paso, el texto correría el riesgo de resultar inacce-

sible o ambiguo, especialmente si la persona lectora desconoce el significado de las abreviaciones empleadas.

El razonamiento que sustenta esta hipótesis se basa en fundamentos del procesamiento del lenguaje especializado, que destacan la importancia de la desambiguación y expansión de abreviaciones como condición previa para una comunicación efectiva. Así, se entiende que una simplificación útil no puede limitarse a reducir complejidad sintáctica o sustituir tecnicismos, sino que debe también hacer explícita la información que normalmente queda implícita en el lenguaje técnico-profesional. Por ejemplo, un acrónimo como “IAM” (infarto agudo de miocardio) debe ser interpretado y expandido correctamente en función de su aparición en secciones como “Diagnóstico principal” o “Evolución clínica”, ya que su relevancia puede variar según el contexto.

Como expectativa asociada a esta hipótesis, se anticipa que un tratamiento activo de las abreviaciones contribuirá a mejorar la legibilidad del texto simplificado, así como su precisión y utilidad para personas sin formación médica. Esta estrategia también abre la puerta a futuras extensiones del sistema, como la adaptación a otros lenguajes clínicos o la incorporación de glosarios personalizados según el perfil del usuario.

3.2.3. Hipótesis 3: La explicación del tratamiento incrementa la accesibilidad del informe

La tercera hipótesis que fundamenta esta propuesta es la siguiente:

La inclusión de explicaciones claras sobre la función y el modo de administración del tratamiento farmacológico mejora la accesibilidad y utilidad del informe clínico simplificado para el paciente.

Esta hipótesis se apoya en la consideración de que el apartado de tratamiento —habitualmente situado en secciones como “Plan terapéutico” o “Prescripción al alta”— constituye una de las partes más directamente relevantes para la persona receptora del informe. A diferencia de otras secciones de carácter más técnico o retrospectivo, el tratamiento contiene información orientada a la acción: pautas que el paciente debe seguir para continuar su cuidado, instrucciones de administración de fármacos, posibles combinaciones o advertencias relevantes para su seguridad y salud.

En la práctica clínica, sin embargo, esta sección suele adoptar un formato sumamente condensado, repleto de nombres comerciales o genéricos, dosis expresadas mediante códigos numéricos (como “1-0-1”) y sin información explícita sobre la finalidad del medicamento. Esta codificación, aunque eficaz para personal sanitario, puede

resultar completamente opaca para personas sin formación médica, especialmente en contextos de pluripatología, polimedicación o niveles bajos de alfabetización sanitaria. Esta situación compromete la comprensión del informe y, en última instancia, la adherencia terapéutica.

Desde esta perspectiva, se defiende que un proceso de simplificación verdaderamente centrado en el usuario debe incluir una reformulación ampliada de la sección de tratamiento, en la que cada fármaco sea presentado con una breve explicación de su función, su posología y, si procede, advertencias relevantes. Este tipo de transformación no debe considerarse como una mera traducción lingüística, sino como una reinterpretación guiada por principios de comunicación sanitaria centrada en el paciente.




Figura 3.2: Ejemplo de simplificación funcional de prescripciones médicas

La transformación de la Figura 3.2 convierte una información técnica y esquemática en un mensaje comprensible, útil y directamente accionable por parte del paciente, lo que puede facilitar el cumplimiento terapéutico, reducir errores de administración y mejorar la percepción general del informe como herramienta de apoyo al autocuidado.

El razonamiento que respalda esta hipótesis se fundamenta en estudios de comunicación médico-paciente y diseño de materiales informativos, los cuales señalan que

el acceso comprensible a la información terapéutica no solo mejora la experiencia del paciente, sino que puede influir positivamente en indicadores clínicos [51][52]. La explicabilidad del tratamiento, en este sentido, no debe considerarse un lujo o añadido opcional, sino un componente fundamental de la accesibilidad textual.

Como expectativa derivada de esta hipótesis, se plantea que los modelos de lenguaje que incluyen estrategias de expansión explicativa para el tratamiento generarán informes más accesibles, especialmente para personas mayores, pacientes crónicos o personas con niveles bajos de alfabetización sanitaria. Además, esta estrategia también puede abrir la puerta a futuras adaptaciones centradas en farmacovigilancia, recordatorios personalizados o integración con sistemas de prescripción electrónica.

3.3. Arquitectura general del sistema

Finalmente, la arquitectura general del sistema propuesto se basa en una cadena de procesamiento modular, diseñada para transformar informes clínicos originales en versiones simplificadas y comprensibles para usuarios no expertos. Cada módulo aborda una transformación específica sobre el texto original, con el objetivo de facilitar la comprensión manteniendo la fidelidad informativa.

3.3.1. Entrada y preprocesamiento

El módulo de entrada y preprocesamiento se encarga de transformar los informes clínicos en bruto, generalmente obtenidos a partir de documentos PDF, en un formato textual depurado y estructurado, adecuado para su posterior análisis. Estos informes suelen contener irregularidades y artefactos derivados del proceso de digitalización, como saltos de línea innecesarios, caracteres no interpretables, encabezados repetitivos o firmas automatizadas.

La primera fase del módulo se centra en la limpieza del texto. Esto implica la eliminación de elementos que no aportan valor clínico o que pueden interferir en el procesamiento, como enlaces, marcas administrativas y rúbricas automáticas. Asimismo, se normaliza la estructura del texto, homogeneizando la puntuación, los espacios y otros signos de formato.

Posteriormente, el sistema divide el texto resultante en distintas secciones lógicas con el fin de identificar bloques semánticos diferenciados que respondan a distintas funciones informativas dentro del informe médico. La lógica de esta división se basa

en patrones textuales recurrentes que permiten detectar puntos de corte coherentes, pero no supone una interpretación del contenido.

Las secciones extraídas no se detallan en esta parte, ya que serán descritas y ejemplificadas en profundidad en la sección de experimentación. El objetivo general de este módulo es, por tanto, establecer una base limpia y estructurada sobre la cual puedan operar con precisión los siguientes módulos del sistema.

3.3.2. Módulo de tratamiento de abreviaciones

El módulo de tratamiento de abreviaciones tiene como objetivo identificar y comprender abreviaciones médicas presentes en los informes clínicos, con el fin de facilitar su posterior procesamiento durante la simplificación del texto. Muchas de estas abreviaciones, aunque habituales en el lenguaje profesional sanitario, pueden dificultar la comprensión para personas sin formación médica.

Para abordar este problema, el sistema recurre al diccionario oficial de abreviaciones de la Sociedad Española de Documentación Médica (**SEDOM**)², que proporciona una base fiable y estandarizada para asociar cada abreviación con su significado correspondiente (véase Figura 3.3). Esta asociación se realiza teniendo en cuenta tanto el término abreviado como su contexto inmediato dentro del informe.

Una vez detectadas y contextualizadas, las abreviaciones se vinculan a su significado, que se proporciona como entrada auxiliar al sistema generador del informe simplificado. Esto permite que el módulo de generación tenga acceso al contenido semántico completo, incluso cuando en el texto original aparecían únicamente formas abreviadas. De esta forma, se garantiza que la presencia de abreviaciones no impida la elaboración de un borrador más claro y accesible, sin necesidad de introducir ambigüedades o suposiciones en la salida generada.

3.3.3. Módulo de tratamiento de medicamentos

Este módulo se encarga de analizar y reformular la información farmacológica contenida en los informes de alta, con el objetivo de facilitar su comprensión por parte del paciente. Para ello, se proponen tres funciones principales: la identificación de medicamentos y principios activos, la obtención de información terapéutica oficial y la generación de explicaciones en lenguaje claro.

²<http://diccionario.sedom.es/>




Figura 3.3: Captura de pantalla del Diccionario de Siglas Médicas de la Sociedad Española de Documentación Médica (SEDOM). Fuente: <http://diccionario.sedom.es/>

En primer lugar, el sistema debe ser capaz de reconocer tanto nombres comerciales como principios activos presentes en el texto del informe. Esta tarea de identificación permitirá enlazar cada mención farmacológica con su forma genérica, reduciendo la ambigüedad y facilitando su posterior procesamiento. Se contempla la utilización de un diccionario farmacológico basado en las fuentes oficiales disponibles en la Agencia Española de Medicamentos y Productos Sanitarios (**AEMPS**)³ (véase Figura 3.4)..

Una vez identificado el principio activo, se plantea la consulta de una base de datos derivada de la AEMPS para obtener su uso terapéutico habitual. Esta base de datos contendrá descripciones breves y estandarizadas sobre indicaciones, vía de administración y posibles advertencias relevantes. Este paso es clave para garantizar que la información proporcionada sea precisa y clínicamente válida.

Finalmente, el módulo generará una reformulación accesible de cada medicamento, expresada en lenguaje claro y orientada al paciente. Estas explicaciones incluirán, de forma resumida, para qué sirve el medicamento, cómo debe tomarse y qué precauciones básicas deben tenerse en cuenta. La redacción será realizada por un modelo de lenguaje previamente ajustado para tareas de simplificación médica.

³<https://www.aemps.gob.es/>



Figura 3.4: Captura de la sección sobre farmacovigilancia en la web de la AEMPS.
Fuente: <https://www.aemps.gob.es/>

3.3.4. Flujo de simplificación

El flujo de simplificación culmina en la intervención de un LLM, encargado de generar una versión simplificada del informe clínico original (véase la Figura 3.5). Este modelo opera directamente sobre el texto procesado y estructurado, y hace uso de los módulos previos de tratamiento de abreviaciones y de medicamentos para guiar su generación.

El módulo de abreviaciones permite identificar y expandir formas reducida de información en función de su contexto, mientras que el módulo farmacológico proporciona información sobre la función, posología y advertencias de los medicamentos mencionados. Estos recursos se integran como apoyo semántico al proceso de generación, permitiendo que el modelo produzca una salida más clara, precisa y comprensible para personas sin formación médica.




Figura 3.5: Esquema general del sistema de simplificación de informes clínicos. El flujo parte de la izquierda con la entrada de un informe clínico en formato PDF, que pasa por un módulo de preprocesamiento, encargado de limpiar y dividir el texto en secciones. El contenido se dirige al centro del sistema, donde un modelo de lenguaje simplifica cada sección individual. Este modelo está asistido por dos módulos especializados: el de tratamiento de abreviaciones, que consulta el diccionario oficial de la SEDOM, y el de tratamiento de medicamentos, que accede a información terapéutica de la AEMPS. Finalmente, a la derecha, el sistema produce una salida simplificada y comprensible para pacientes, con énfasis en claridad y accesibilidad. Fuente: elaboración propia.

Capítulo 4

Diseño experimental


4.1. Descripción del corpus

4.1.1. Origen de los informes

El corpus utilizado en este trabajo está compuesto por un total de 307 informes de alta hospitalaria, procedentes exclusivamente del servicio de Cardiología del Hospital [REDACTED]. Todos los informes corresponden a pacientes que ingresaron en dicho servicio por diversas patologías relacionadas con el ámbito y fueron dados de alta tras su hospitalización.

Los documentos fueron proporcionados con fines de investigación bajo un marco de colaboración institucional entre el grupo de investigación de [REDACTED] y el propio hospital. Previamente a su cesión, los informes fueron anonimizados por personal del hospital siguiendo los protocolos establecidos de protección de datos.

Este conjunto de datos, al estar centrado en la especialidad de cardiología, presenta una coherencia temática y terminológica que reduce significativamente la variabilidad lingüística habitual en entornos clínicos más generales. Esta especialización permite el desarrollo de sistemas más enfocados y, por tanto, más controlables y evaluables, lo que favorece una experimentación más precisa y la obtención de resultados más robustos en tareas de simplificación textual.



INFORME DE ALTA DE HOSPITALIZACION

Motivo de ingreso

Disnea

Antecedentes

Personales:

Sin alergias medicamentosas conocidas.
HTA. DM. Dislipemia. FA permanente.
Ingreso en [redacted] en Cardiología por taquimiopatia (FA RVR) con DVI severa (30%) con recuperación parcial en seguimiento en consultas, persistiendo la asincronia por BRIHH, y disfunción leve.
Criterios clínicos de broncopatía crónica. No evaluado por Neumología.
Semidependiente para las ABVD.

Tratamiento: Apixaban 5 mg/12h. Bisoprolol 5 mg/24h, Espironolactona 25mg/24h. Furosemida (1-0-0). Olmesartan/Amlodipino/HCT 40/10/12.5mg un comprimido cada 24h. Metformina/Empaglifozina 1/5mg, Atorvastatina/Ezetimiba 40/10mg, Alopurinol 100mg. Nexium, Acetilcisteína. Spiriva.

Enfermedad Actual

Anamnesis:

Paciente de [redacted] años que acude a Urgencias por disnea, astenia y síntomas de insuficiencia cardíaca progresiva desde hace al menos 1-2 meses. Edematización de MMII solo en los últimos días. Niega palpitaciones, niega síncope. Niega dolor torácico.
Última toma de Bisoprolol hace 24h.

Exploración:

TA 114/61 mmHg, Fc 45 lpm, Tª 37.8°C. SatO2 3 l, a 97%. Diuresis 1800 ml desde ayer por la tarde REG, disneico en reposo, trabajo respiratorio abdominal. Palidez cutánea.
Rítmico, a 40 lpm, no ausculto soplos. MV abolido hasta campos medio derechos, crepitantes generalizados en resto de campos.

Figura 4.1: Primera página de un informe de alta hospitalaria cedido por el Hospital [redacted], utilizado con fines de investigación en el procesamiento del lenguaje clínico. Todos los datos han sido anonimizados para preservar la confidencialidad del paciente por parte del hospital.

4.1.2. Características del corpus

4.1.2.1. Formato y estructura

Los informes se encuentran en formato PDF y presentan una estructura clínico-documental típica, segmentada en un máximo de diez secciones predefinidas. A continuación, se describe el contenido habitual de cada una de ellas:

- **Motivo de ingreso:** Resume de forma concisa el síntoma o situación clínica que motivó la hospitalización del paciente (por ejemplo, dolor torácico, síncope o disnea). Suele ser breve, directa y con lenguaje médico específico.

- **Antecedentes:** Describe antecedentes personales y familiares relevantes, incluyendo patologías previas (ej. hipertensión arterial, diabetes, dislipemia), intervenciones quirúrgicas o hábitos nocivos. Contiene muchas abreviaciones clínicas.

- **Enfermedad Actual:** Expone la evolución reciente de los síntomas que llevaron al ingreso, con una narrativa más desarrollada y temporal (por ejemplo, “dolor opresivo de 3 horas de evolución que cede con nitroglicerina”). Suele contener tecnicismos cardiovasculares.

- **Evolución y Curso Clínico:** Describe de forma secuencial la evolución del paciente durante su estancia hospitalaria: pruebas realizadas, cambios de tratamiento, respuesta clínica. Es una de las secciones más largas y complejas del informe.

- **Pruebas Complementarias:** Incluye los resultados de análisis de sangre, ECG, radiografías, ecocardiogramas, cateterismos, etc. Contiene lenguaje técnico, abreviaciones y cifras. A menudo se presenta en formato casi telegráfico.

- **Intervenciones / Procedimientos quirúrgicos:** Describe procedimientos realizados durante la hospitalización (por ejemplo, implantación de stents, ablaciones o marcapasos). Es específica y a menudo escueta, pero con alta densidad técnica.

- **Juicio Clínico:** Resume la conclusión diagnóstica final y su relación con los síntomas del paciente. Suele estar formulado con expresiones médicas muy condensadas.

- **Tratamiento:** Detalla el tratamiento prescrito al alta: medicamentos, dosis, pautas horarias. A menudo aparecen nombres comerciales, principios activos y sistemas de notación abreviada (por ejemplo, 1-0-1 o 0-1-0).

- **Plan de Actuación:** Indica los pasos siguientes tras el alta: consultas de seguimiento, pruebas pendientes, cuidados domiciliarios. Es importante para el paciente, pero también para otros profesionales que continúan el proceso asistencial.

- **Revisiones:** Informa de las citas de revisión ya programadas o sugeridas. Su contenido puede ser técnico o simplemente administrativo.

Estas secciones pueden no estar presentes en todos los informes, pero constituyen la estructura de referencia sobre la que se ha organizado el análisis del corpus.

4.1.2.2. Estadísticas Estructurales

Respecto al análisis estructural del corpus médico, se han extraído principalmente dos gráficas que permiten caracterizar la distribución y composición de las secciones que conforman los informes de alta hospitalaria. Estas visualizaciones revelan patrones característicos en la estructura interna de la documentación médica analizada.




Figura 4.2: Distribución de longitud de secciones - Explica que es un diagrama de cajas con escala logarítmica mostrando mediana, cuartiles y valores atípicos.

La Figura 4.2 muestra la distribución de tokens por sección en el corpus médico. El análisis revela que la sección de motivo de ingreso presenta la menor extensión, con valores consistentemente inferiores a 10 tokens y una mediana aproximada de 5 palabras. Esta brevedad refleja la naturaleza concisa con la que se documenta la causa principal del ingreso hospitalario, donde los médicos tienden a utilizar terminología específica y directa.

En el extremo opuesto, la sección de pruebas complementarias muestra la mayor extensión promedio, lo cual es coherente con la necesidad de documentar exhaustivamente los resultados de múltiples estudios diagnósticos, incluyendo valores numéri-

cos, rangos de referencia y descripciones técnicas detalladas. Las secciones de plan de actuación, revisiones y juicio clínico mantienen extensiones intermedias, reflejando el equilibrio entre la necesidad de precisión clínica y la síntesis diagnóstica.

Un aspecto particularmente relevante es la presencia de valores extremadamente bajos (incluso un solo token) en secciones como evolución y tratamiento. Este fenómeno se debe a la práctica clínica de incluir formalmente todas las secciones estructurales del informe, pero completándolas únicamente con signos de puntuación (como puntos) cuando no hay información específica que reportar. Esto explica también la presencia de bigotes largos en el diagrama de cajas, donde los valores atípicos superiores corresponden a casos con descripciones particularmente detalladas.




Figura 4.3: recuena de aparición de secciones - Describe el gráfico de barras con frecuencias normalizadas y su relevancia para identificar secciones obligatorias vs. opcionales.

La Figura 4.3 presenta el patrón de frecuencias que revela la estructura jerárquica de importancia en la documentación médica. Las secciones enfermedad actual, antecedentes y pruebas complementarias aparecen de manera prácticamente universal (cerca de 307 informes), confirmando su carácter obligatorio en la documentación hospitalaria. El juicio clínico y el tratamiento mantienen también frecuencias elevadas, seguidos por evolución y plan de actuación.

La notable excepción es intervención quirúrgica/procedimiento, que aparece únicamente en 42 informes de los 307 analizados. Esta baja frecuencia refleja la realidad asistencial donde no todos los pacientes requieren intervenciones quirúrgicas, siendo muchos casos tratados mediante manejo médico conservador.




Figura 4.4: Matriz de coocurrencias - Caracteriza el mapa de calor de términos clínicos y su relación con protocolos diagnósticos.

La Figura 4.4 muestra la matriz de coocurrencias que revela patrones de asociación clínica significativos. Las altas frecuencias de coocurrencia entre términos como ECG-estenosis y HTA-ECG reflejan protocolos diagnósticos estándar donde ciertos estudios se realizan sistemáticamente ante determinadas condiciones clínicas. Por ejemplo, la electrocardiografía es un estudio de rutina en pacientes con hipertensión arterial o sospecha de patología cardiovascular, explicando estas asociaciones frecuentes.

4.1.2.3. Análisis Léxico

Para contextualizar el grado de especialización léxica del corpus médico, se ha realizado una comparación con el corpus de noticias MLSUM, que representa un dominio de texto de propósito general dirigido al público no especializado. Esta comparación permite cuantificar objetivamente el nivel de vocabulario técnico presente en la documentación médica frente a textos de divulgación general.




Figura 4.5: Comparación de vocabulario - Explica la comparación léxica entre ambos corpus (MLSM e informes de alta cardiológicos) y su significado en términos de especialización terminológica

La Figura 4.5 presenta la comparación entre el corpus médico (41.3%) y el corpus de noticias (73.9%) en términos de vocabulario común, revelando una diferencia sustancial de 32.6 puntos porcentuales. Esta disparidad se explica por varias razones fundamentales:

Especialización terminológica: El corpus médico contiene un alto porcentaje de terminología técnica específica del dominio sanitario que no forma parte del vocabulario común del español. Términos como “fibrilación auricular”, “angioplastia”, “ecocardiograma” o “estenosis mitral” son ejemplos de vocabulario altamente especializado que raramente aparece en el uso cotidiano del idioma.

Registro formal vs. divulgativo: Mientras que las noticias están redactadas con un lenguaje accesible al público general, utilizando vocabulario común para facilitar la comprensión, los informes médicos emplean un registro técnico-científico que prioriza la precisión terminológica sobre la accesibilidad lingüística.

Función comunicativa diferente: Los informes médicos sirven como documentos de comunicación entre profesionales sanitarios, mientras que las noticias buscan informar a una audiencia heterogénea. Esta diferencia funcional determina las elecciones léxicas de cada tipo de texto.

Estandarización profesional: La medicina emplea nomenclaturas internacionales estandarizadas (como la CIE-10 o terminología anatómica internacional) que introducen términos técnicos específicos no presentes en el vocabulario general.

La distribución complementaria muestra que el corpus médico contiene un 58.7 % de vocabulario especializado frente al 26.1 % del corpus de noticias, confirmando la naturaleza altamente técnica de la documentación médica. Esta diferencia no representa una limitación, sino una característica inherente y necesaria de la comunicación científica en el ámbito sanitario, donde la precisión terminológica es crucial para la seguridad del paciente y la efectividad de la comunicación interprofesional.

Otras estadísticas como pueden ser las nubes de palabras por sección o un análisis léxico de sílabas, palabras y frases al igual que la diversidad léxica se puede ver en el [Apéndice A](#).

4.2. Simplificación general vs. por secciones (Hipótesis 1)

4.2.1. Enfoque 1: Simplificación global del informe

En el primer enfoque, denominado *simplificación global*, se presenta al modelo el informe clínico completo como un único bloque textual. Es decir, se proporciona la totalidad del texto original de manera conjunta, sin segmentar ni diferenciar internamente sus distintas secciones o apartados. Para ello, se construye un *prompt* general que orienta al modelo hacia la tarea específica de producir una versión simplificada del texto íntegro. Esta versión está especialmente pensada para pacientes de edad avanzada o para personas con un nivel limitado de comprensión médica.

El *prompt* general incluye directrices explícitas sobre diversos aspectos fundamentales: la necesidad de emplear un lenguaje claro y accesible, la eliminación de terminología técnica y jerga médica innecesaria, la preservación de la información clínica esencial y, al mismo tiempo, la reformulación cuidadosa de términos especializados para asegurar la comprensión sin perder precisión. En particular, se presta atención a aquellos conceptos relacionados con patologías cardiovasculares, dada la naturaleza del informe.

Este procedimiento representa la forma más directa y básica de aplicar modelos generativos a tareas de reescritura textual: se ofrece un texto largo con una instrucción global sobre el tipo de transformación que se desea, sin segmentación ni especialización. Aunque sencillo, este enfoque permite evaluar la capacidad general del modelo para realizar simplificaciones en un contexto complejo.

La Figura 4.6 muestra un ejemplo del *prompt* utilizado para la simplificación automática de informes de alta de cardiología. En el Apéndice B se presentan el *prompt* detallado y explicado, además de los siguientes *prompts* definidos en este trabajo.

Eres un experto en simplificación de informes de alta de cardiología, dirigido principalmente a personas mayores con niveles de comprensión médica limitados. Tu tarea es simplificar el siguiente informe de alta para que sea fácilmente comprensible, sin perder la precisión del contenido médico. Por favor, proporciona una respuesta clara y concisa, eliminando cualquier complejidad o jerga innecesaria. Además, explica cada término médico clave, en especial los relacionados con cardiología. Es importante que tu respuesta sea comprensible, y que permita varias versiones simplificadas relevantes y creativas, siempre y cuando el significado original se mantenga fiel. El informe de alta incluye los siguientes apartados: {Apartados} La simplificación tiene que incluir únicamente estos campos sin ninguna información adicional y sin ningún campo más. Por favor, simplifica este informe de alta y proporciona la versión simplificada:

Figura 4.6: *Prompt* utilizado para la simplificación automática de informes de alta de cardiología

4.2.2. Enfoque 2: Simplificación por secciones con *prompts* especializados

En contraste con el enfoque global descrito anteriormente, el segundo enfoque experimental propone una segmentación explícita y sistemática del informe clínico. En este caso, el documento se divide en sus secciones constitutivas y cada una de estas secciones se trata como una unidad textual autónoma.

Para cada unidad o sección, se diseña un *prompt* específico que se adapta a las particularidades lingüísticas, discursivas y pragmáticas propias de dicha sección del informe. Esta especialización implica que la instrucción al modelo no es uniforme, sino que varía en función del tipo de contenido y la función comunicativa que la sección desempeña dentro del informe médico.

Los *prompts* especializados mantienen una estructura base común con el *prompt* general, pero añaden instrucciones detalladas que controlan el tono discursivo (por ejemplo, uso de la tercera persona, lenguaje formal y respetuoso), la indicación explícita de cuándo y cómo incluir la explicación entre paréntesis de términos técnicos, y recomendaciones sobre la extensión máxima o el nivel de detalle de la respuesta. En ciertos casos, también se incluyen pautas específicas para reformular eventos clínicos relevantes, con el objetivo de favorecer la comprensión por parte del paciente.

En el **Apéndice B** se presentan los distintos *prompts* diseñados para cada sección, junto con una tabla que indica qué elementos retóricos o instructivos se activan en cada caso, proporcionando así una visión completa de la lógica instruccional empleada.

4.2.3. Consideraciones generales de diseño

Ambas estrategias se han implementado utilizando el mismo modelo de lenguaje como ya se explicó anteriormente, a fin de eliminar el posible sesgo asociado a diferencias arquitectónicas o de entrenamiento. Asimismo, se ha mantenido constante el conjunto de informes de entrada y se ha asegurado que los textos estén correctamente estructurados y normalizados antes del procesamiento. La única diferencia sustancial entre las condiciones reside, por tanto, en la forma en que se estructura la entrada al modelo y en el tipo de guía proporcionada mediante los *prompts*.

En el caso del enfoque seccional, el diseño de los *prompts* específicos no se limita a fragmentar el contenido por partes, sino que se fundamenta en una arquitectura instruccional cuidadosamente planificada. Esta arquitectura se articula en torno a trece elementos clave —que se detallan en el **Apéndice B** y que orientan al modelo en diferentes dimensiones: el rol que debe asumir, el destinatario de la simplificación, el nivel de tecnicismo permitido, el formato narrativo, el tratamiento de términos médicos, o la adecuación estilística y comunicativa del resultado final.

A continuación se describen, de forma resumida, los principios que rigen la construcción de estos *prompts*:

1. **Rol asignado:** Se indica explícitamente que el modelo debe asumir la función de un experto en simplificación de informes clínicos del ámbito de la cardiología.
2. **Perfil del destinatario:** Se define con precisión que el público objetivo está formado por personas mayores con escasa formación médica.
3. **Tarea concreta:** Cada *prompt* especifica que la sección que se presenta ha de ser simplificada, no resumida, manteniendo la integridad semántica del contenido.

4. **Preservación de la precisión médica:** Se establece que, si bien el texto debe ser comprensible, no debe alterar ni reducir la precisión de la información médica contenida.
5. **Concisión y claridad:** Se solicita que la respuesta sea directa, sin redundancias ni explicaciones innecesarias, priorizando frases cortas y comprensibles.
6. **Eliminación de tecnicismos innecesarios:** Se pide evitar el uso de jerga médica, a menos que sea estrictamente necesario para la fidelidad del mensaje.
7. **Equilibrio explicativo:** Se señala que las explicaciones no deben ser excesivas ni demasiado técnicas, buscando un punto medio entre claridad y brevedad.
8. **Estilo formal, en tercera persona:** Se requiere que la respuesta adopte un tono respetuoso, sin expresiones coloquiales ni dirigidas directamente al paciente.
9. **Mantenimiento del término médico entre paréntesis:** Se solicita que, cuando se simplifica un término técnico, se indique entre paréntesis la denominación original.
10. **Relevancia y creatividad controlada:** Se permite una cierta flexibilidad creativa en la reexpresión, siempre que el significado se mantenga fiel.
11. **Fidelidad semántica como criterio principal:** Se recuerda que cualquier cambio debe preservar el significado clínico del texto original.
12. **Visibilidad directa del resultado para el paciente:** Se asume que la versión generada será leída tal cual por el paciente, lo que refuerza la necesidad de claridad, adecuación y tono apropiado.
13. **Enunciado de la tarea al final del *prompt*:** Se formula explícitamente, como cierre del *prompt*, la instrucción operativa de simplificar la sección en cuestión y generar la versión transformada.

Este conjunto de pautas proporciona un marco homogéneo para el diseño de los *prompts*, al tiempo que permite introducir matices específicos para cada sección del informe. Por ejemplo, en secciones como *Motivo de ingreso* o *Antecedentes personales*, se refuerza la claridad causal o cronológica, mientras que en *Pruebas complementarias* o *Tratamiento* se subraya la necesidad de explicar términos técnicos o indicar funciones terapéuticas.

4.3. Tratamiento de abreviaciones (Hipótesis 2)

4.3.1. Detección de abreviaciones

El primer paso en el tratamiento de abreviaciones dentro del proceso de simplificación de informes clínicos consiste en su detección. Para ello, se han aplicado dos enfoques complementarios: uno basado en expresiones regulares y otro fundamentado en un modelo de lenguaje entrenado específicamente para esta tarea.

Expresión regular: Como primer mecanismo de identificación, se ha diseñado una expresión regular con el objetivo de localizar patrones que puedan corresponderse con abreviaciones. Concretamente, se emplea el siguiente patrón:

$$(?<![a-zA-Z0-9])([A-Z]{2})(?![a-zA-Z0-9])$$

Este patrón busca dos caracteres en mayúscula ($[A-Z]{2}$) que estén rodeados por caracteres no alfanuméricos ($[a-zA-Z0-9]$), lo que evita capturar palabras normales y permite identificar posibles siglas o abreviaciones clínicas, como HT, EC, o TA, típicas en informes médicos.

Cada instancia detectada se considera un *candidato a abreviación*. No obstante, para confirmar su validez como abreviación médica, cada uno de estos candidatos se contrasta con un diccionario de abreviaciones clínicas (descrita en la sección siguiente). Si el elemento detectado no se encuentra en dicho diccionario, se descarta como abreviación médica, eliminando así falsos positivos producidos por coincidencias fortuitas en la escritura del informe.

Modelo de lenguaje especializado: El segundo enfoque propuesto para la detección de abreviaciones se fundamenta en un modelo de lenguaje específicamente entrenado para esta tarea. Para ello, se ha desarrollado un corpus supervisado que contiene instancias de abreviaciones médicas presentes en informes reales.

El conjunto de datos se ha generado a partir del 70 % del corpus de informes clínicos cedido por el Hospital [REDACTED]. A este subconjunto se le ha aplicado un procedimiento automatizado de anotación mediante el modelo **GPT-4o**, al cual se le solicitó explícitamente que detectara todas las abreviaciones presentes en cada informe, devolviéndolas en forma de listado estructurado. El *prompt* utilizado para esta tarea se puede consultar en el [Apéndice B](#). El resultado ha sido un corpus anotado de abreviaciones clínicas reales, sobre el cual se ha procedido a entrenar un modelo de lenguaje de tamaño reducido.

El modelo base utilizado ha sido **LLaMA 3B 3.2 Instruct**, adaptado para tareas supervisadas mediante instrucciones. Se ha llevado a cabo un proceso de *fine-tuning*

EJEMPLO DE DETECCIÓN CORRECTA
Texto de entrada: "Control de FRCV por su médico."
Abreviaciones detectadas: FRCV



ERROR POR FORMATO DE TEXTO INADECUADO



EJEMPLO DE DETECCIÓN INCORRECTA
Texto de entrada: "CONTROL DE FRCV POR SU MEDICO."
Abreviaciones detectadas: DE, SU, FRCV

Análisis del error:

El uso de **mayúsculas sostenidas** interfiere con los criterios de detección:

- ✗ DE - Preposición identificada como abreviación
- ✗ SU - Pronombre identificado como abreviación
- ✓ FRCV - Abreviación correctamente detectada

Causa: La expresión regular utilizada ofrece una buena aproximación general, pero falla cuando todo el texto está en mayúsculas, perdiendo las pistas tipográficas distintivas.


Figura 4.7: Error en la detección automática de abreviaciones mediante expresiones regulares. La expresión regular utilizada proporciona una buena aproximación para la detección de abreviaciones, pero comete errores cuando el texto se encuentra completamente en mayúsculas, identificando erróneamente palabras comunes como «DE» y «SU» como posibles abreviaciones médicas.

sobre este modelo, utilizando el corpus generado como conjunto de entrenamiento. El objetivo ha sido dotar al modelo de la capacidad de detectar abreviaciones clínicas en textos reales con alta precisión, considerando no solo características formales (como el uso de mayúsculas), sino también el contexto léxico y semántico en el que estas aparecen.


El modelo resultante constituye un modelo de lenguaje pequeño (SLM, por sus siglas en inglés) especializado exclusivamente en la detección de abreviaciones médicas. Este modelo puede ser desplegado como componente autónomo en sistemas de preprocesamiento clínico o incorporado como etapa previa en flujos de simplificación lingüística. Aunque su evaluación se ha centrado en textos del ámbito de la cardiología, el modelo ha sido diseñado de forma generalista, por lo que su aplicación es extensible a cualquier especialidad médica.

Durante el proceso de entrenamiento se monitorizaron tanto la pérdida como la precisión del modelo, como se puede observar en las figuras 4.8a y 4.8b. Estas métricas evidencian la convergencia exitosa del modelo hacia la tarea específica de detección de abreviaciones médicas.

La configuración específica de hiperparámetros utilizada para el entrenamiento del modelo se detalla en la [Tabla 4.1](#).



(a) Evolución de la función de pérdida durante el entrenamiento



(b) Evolución de la precisión por token durante el entrenamiento

Figura 4.8: Métricas de entrenamiento del modelo LLaMA 3B 3.2 especializado en detección de abreviaciones

4.3.2. Búsqueda de posibles significados

Una vez detectadas las abreviaciones candidatas mediante alguno de los métodos anteriores, el siguiente paso consiste en la búsqueda y expansión de sus posibles significados. Para ello, se ha utilizado el diccionario de siglas del **SEDOM**, un recurso

Parámetro	Valor
Tamaño de lote por dispositivo (entrenamiento)	2
Tamaño de lote por dispositivo (evaluación)	1
Número de épocas de entrenamiento	3
Pasos entre evaluaciones	10
Estrategia de evaluación	Por pasos
Pasos entre guardados del modelo	500
Pasos de acumulación de gradiente	4
Tasa de aprendizaje	1×10^{-4}
Semilla aleatoria	42
Longitud máxima de secuencia	2048 tokens

Tabla. 4.1: Configuración detallada de hiperparámetros para el *fine-tuning* del modelo LLaMA 3.2-1B Instruct

léxico que contiene un total de 7.054 abreviaciones médicas en español, recopiladas a partir de diversas fuentes especializadas del ámbito clínico, académico y documental.

El diccionario se clasifica las abreviaciones médicas en distintas categorías:


- **Abreviaturas:** formas truncadas de palabras mediante suspensión o contracción, como a. c. para *antes de comida*.
- **Siglas:** construidas a partir de las letras iniciales de varias palabras, como EPOC para *enfermedad pulmonar obstructiva crónica*.
- **Acrónimos:** siglas lexicalizadas formadas por sílabas completas, como DIU para *dispositivo intrauterino*.
- **Símbolos:** signos convencionales en notación médica y científica, como mg, mmHg o cm.

El proceso de correspondencia entre una abreviación detectada y su significado se realiza mediante una búsqueda directa en este diccionario. En caso de encontrar una coincidencia, se considera válida y se incorpora como parte de la expansión del informe. En situaciones en las que una abreviación pueda tener múltiples significados posibles, se prevé un módulo posterior de desambiguación (ver Sección 4.3.3) encargado de seleccionar la interpretación más adecuada.

4.3.3. Contextualización en el informe clínico

Una de las principales limitaciones a la hora de realizar una desambiguación precisa de abreviaciones médicas es la ausencia de un corpus de referencia anotado

Búsqueda de siglas médicas



HTA

BUSCAR

Resultado de su búsqueda

HTA

1. Hipertensión arterial diastólica. [definición en Wikipedia](#)
2. Hipertensión arterial. [definición en Wikipedia](#)
3. Histerectomía total abdominal. [definición en Wikipedia](#)

Figura 4.9: Ejemplo de búsqueda de la abreviatura “HTA” (hipertensión arterial) en el diccionario de siglas médicas de la Sociedad Española de Documentación Médica (SEDOM). Fuente: <http://diccionario.sedom.es/>. Accedido el 18 de junio de 2025.

con los significados correctos de dichas abreviaciones en contexto. Es decir, no se dispone actualmente de un conjunto de datos en el que, para cada abreviación ambigua presente en un informe clínico, se indique explícitamente cuál es su interpretación correcta, junto con otras interpretaciones posibles. Esta carencia impide entrenar y evaluar de forma rigurosa modelos supervisados de desambiguación semántica.

Ante esta situación, se ha optado por delegar la tarea de selección del significado más probable en el propio modelo de lenguaje utilizado en el proceso de simplificación, en este caso, LLaMA 3.2 8B Instruct. La estrategia adoptada consiste en incorporar, dentro del *prompt* proporcionado al modelo, tanto la lista de abreviaciones presentes en el informe como sus posibles significados, extraídos del diccionario definido previamente. A continuación, se le solicita al modelo que, teniendo en cuenta el contenido completo del informe clínico, elija para cada abreviación aquella interpretación que resulte más coherente con el contexto.

Este mecanismo permite llevar a cabo una desambiguación semántica adaptativa, basada en la comprensión contextual del texto por parte del modelo. Aunque no se dispone de anotaciones de referencia con las que contrastar los resultados, esta aproximación permite resolver ambigüedades de forma razonada, aprovechando las

capacidades de inferencia del modelo de lenguaje sin necesidad de entrenamiento adicional específico para esta tarea.

4.4. Tratamiento de la medicación (Hipótesis 3)

4.4.1. Reconocimiento de medicamentos y principios activos

Para esta subtarea, se ha optado por un enfoque basado exclusivamente en modelos de lenguaje, descartando explícitamente el uso de expresiones regulares. Esta decisión metodológica se ha tomado en base a la naturaleza irregular con la que aparecen los nombres de medicamentos y principios activos en los informes reales. En muchos casos, los profesionales redactan estas entidades con errores ortográficos, abreviaciones informales o directamente con formas incorrectas. Este comportamiento introduce una alta variabilidad que dificulta significativamente la eficacia de patrones formales como las expresiones regulares, los cuales dependen de coincidencias exactas o estructuras textuales predecibles. A diferencia de otras entidades clínicas, como las variaciones, donde una mínima diferencia gráfica puede implicar un concepto clínico distinto, en el caso de los principios activos y medicamentos estos errores suelen ser accidentales y no semánticamente diferenciadores. Por tanto, se consideró que las expresiones regulares generarían un volumen excesivo de falsos negativos, comprometiendo la precisión del sistema.


Modelo de lenguaje especializado: En su lugar, se ha seguido un enfoque análogo al empleado en la detección de abreviaciones, utilizando un SLM entrenado específicamente para esta tarea. Para ello, se ha construido un corpus supervisado a partir de un subconjunto del 70 % del total de informes clínicos, manteniendo la misma división establecida previamente en la detección de abreviaciones. Este corpus ha sido anotado automáticamente mediante **GPT-4o**, al que se le ha solicitado identificar todas las menciones de medicamentos y principios activos presentes en cada documento. El proceso de anotación se llevó a cabo utilizando un *prompt* estructurado (descrito en el **Apéndice B**), y los datos resultantes se utilizaron como conjunto de entrenamiento para el modelo.

El modelo base seleccionado ha sido **LLaMA 3B 3.2 Instruct**, el cual se ha ajustado mediante *fine-tuning* con el objetivo de dotarlo de la capacidad para reconocer medicamentos y principios activos en textos clínicos redactados en lenguaje natural. Durante el entrenamiento se ha buscado que el modelo aprenda tanto los patrones léxicos como el contexto semántico en el que estas entidades suelen aparecer, permitiendo


así una detección robusta frente a errores ortográficos, variantes no estandarizadas o formas abreviadas.

El proceso de entrenamiento del modelo especializado se monitorizó a través de las métricas de pérdida y precisión por token, como se observa en las figuras 4.10a y 4.10b. Estas gráficas demuestran la convergencia exitosa del modelo hacia la tarea específica de reconocimiento de entidades farmacológicas.

La configuración específica de hiperparámetros utilizada para el entrenamiento del modelo se detalla en la Tabla 4.1. Es la misma que para la tarea anterior ya que utilizan el mismo modelo y también se trata de reconocimiento.



(a) Evolución de la función de pérdida durante el entrenamiento



(b) Evolución de la precisión por token durante el entrenamiento

Figura 4.10: Métricas de entrenamiento del modelo LLaMA 3B 3.2 especializado en detección de medicamentos y principios activos

4.4.2. Generación de explicaciones terapéuticas

Como parte del tratamiento de la medicación, y con el objetivo de proporcionar explicaciones accesibles y contextualizadas sobre los medicamentos identificados en los informes clínicos, se ha desarrollado un diccionario estructurado de usos terapéuticos. Este recurso constituye una herramienta fundamental para enriquecer los procesos de simplificación textual, permitiendo no solo identificar la presencia de un medicamento, sino también ofrecer una descripción de su finalidad terapéutica.

Origen de los datos: Para la construcción de este diccionario, se ha llevado a cabo una recolección sistemática de información a partir de la base de datos pública de la **AEMPS**, específicamente del Centro de Información online de Medicamentos de la AEMPS (**CIMA**)¹. Mediante técnicas de *web scraping*, se han recopilado un total de 14.611 medicamentos autorizados en España, accediendo tanto a sus prospectos oficiales como a sus fichas técnicas completas.

¹<https://cima.aemps.es/cima/publico/home.html>

Extracción de información terapéutica: Cada medicamento recopilado contiene dos fuentes principales de información: el prospecto dirigido a pacientes y la ficha técnica destinada a profesionales sanitarios. Una vez descargados y estructurados estos documentos, se seleccionaron secciones clave para la extracción del uso terapéutico:

- En el caso de los prospectos, se utilizó principalmente la **primera sección**, la cual suele describir en lenguaje accesible para el paciente qué es el medicamento y para qué se utiliza.
- Para las fichas técnicas, se empleó específicamente la **sección 4.1**, que corresponde a las “indicaciones terapéuticas” y presenta una descripción más formal y técnica del uso clínico autorizado del medicamento.

Procesamiento mediante LLM: Con el objetivo de extraer automáticamente el uso terapéutico de cada medicamento a partir de los textos recopilados, se utilizó un modelo de lenguaje de tamaño medio, concretamente **GPT-4o mini**, debido a su equilibrio entre coste computacional y capacidad de comprensión del lenguaje técnico y general.

A cada par de documentos se le aplicó un *prompt* que solicitaba al modelo extraer de manera concisa el uso terapéutico del medicamento, así como identificar el principio activo y el nombre comercial. El *prompt* utilizado puede consultarse en el **Apéndice B**. Este proceso se aplicó de forma iterativa a toda la colección de documentos, generando un corpus estructurado con la siguiente información por entrada:

- Nombre del medicamento (nombre comercial)
- Principio(s) activo(s)
- Uso terapéutico (explicado en una o dos frases)

Construcción del diccionario: Una vez procesada toda la información, se consolidó un **diccionario terapéutico**² que vincula cada medicamento y principio activo con su correspondiente explicación de uso clínico. Este diccionario constituye una fuente de conocimiento reutilizable dentro del sistema, utilizada en etapas posteriores del flujo de simplificación para enriquecer automáticamente los informes clínicos con explicaciones terapéuticas claras y comprensibles.

4.4.3. Búsqueda de la explicación terapéutica

Una vez identificadas las menciones a medicamentos o principios activos en los informes clínicos, el siguiente paso en el tratamiento de la medicación consiste en

²https://github.com/██████████DICCIONARIO_MEDICAMENTOS

FICHA TÉCNICA PARACETAMOL TECNIGEN 1 g COMPRIMIDOS EFG

1. NOMBRE DEL MEDICAMENTO

Paracetamol Tecnigen 1 g comprimidos EFG.

2. COMPOSICIÓN CUALITATIVA Y CUANTITATIVA

Cada comprimido contiene 1 g de paracetamol.

Para consultar la lista completa de excipientes, ver sección 6.1.

3. FORMA FARMACÉUTICA

Comprimido.

Los comprimidos son oblongos, de color blanco y ranurado por una de sus caras.

La ranura es sirve únicamente para fraccionar y facilitar la deglución pero no para dividir en dosis iguales.

4. DATOS CLÍNICOS**4.1. Indicaciones terapéuticas**

Tratamiento sintomático del dolor de cualquier etiología de intensidad moderada como dolores postoperatorios, dolores postparto, dolores reumáticos (artrosis o artritis reumatoide), lumbago, torticollis, ciáticas, neuralgias, dolores musculares, dismenorrea, cefaleas y odontalgias. Estados febriles.

Figura 4.11: Fragmento de la ficha técnica del medicamento *Paracetamol Tecnigen 1 g comprimidos EFG*, publicada por la AEMPS. Fuente: https://cima.aemps.es/cima/dochtml/ft/75994/FT_75994.html

1. Qué es Paracetamol TecniGen y para qué se utiliza

Paracetamol Tecnigen 1 g comprimidos pertenece al grupo de medicamentos llamados analgésicos y antipiréticos.

Paracetamol Tecnigen 1 g comprimidos está indicado para el tratamiento sintomático del dolor de cualquier causa de intensidad moderada, como por ejemplo: dolores postoperatorios y del postparto, dolores reumáticos (artrosis y artritis reumatoide), lumbago, torticollis, ciática, neuralgias, dolor de espalda, dolores musculares, dolores menstruales, dolor de cabeza y dolor dental .Estados febriles y en las molestias que acompañan al resfriado y a la gripe.

Paracetamol 1 g es adecuado para adultos y adolescentes desde 16 años de edad (a partir de 50 Kg).

Figura 4.12: Fragmento del prospecto del medicamento *Paracetamol Tecnigen 1 g comprimidos EFG*, disponible en el sitio web de la AEMPS. Fuente: https://cima.aemps.es/cima/dochtml/p/75994/P_75994.html

la búsqueda automatizada de la explicación terapéutica correspondiente. Para ello, se realiza una consulta sobre el diccionario terapéutico previamente descrito, con el objetivo de recuperar la descripción del uso clínico asociada a cada entidad detectada.

El mecanismo empleado para llevar a cabo esta consulta se basa en la **distancia de Levenshtein**, una métrica ampliamente utilizada en el procesamiento de lenguaje natural para medir el grado de similitud entre cadenas de texto. Esta distancia cuantifica el número mínimo de operaciones de edición (inserciones, eliminaciones o sustituciones de caracteres) necesarias para transformar una cadena en otra. En el contexto

del presente trabajo, se utiliza esta métrica para comparar la forma textual detectada en el informe con las entradas registradas en el diccionario terapéutico, tanto en lo que respecta al nombre comercial del medicamento como a los principios activos. La definición recursiva formal de esta distancia se muestra en la Ecuación 4.1, donde $\text{lev}_{a,b}(i, j)$ representa la distancia entre los prefijos de longitud i de a y j de b . Un ejemplo visual de su aplicación se ilustra en la Figura 4.13, donde se observa cómo se construye la matriz de distancias para determinar la similitud entre la cadena mal escrita “paracitamol” y la correcta “paracetamol”.

$$\text{lev}_{a,b}(i, j) = \begin{cases} \text{máx}(i, j) & \text{si } \text{mín}(i, j) = 0, \\ \text{mín} \begin{cases} \text{lev}_{a,b}(i-1, j) + 1, \\ \text{lev}_{a,b}(i, j-1) + 1, \\ \text{lev}_{a,b}(i-1, j-1) + 1_{(a_i \neq b_j)} \end{cases} & \text{en otro caso.} \end{cases} \quad (4.1)$$

	ε	p	a	r	a	c	e	t	a	m	o	l
ε	0	1	2	3	4	5	6	7	8	9	10	11
p	1	0	1	2	3	4	5	6	7	8	9	10
a	2	1	0	1	2	3	4	5	6	7	8	9
r	3	2	1	0	1	2	3	4	5	6	7	8
a	4	3	2	1	0	1	2	3	4	5	6	7
c	5	4	3	2	1	0	1	2	3	4	5	6
i	6	5	4	3	2	1	1	2	3	4	5	6
t	7	6	5	4	3	2	2	1	2	3	4	5
a	8	7	6	5	4	3	3	2	1	2	3	4
m	9	8	7	6	5	4	4	3	2	1	2	3
o	10	9	8	7	6	5	5	4	3	2	1	2
l	11	10	9	8	7	6	6	5	4	3	2	1

Figura 4.13: Matriz de distancia de Levenshtein para la comparación entre las cadenas “paracitamol” (entrada con error ortográfico) y “paracetamol” (nombre genérico de referencia). Fuente propia.

Para cada entidad reconocida en el texto clínico, se calcula su distancia de Levenshtein con respecto a todas las entradas del diccionario. La coincidencia más próxima —es decir, aquella con menor distancia de edición— se considera como la correspon-

dencia más probable, y su información terapéutica asociada es la que se incorpora al proceso de simplificación.

En aquellos casos en los que se detecta la presencia conjunta de varios principios activos en una misma mención, se asume que estos forman parte de un único medicamento compuesto. En este escenario, se realiza una búsqueda combinada en el diccionario terapéutico para identificar medicamentos que contengan exactamente el conjunto de principios activos reconocidos. Esta búsqueda considera la presencia conjunta de dichos principios activos como una entidad única, y se compara también utilizando la distancia de Levenshtein, priorizando las coincidencias que contengan todos los componentes identificados.

Este enfoque permite una mayor robustez ante errores ortográficos, abreviaciones o variantes no estándar presentes en los textos clínicos, asegurando una correcta vinculación entre las menciones del informe y la información terapéutica estructurada. De este modo, se garantiza que el sistema proporcione explicaciones precisas y accesibles sobre los tratamientos identificados, contribuyendo así a la comprensión clínica y la simplificación textual.

4.5. Tecnologías utilizadas

En este apartado se describen las principales tecnologías empleadas para el desarrollo y la experimentación de este trabajo. Se han seleccionado herramientas ampliamente utilizadas en el campo de la inteligencia artificial y el procesamiento del lenguaje natural, como Python, Hugging Face y vLLM, que han facilitado tanto la implementación de los modelos como la gestión eficiente de los experimentos. Asimismo, se ha hecho uso de Git y GitHub para la gestión del código y el control de versiones.

4.5.1. Python

*Python*³ es un lenguaje de alto nivel, interpretado y de propósito general, diseñado con el objetivo de ofrecer una sintaxis sencilla y legible. Una de sus principales características es su tipado dinámico y la gestión automática de memoria, lo que favorece el desarrollo rápido y la mejora continua del código. Python soporta múltiples paradigmas de programación, como la programación estructurada, orientada a objetos y funcional.

Además, cuenta con una extensa biblioteca estándar y una gran cantidad de paquetes externos, lo que lo hace especialmente adecuado para tareas de análisis de

³<https://www.python.org/>

datos, desarrollo web e inteligencia artificial. Gracias a su comunidad activa y recursos abundantes, Python se ha consolidado como el lenguaje de referencia en proyectos de procesamiento del lenguaje natural y aprendizaje automático.

4.5.2. Hugging Face

*Hugging Face*⁴ es una empresa centrada en el desarrollo de tecnologías de inteligencia artificial, especialmente en el ámbito del procesamiento del lenguaje natural. Su plataforma colaborativa permite el acceso a miles de modelos preentrenados, conjuntos de datos y herramientas útiles para la investigación y el desarrollo de soluciones basadas en lenguaje.

En este trabajo se ha utilizado Hugging Face principalmente para la generación automática de texto simplificado, mediante modelos generativos de la familia *LLaMA*, entre otros. Estos modelos, alojados en la plataforma, han permitido explorar diferentes estilos y grados de simplificación lingüística de los informes clínicos, contribuyendo significativamente a la validación de las hipótesis planteadas.

4.5.3. vLLM

*vLLM*⁵ es una biblioteca de código abierto optimizada para la ejecución eficiente de modelos de lenguaje de gran tamaño. Esta herramienta permite una inferencia rápida y con un uso eficiente de memoria, lo que facilita el despliegue de modelos en producción y la atención de múltiples solicitudes simultáneas.

En este proyecto se ha utilizado vLLM como herramienta principal para la inferencia de los modelos generativos empleados en la simplificación de texto. Gracias a su eficiencia, ha sido posible realizar experimentos a gran escala de forma rápida y con un bajo consumo de recursos, lo que ha agilizado las pruebas con distintos modelos de la familia *LLaMA* y otros.

4.5.4. Git y GitHub

*Git*⁶ es un sistema de control de versiones distribuido que permite llevar un registro detallado del historial de cambios en un proyecto. *GitHub*⁷ es una plataforma basada en Git que facilita la colaboración, revisión de código y documentación compartida.

⁴<https://huggingface.co/>

⁵<https://github.com/vllm-project/vllm>

⁶<https://git-scm.com/>

⁷<https://github.com/>

Durante el desarrollo de este trabajo, Git y GitHub han sido utilizados para organizar el código fuente, mantener diferentes versiones del proyecto y documentar el progreso de forma clara. Además, han sido fundamentales para asegurar la trazabilidad de los cambios y facilitar la replicabilidad de los experimentos.




Figura 4.14: Logos de las principales tecnologías utilizadas en el desarrollo del proyecto. Fuentes: Python (<https://www.python.org/>), Git (<https://git-scm.com/>), GitHub (<https://github.com/>), vLLM (<https://github.com/vllm-project/vllm>), Hugging Face (<https://huggingface.co/>).

4.6. Evaluación de la simplificación

En la Sección de Resultados ([Capítulo 5](#)), se presentan los hallazgos obtenidos a partir de las evaluaciones descritas a continuación. Estas evaluaciones se centran en las distintas subtarefas que componen el proceso de simplificación clínica, así como en una valoración global de la calidad de la redacción simplificada. De este modo, se podrá apreciar tanto el rendimiento específico de cada componente del sistema como su impacto combinado en la generación de textos clínicos más accesibles.

4.6.1. Evaluación global de la redacción simplificada

La evaluación integral de la calidad de los textos generados por el sistema de simplificación presenta importantes desafíos, debido a la ausencia de métricas automáticas consolidadas que se adapten adecuadamente al dominio médico. Las métricas tradicionales de simplificación, centradas en aspectos superficiales como la longitud de

frase, el número de sílabas por palabra o la legibilidad general, no resultan adecuadas en este contexto. Esto se debe a que los textos clínicos originales carecen de cohesión discursiva y poseen una estructura técnica fragmentada, lo que limita gravemente la aplicabilidad de dichos índices. Además, las métricas actuales centradas en el léxico se encuentran en fases preliminares de desarrollo y, en su mayoría, dependen de modelos de lenguaje generalistas que no capturan adecuadamente las particularidades del lenguaje médico.

Dado este escenario, se ha optado por una evaluación manual estructurada en dos componentes principales:

- **Evaluación cuantitativa por expertos clínicos:** Se solicitó a dos profesionales médicos que evaluaran manualmente versiones simplificadas generadas por el sistema. Esta evaluación se realizó de forma segmentada por secciones del informe (como "Motivo de ingreso", "Juicio clínico", "Tratamiento", entre otras), asignando a cada una de ellas una valoración en una escala categórica: **Incorrecto**, **Aceptable** o **Adecuado**. Esta evaluación cualitativa permite analizar la fidelidad semántica, la claridad de la simplificación y la adecuación del lenguaje empleado (véase Figura 4.15).
- **Análisis cualitativo complementario:** Además de la clasificación categórica, se solicitó a los expertos que proporcionaran un análisis cualitativo global, que incluye observaciones, sugerencias de mejora y comentarios generales sobre la calidad de la simplificación. Esta evaluación adicional permite capturar percepciones más amplias que no quedan reflejadas en la simple asignación de categorías, y contribuye a una visión más completa del impacto práctico de la simplificación en contextos reales de uso.

Asimismo, como apoyo a esta evaluación cualitativa, se ha utilizado una serie de ejemplos comparativos entre distintas configuraciones del sistema (por ejemplo, con y sin explicación de medicamentos, o con distintos niveles de expansión de abreviaciones). Estos ejemplos sirven para ilustrar de manera concreta cómo afectan las distintas subtareas al resultado final de la simplificación, permitiendo observar diferencias sustantivas en comprensión, accesibilidad y coherencia del texto.

Esta combinación de enfoques cualitativos y cuantitativos constituye actualmente la única vía fiable para evaluar la calidad de la simplificación en el ámbito clínico, en ausencia de métricas automáticas adecuadas para este dominio.




Figura 4.15: Ejemplos de evaluación de casos clínicos: comparación entre una evaluación incorrecta (caso 82) y una evaluación adecuada (caso 85)

4.6.2. Evaluación de las subtareas asociadas

La evaluación del sistema se ha estructurado en torno a las diferentes subtareas que conforman el proceso de simplificación clínica. Cada una de estas tareas ha sido evaluada individualmente con el fin de validar su efectividad antes de analizar el impacto del sistema completo.

División por secciones (hipótesis 1): debido a limitaciones de recursos, no ha sido posible solicitar a los expertos que evalúen ambas modalidades de generación del modelo de lenguaje: con división por secciones y sin dicha división. Por este motivo, no se dispone de una evaluación formal que permita validar esta hipótesis de manera concluyente. No obstante, se reconoce que el enfoque segmentado suele ofrecer mejores resultados, y para ilustrarlo se presentan algunos ejemplos en los que se observa este patrón. Aunque no es posible generalizar a partir de un número reducido de casos, en estos ejemplos se aprecia claramente la ventaja de la división por secciones, coincidiendo con las observaciones manuales realizadas en la mayoría de los casos revisados. Esta evidencia cualitativa, aunque limitada, respalda la hipótesis planteada.

Módulo de abreviaciones (hipótesis 2): esta subtarea incluye dos fases: detección y contextualización. Para la detección de abreviaciones se han comparado dos enfoques: un sistema basado en expresiones regulares y un SLM específicamente ajustado para esta tarea. Con el fin de llevar a cabo la evaluación, se generó un corpus anotado automáticamente mediante el modelo **GPT-4o**, que sirvió como referencia pa-

ra medir el rendimiento de ambos enfoques. Las métricas utilizadas fueron precisión, cobertura y *F1-score*, proporcionando una visión clara sobre la capacidad de cada sistema para identificar correctamente abreviaciones en el texto clínico. En cuanto a la contextualización, esta no se ha podido evaluar al no tener un corpus de referencia.

Módulo de medicamentos y principios activos (hipótesis 3). en este caso, se empleó únicamente un modelo de lenguaje pequeño ajustado mediante *fine-tuning*, excluyendo expresamente el uso de expresiones regulares debido a su limitada eficacia frente a la variabilidad textual de los informes médicos. La evaluación se realizó también utilizando un corpus anotado automáticamente con **GPT-4o**, y se aplicaron las mismas métricas clásicas de evaluación (precisión, cobertura y F1) para medir la capacidad del modelo de identificar de manera robusta los medicamentos y principios activos presentes en los textos.

Capítulo 5

Resultados

5.1. Resultados cuantitativos

5.1.1. Identificación de abreviaciones

Sistema	Precisión	Cobertura	F1
Expresiones regulares	0,6271	0,7675	0,6704
SLM	0,8902	0,9283	0,9024

Tabla. 5.1: Resultados de la identificación de abreviaciones.

Los resultados obtenidos en la identificación de abreviaciones (Tabla 5.1) muestran una clara superioridad del SLM sobre las expresiones regulares. Como se observa en la tabla, el SLM alcanza una precisión de 0,8902, una cobertura de 0,9283 y un F1 de 0,9024, mientras que las expresiones regulares obtienen valores considerablemente menores (precisión: 0,6271, cobertura: 0,7675, F1: 0,6704). Esta diferencia significativa se debe principalmente a que el SLM ha sido ajustado específicamente al corpus médico utilizado en el proyecto, lo que le permite reconocer patrones y contextos específicos del dominio cardiológico. Las expresiones regulares, por el contrario, presentan limitaciones debido a que no están completamente ajustadas a las particularidades del corpus y no pueden capturar la variabilidad contextual que caracteriza el uso de abreviaciones en textos médicos especializados. La naturaleza rígida de las expresiones regulares no cumple completamente con las necesidades que requiere esta tarea de identificación en un dominio tan específico.

Sistema	Precisión	Recall	F1
SLM - PA	0,703	0,711	0,702
SLM Medicamentos	0,906	0,910	0,906
SLM Union	0,890	0,928	0,902

Tabla. 5.2: Resultados de identificación para diferentes categorías SLM

5.1.2. Identificación de medicamentos y principios activos

En la identificación de medicamentos y principios activos (Tabla 5.2), los resultados revelan diferencias notables entre las categorías evaluadas. Como se muestra en la tabla, el sistema SLM para medicamentos obtiene los mejores resultados (precisión: 0,906, recall: 0,910, F1: 0,906), seguido por la unión de ambas categorías (precisión: 0,890, recall: 0,928, F1: 0,902), mientras que el SLM para principios activos presenta valores inferiores (precisión: 0,703, recall: 0,711, F1: 0,702).

La superioridad en la identificación de medicamentos se explica porque muchos principios activos son incorrectamente clasificados dentro de la categoría de medicamentos, lo que reduce la precisión de la categoría específica de principios activos. Por esta razón, la unión de ambas categorías obtiene mejores resultados que los principios activos por separado, ya que compensa esta confusión categorial. El problema subyacente radica en que la categoría de principios activos incluye frecuentemente elementos que no corresponden estrictamente a principios activos, sino a nombres comerciales o formulaciones específicas, lo que genera esta aparente mejora en los resultados de la unión.

5.1.3. Evaluación manual realizada por expertos

5.1.3.1. Valoraciones estructuradas

La evaluación estructurada fue realizada por dos expertos cardiólogos, quienes analizaron distintas secciones de un conjunto de informes generados por el sistema. Cada sección fue valorada con una escala discreta de tres niveles: 0 (incorrecto), 0.5 (parcialmente correcto) o 1 (correcto). Posteriormente, se aplicó una media ponderada entre ambas valoraciones para cada sección. Por limitaciones de tiempo y recursos, el número total de informes evaluados fue de ocho, seleccionados aleatoriamente del conjunto de salidas generadas.

La Tabla 5.3 muestra los resultados obtenidos. Se observa una calidad heterogénea según la sección analizada. El motivo de ingreso (MI) alcanza el valor más alto (0,91), seguido por el tratamiento (TR) y la enfermedad actual (EA), ambos con puntuaciones

Nº Informe	MI	ANT	EA	PC	ECC	IQP	JC	TR	PC	REV	Valoración General
19	1,00	0,75	0,75	0,00	1,00	—	0,50	1,00	1,00	1,00	1,00
31	1,00	0,75	1,00	0,50	—	0,50	0,50	0,00	—	—	1,00
50	1,00	0,50	0,50	0,25	0,00	0,50	1,00	0,25	0,25	—	0,50
61	1,00	1,00	0,50	0,50	0,75	—	0,75	1,00	1,00	—	1,00
73	1,00	1,00	1,00	0,50	0,50	—	0,25	0,25	0,25	0,25	0,50
82	1,00	0,25	0,75	1,00	—	—	0,25	0,75	—	—	0,50
85	0,75	0,75	0,50	0,25	0,25	1,00	0,50	1,00	1,00	1,00	0,50
94	0,50	0,50	1,00	0,50	—	—	0,50	0,00	0,00	0,00	1,00
Total Ponderado	0,91	0,69	0,75	0,44	0,50	0,67	0,56	0,53	0,71	0,56	0,75

Tabla. 5.3: Tabla de valoraciones por informe

relativamente altas (0,75). Esto se debe a que son secciones que presentan textos breves, con lenguaje más factual y directo, que no requiere una interpretación clínica compleja. En estas secciones, el modelo tiende a reproducir fielmente la información original, logrando un alto grado de acierto.

En cambio, las pruebas complementarias (PC) muestran la puntuación más baja (0,44). Esta sección exige interpretar resultados de analíticas, pruebas de imagen o registros electrocardiográficos, lo que supera la capacidad del modelo actual, especialmente debido a su tamaño reducido y a la falta de conocimiento clínico especializado. Por ello, se ha observado una tendencia recurrente a introducir interpretaciones erróneas de los hallazgos.

De manera similar, la sección de evolución y curso clínico (ECC) obtiene una puntuación media de 0,50, reflejando la dificultad del modelo para manejar secuencias narrativas que implican cambios clínicos, razonamientos médicos o seguimiento temporal.

La valoración general, con una media de 0,75, indica que el sistema alcanza un nivel razonable de calidad en muchas secciones, pero aún está lejos de poder ser implementado en un contexto asistencial. Este resultado global sugiere que el sistema posee potencial, aunque necesita mejoras significativas, especialmente en aspectos que requieren interpretación clínica y reformulación compleja del contenido.

5.1.3.2. Comentarios y sugerencias cualitativas

Los comentarios detallados de ambos expertos, incluidos en el **Apéndice C**, proporcionan conocimiento valioso sobre las limitaciones del sistema actual. Ambos evaluadores coinciden en que el lenguaje generado no alcanza el nivel de claridad y ac-

cesibilidad requerido para pacientes sin conocimientos médicos, y que algunos casos pueden generar confusión.

El primer experto enfatiza que, siendo estrictos, los informes no son adecuados para su entrega directa a pacientes debido a imprecisiones en temas tan trascendentes como la salud. Sugiere adoptar un formato más directo, similar al utilizado en algunos países europeos, donde se dirige personalmente al paciente explicando su diagnóstico, las pruebas realizadas y el propósito del tratamiento.

El segundo experto, aunque asigna calificaciones relativamente benévolas, confirma que ningún informe se acerca a ser entregable a un paciente real. Propone una reestructuración fundamental hacia un formato más cercano y menos estructurado, utilizando segunda persona y enfocándose en información esencial mediante recorte de texto más que interpretación.

Ambos expertos identifican problemas recurrentes como redundancias, terminología técnica sin explicar adecuadamente, interpretaciones erróneas de pruebas diagnósticas, e información innecesaria que puede confundir al paciente. Estas observaciones confirman la necesidad de refinamiento significativo del sistema antes de su implementación clínica.

5.2. Análisis de errores

A lo largo de las secciones anteriores se han identificado diversos errores en el sistema, especialmente gracias a la evaluación estructurada y a las sugerencias cualitativas proporcionadas por los expertos. Aunque ya se ha comentado parte de estos fallos, en este apartado se ofrece un análisis más detallado, desglosado por módulos, con el objetivo de entender mejor las limitaciones actuales del sistema y establecer líneas de mejora.

5.2.1. Módulo de tratamiento de abreviaciones

El principal problema observado en este módulo está relacionado con la desambiguación de términos. En numerosos casos, una misma abreviación puede tener varios significados dependiendo del contexto clínico, y el modelo de lenguaje tiene que decidir entre ellos. Se ha comprobado que en algunos casos esta elección no es correcta, lo que constituye un error grave, ya que puede inducir a malentendidos importantes en la interpretación del informe. Este tipo de fallo es especialmente crítico en el ámbito médico.

TEXTO MÉDICO ORIGINAL

Ecocardiograma transtorácico 22/1/2021: Ventrículo izquierdo no dilatado, hipertrófico, SIV 15 mm, con función sistólica global conservada, FEVI A4C 50 %, con marcada asincronía. Aurícula izquierda dilatada. 56 mm, área 24.6cm². Llenado ventricular izquierdo monofásico. Insuficiencia aórtica y mitral leve. Aurícula derecha dilatada. Ventrículo derecho dilatado, con función sistólica normal, TAPSE 26 mm. IT leve, velocidad 3.4 m/s. Alta probabilidad de HTP. No derrame pericárdico. VCI dilatada, sin colapso inspiratorio fisiológico.



SIMPLIFICACIÓN CON ERROR DE DESAMBIGUACIÓN

**TEXTO SIMPLIFICADO (CON ERROR)**

Ecocardiograma del 22/1/2021: el ventrículo izquierdo está algo más grueso de lo normal pero funciona bien (FEVI del 50 %). La aurícula izquierda está agrandada y el llenado del ventrículo izquierdo es monofásico. Hay leves insuficiencias en las válvulas aórtica y mitral. También están dilatadas la aurícula y el ventrículo derechos, aunque este último tiene buena función (TAPSE 26 mm). Se detecta insuficiencia tricuspídea leve, con una velocidad de 3.4 m/s. Se considera que hay una alta probabilidad de **hipertensión portal**. No hay líquido alrededor del corazón. La vena cava inferior está dilatada y no colapsa con la inspiración.

Error de desambiguación:

HTP puede significar:

- ✗ Hipertensión portal (*incorrecta*)
- ✓ Hipertensión pulmonar (*correcta*)
- Test Casa-árbol-persona

Figura 5.1: Error de desambiguación de la abreviación HTP en el módulo de tratamiento de abreviaciones. El sistema interpretó incorrectamente HTP como «hipertensión portal» en lugar de «hipertensión pulmonar», que es el significado correcto en el contexto cardiológico del ecocardiograma.

Un ejemplo representativo de este problema se ilustra en la Figura 5.1, donde el sistema interpretó incorrectamente la abreviación **HTP** como «hipertensión portal» cuando el contexto cardiológico del ecocardiograma indicaba claramente que se refería a «hipertensión pulmonar». Este error de desambiguación resulta particularmente problemático, ya que ambas condiciones médicas tienen implicaciones clínicas completamente diferentes: la hipertensión pulmonar está directamente relacionada con los hallazgos ecocardiográficos descritos (dilatación de cavidades derechas, insuficiencia tricuspídea), mientras que la hipertensión portal es una patología hepática sin relación con los datos presentados.

No obstante, dada la naturaleza del modelo utilizado y los recursos computacionales disponibles en este proyecto, actualmente no es posible abordar de forma efectiva este problema.

5.2.2. Módulo de tratamiento de medicamentos

En términos generales, el módulo de medicamentos ha ofrecido un rendimiento muy satisfactorio. Durante las evaluaciones no se han identificado errores significativos, y el comportamiento del sistema se considera sólido y alineado con los objetivos planteados. Este módulo ha logrado identificar correctamente la mayoría de los medicamentos mencionados en los informes.

Sin embargo, se ha detectado un error específico relacionado con el reconocimiento incompleto de medicamentos combinados, como se muestra en la Figura 5.2. En este caso, el sistema identificó únicamente el principio activo **Hidroclorotiazida** del medicamento combinado Olmesartán/Amlodipino/Hidroclorotiazida, atribuyendo su función exclusivamente al tratamiento de edemas. Este reconocimiento parcial llevó a una explicación incorrecta, ya que la combinación de los tres principios activos está específicamente diseñada para el control de la hipertensión arterial, no para el tratamiento aislado de edemas. Este tipo de error evidencia las limitaciones del módulo de reconocimiento de medicamentos cuando se enfrenta a formulaciones combinadas, donde la acción terapéutica conjunta de varios principios activos puede diferir significativamente de la función individual de cada componente.

Es importante remarcar que, al igual que otros componentes del sistema, no ha sido posible aplicar métricas de evaluación específicas que permitan cuantificar su rendimiento de forma precisa, lo que limita en parte la evaluación objetiva del mismo.

PRESCRIPCIÓN ORIGINAL

Olmesartán/Amlodipino/HCT 40/10/12.5mg 1-0-0
Metformina/Empagliflozina 1000/5mg 1-0-1
Atorvastatina/Ezetimiba 40/10mg 0-0-1
Alopurinol 100mg 0-1-0
Nexium 40 mg, 1-0-0



SIMPLIFICACIÓN CON ERROR DE RECONOCIMIENTO

**EXPLICACIÓN SIMPLIFICADA (CON ERROR)**

Olmesartán/Amlodipino/Hidroclorotiazida 40/10/12.5mg
 – **Para tratar los edemas. 1-0-0:** una toma por la mañana.

Metformina/Empagliflozina 1000/5mg – Para el control de la diabetes tipo 2. **1-0-1:** una toma por la mañana y otra por la noche.

Atorvastatina/Ezetimiba 40/10mg – Para disminuir el colesterol. **0-0-1:** una toma por la noche.

Alopurinol 100mg – Para prevenir ataques de gota al reducir el ácido úrico. **0-1-0:** una toma al mediodía.

Nexium (Esomeprazol) 40mg – Para tratar el reflujo gástrico o acidez. **1-0-0:** una toma por la mañana.

Error en el reconocimiento de medicamentos:

Explicación incorrecta	Explicación correcta
Para tratar los edemas	Para reducir la presión arterial alta

Causa del error: El detector de medicamentos solo identificó el principio activo **Hidroclorotiazida** (diurético para edemas), pero no reconoció que la combinación de los tres principios activos (Olmesartán + Amlodipino + Hidroclorotiazida) está destinada al tratamiento de la hipertensión arterial.

Figura 5.2: Error en el módulo de reconocimiento de medicamentos. El sistema identificó incorrectamente la finalidad del medicamento combinado Olmesartán/Amlodipino/Hidroclorotiazida, atribuyendo su uso solo al tratamiento de edemas en lugar de su verdadero propósito: el control de la hipertensión arterial.

5.2.3. Simplificación global

En lo que respecta al proceso completo de simplificación, la evaluación automática no permite realizar un análisis detallado de errores, ya que no existen métricas objetivas que evalúen directamente la calidad de los textos generados. Por ello, en la siguiente sección se presentarán una serie de ejemplos representativos que ilustran cualitativamente distintos aciertos y errores del sistema.

Un ejemplo particularmente preocupante de este tipo de errores se ilustra en la Figura 5.3, donde el sistema cometió un error conceptual grave al explicar el Síndrome de Tako-Tsubo tipo 1. El modelo interpretó incorrectamente esta patología como una "infección bacteriana que inflama el músculo cardíaco", cuando en realidad, según la Sociedad Española de Cardiología, se trata de una miocardiopatía por estrés también conocida como "síndrome del corazón roto", que ocurre cuando el corazón se debilita temporalmente debido a situaciones de estrés emocional o físico intenso. Este error es especialmente crítico porque no solo proporciona información médica incorrecta, sino que podría generar ansiedad innecesaria en el paciente al sugerir una causa infecciosa que requeriría un tratamiento completamente diferente. La confusión entre una miocardiopatía inducida por estrés y una infección bacteriana del miocardio representa una falta fundamental de comprensión de la fisiopatología cardiovascular, evidenciando las limitaciones del sistema cuando se enfrenta a conceptos médicos complejos que requieren un conocimiento especializado preciso.

En cualquier caso, la evaluación manual realizada por expertos es el indicador más fiable sobre el rendimiento general del sistema en su estado actual. A partir de sus valoraciones y observaciones, se concluye que, si bien el sistema muestra un potencial significativo, aún no está listo para ser utilizado en entornos clínicos reales. Las principales mejoras necesarias pasan por reenfocar el formato de salida para centrarse más en la información esencial, aumentar la capacidad de síntesis —más allá de una mera simplificación léxica— y mejorar tanto la calidad como la accesibilidad del lenguaje generado. Además, resulta fundamental implementar mecanismos de validación médica que permitan detectar y corregir errores conceptuales graves como el ilustrado en el ejemplo anterior. Solo mediante estas mejoras será posible ofrecer informes verdaderamente útiles y comprensibles para usuarios sin formación médica especializada.

DIAGNÓSTICO ORIGINAL
<i>MINOCA.</i> <i>Síndrome de Tako-Tsubo tipo 1.</i> <i>FEVI limítrofe</i>



SIMPLIFICACIÓN CON ERROR CONCEPTUAL



EXPLICACIÓN SIMPLIFICADA (CON ERROR)
MINOCA – Es un tipo de infarto en el que no hay taponamiento importante en las arterias del corazón. Síndrome de Tako-Tsubo tipo 1 – Es una enfermedad del corazón causada por una infección bacteriana que inflama el músculo cardíaco. FEVI limítrofe – Significa que el corazón está bombeando con una fuerza un poco más baja de lo normal, pero no grave.

Error conceptual grave:

Explicación incorrecta	Explicación correcta
Enfermedad causada por una infección bacteriana que inflama el músculo cardíaco	También conocido como "miocardiopatía por estrés" o "síndrome del corazón roto", ocurre cuando el corazón se debilita temporalmente, muchas veces por un susto o una emoción fuerte

Fuente: Sociedad Española de Cardiología^a

Gravedad del error: El sistema confundió completamente la etiología del síndrome, atribuyendo una causa infecciosa cuando en realidad se trata de una miocardiopatía inducida por estrés emocional o físico.

^a<https://secardiologia.es/>

Figura 5.3: Error conceptual grave en la explicación del Síndrome de Tako-Tsubo tipo 1. El sistema interpretó incorrectamente este síndrome como una infección bacteriana, cuando según la Sociedad Española de Cardiología se trata de una miocardiopatía por estrés emocional, también conocida como "síndrome del corazón roto".

5.3. Resultados cualitativos: ejemplos ilustrativos

Con el objetivo de ilustrar cómo contribuyen las distintas hipótesis a una simplificación más precisa y completa, a continuación se presentan ejemplos comparativos correspondientes a cada una de ellas.

Aunque no es posible extraer conclusiones generales a partir de tan solo dos ejemplos por módulo o sistema generado, esta es actualmente la única forma disponible que permite realizar un análisis preliminar del comportamiento observado. Cabe insistir en que estos casos no permiten obtener estadísticas fiables ni establecer generalizaciones, pero sí constituyen un punto de partida útil para comenzar a identificar patrones internos bajo los nuevos módulos y la estrategia implementada.

5.3.1. Hipótesis 1: La división por secciones mejora la calidad de la simplificación

Ejemplo 1

Original (Juicio clínico)

1. Taquicardia ventricular sostenida cardiovertida eléctricamente y farmacológicamente sintomáticas por síncope.
2. Arterias coronarias normales.
3. Cor pulmonale: dilatación y disfunción de VD. HTP severa. FEVI normal.
4. Derrame pericárdico crónico severo sin datos de compromiso hemodinámico.
5. Fibrilación auricular permanente.
6. EPOC agudizado en contexto de infección respiratoria no condensante.

Simplificación por secciones

■ Taquicardia ventricular sostenida

Episodio sintomático con síncope. Requirió cardioversión eléctrica y tratamiento farmacológico.

■ Arterias coronarias

Morfología normal, sin hallazgos patológicos en el estudio actual.

■ Cor pulmonale

Dilatación y disfunción del ventrículo derecho. Hipertensión pulmonar severa con FEVI conservada.

■ Derrame pericárdico crónico

Presente de forma severa, sin signos de compromiso hemodinámico.

■ Fibrilación auricular permanente

Ritmo arrítmico persistente con necesidad de control crónico.

■ EPOC agudizado

Exacerbación atribuida a infección respiratoria no condensante.

Simplificación completa

Paciente con taquicardia ventricular cardiovertida, fibrilación auricular permanente y EPOC agudizado. Se mantiene seguimiento por cardiología y neumología.

Ejemplo 2**Original (Juicio clínico)**

1. FA de difícil control farmacológico.
2. Portadora de marcapasos monocameral con estimulación de rama izquierda.
3. Ablación de NAV.

Simplificación por secciones**■ Fibrilación auricular de difícil control**

Persisten episodios arrítmicos a pesar del tratamiento médico óptimo.

■ Marcapasos monocameral

Implantado con estimulación dirigida a la rama izquierda para optimizar la conducción.

■ Ablación de nodo auriculoventricular (NAV)

Procedimiento realizado como parte del manejo de la arritmia de difícil control.

Simplificación completa

Paciente con fibrilación auricular de difícil control y portadora de marcapasos. Se realizó ablación del nodo AV para mejorar el control arrítmico.

En ambos ejemplos se observa que la versión «por secciones» no solo conserva todos los diagnósticos originales, sino que los explica de forma estructurada, facilitando la comprensión y el seguimiento de cada uno. En cambio, la simplificación «completa» —pese a su corrección lingüística— omite sistemáticamente parte de las condiciones clínicas, lo que puede comprometer la integridad informativa del informe.

5.3.2. Hipótesis 2: El manejo correcto de abreviaciones médicas mejora la comprensión

Ejemplo 1

Texto original con abreviación ambigua

Paciente con antecedentes de HTA y episodios de FA de difícil control.

Versión sin módulo de abreviaciones (expansión incorrecta)

Paciente con antecedentes de hipertensión y episodios de frecuencia alta de difícil control.

Versión con abreviaciones correctamente desarrolladas

Paciente con antecedentes de hipertensión arterial (HTA) y episodios de fibrilación auricular (FA) de difícil control.

Ejemplo 2

Texto original con uso excesivo de abreviaciones

Portadora de MP monocameral con estimulación de RI. Antecedentes de ablación de NAV por FA persistente.

Versión sin módulo de abreviaciones (expansión incorrecta)

Portadora de marcapaso monocameral con estimulación de registro interno. Antecedentes de ablación de navegación por frecuencia alta persistente.

Versión con abreviaciones desarrolladas

Paciente portadora de marcapasos (MP) monocameral con estimulación dirigida a la rama izquierda (RI). Antecedentes de ablación del nodo auriculoventricular (NAV) debido a fibrilación auricular (FA) persistente.

En estos casos se evidencia que el desarrollo adecuado de abreviaciones médicas mejora significativamente la accesibilidad del lenguaje clínico, mientras que los sistemas sin módulo específico de abreviaciones médicas pueden generar expansiones erróneas que alteran completamente el significado clínico del texto.

5.3.3. Hipótesis 3: La explicación del tratamiento incrementa la accesibilidad del informe

Ejemplo 1

Original (tratamiento de un informe real)

Mismo tratamiento con los siguientes cambios:

- Suspender losartan 25 mg
- Añadir:
 - sacubitrilo/valsartán cada 12h
 - apixaban 5 mg cada 12h

Versión sin módulo de tratamiento

- Losartán: suspender.
- Sacubitrilo/valsartán: 1 dosis cada 12 horas para mejorar la diabetes.
- Apixabán: 1 pastilla de 5 mg por la mañana y 1 pastilla de 5 mg por la noche para prevenir la formación de coágulos sanguíneos.

Versión con módulo de tratamiento

■ Suspensión:

- Losartán: suspender

■ Inicio:

- Sacubitrilo/valsartán: 1 dosis cada 12 horas para mejorar la función del corazón.
- Apixabán: 1 pastilla de 5 mg por la mañana y 1 pastilla de 5 mg por la noche para prevenir la formación de coágulos sanguíneos.

Ejemplo 2**Original (tratamiento de un informe real)**

- Apixaban 5 mg cada 12 horas
- Ácido acetilsalicílico 100 mg cada 24 horas (durante un año y suspender) hasta enero 2022
- Clopidogrel 75 mg cada 24 horas (durante 3 meses y suspender) hasta abril 2021
- Atorvastatina 80 mg cada 24 horas

Versión sin módulo de tratamiento

- Apixabán: 1 pastilla de 5 mg por la mañana y 1 pastilla de 5 mg por la noche para prevenir la formación de coágulos sanguíneos.
- Ácido acetilsalicílico: 1 pastilla de 100 mg cada día para evitar que la sangre forme coágulos.
- Clopidogrel: 1 pastilla de 75 mg cada día para evitar que la sangre forme coágulos.
- Atorvastatina: 1 pastilla de 80 mg cada día para .

Versión con módulo de tratamiento**■ Anticoagulación:**

- Apixabán: 1 pastilla de 5 mg por la mañana y 1 pastilla de 5 mg por la noche para prevenir la formación de coágulos sanguíneos.

■ Antiagregación:

- Ácido acetilsalicílico: 1 pastilla de 100 mg cada día hasta enero 2022 para evitar coágulos después de un problema cardíaco.
- Clopidogrel: 1 pastilla de 75 mg cada día hasta abril 2021 para evitar coágulos tras una intervención en las arterias.

■ Lípidos:

- Atorvastatina: 1 pastilla de 80 mg cada día para bajar el colesterol y proteger el corazón.

Los ejemplos presentados respaldan la hipótesis de que la incorporación de un módulo de tratamiento mejora la accesibilidad del informe médico. Mientras que la versión original utiliza un lenguaje técnico y desestructurado, comprensible solo para profesionales, y la versión sin módulo traduce los términos pero mantiene una lista plana, la versión con módulo organiza la información por categorías clínicas (como anticoagulación o lípidos) y añade explicaciones claras sobre el propósito de cada medicamento y la duración del tratamiento.

Capítulo 6

Plataforma de demostración

El desarrollo de una plataforma web tiene como finalidad facilitar la interacción con el sistema de simplificación automática de informes de alta hospitalaria en el ámbito de la cardiología, propuesto en este Trabajo Fin de Grado. Dado que los modelos de PLN diseñados requieren conocimientos técnicos para su ejecución directa, se ha implementado una interfaz accesible que permita visualizar los resultados de forma clara.

Cabe destacar que esta plataforma tiene un carácter exclusivamente demostrativo y académico. No está destinada a su uso clínico real. Su objetivo es servir como herramienta de apoyo para la validación de resultados, la presentación del trabajo y la exploración de funcionalidades desarrolladas.

La plataforma permite cargar informes médicos, visualizar simultáneamente su versión original y simplificada, consultar las abreviaciones médicas detectadas junto con sus significados, y explorar el contenido dividido por secciones clínicas relevantes. De este modo, no solo se facilita el análisis cualitativo de los resultados, sino que se ofrece una demostración funcional del sistema desarrollado, acercando su aplicabilidad a un contexto más tangible.

6.1. Objetivos de la plataforma

La plataforma web desarrollada tiene como propósito principal facilitar la visualización, exploración y validación de los resultados obtenidos mediante los modelos de simplificación automática de informes clínicos. Su diseño responde a la necesidad de disponer de una herramienta interactiva que permita presentar el sistema de forma clara, accesible y funcional, tanto para el tutor académico como para posibles validadores clínicos.

Los objetivos específicos que persigue la plataforma son los siguientes:

- **Ofrecer una interfaz web intuitiva y accesible** que permita cargar informes médicos sin necesidad de conocimientos técnicos.
- **Mostrar simultáneamente la versión original y la versión simplificada** de cada informe, permitiendo una comparación visual directa y clara entre ambas.
- **Dividir automáticamente el contenido del informe por secciones clínicas relevantes**, tales como antecedentes, diagnóstico, tratamiento o evolución, facilitando así la interpretación del texto médico por partes.
- **Detectar y explicar abreviaciones clínicas** mediante un diccionario especializado, ayudando a la comprensión del lenguaje médico técnico utilizado en los informes.
- **Permitir la exportación del contenido procesado** en distintos formatos (por ejemplo, PDF o JSON), para su análisis externo o almacenamiento.
- **Demostrar la aplicabilidad práctica del sistema** desarrollado en el TFG en un entorno de prueba sencillo, visual y replicable.

En conjunto, la plataforma actúa como un puente entre el desarrollo técnico de los modelos y su comprensión e interpretación por parte de usuarios no técnicos. Aunque no está orientada a su uso clínico real, cumple una función clave en la evaluación del trabajo realizado y en la presentación de resultados de forma estructurada.

6.2. Análisis

6.2.1. Público Objetivo

El sistema está dirigido exclusivamente a personas autorizadas en contextos de investigación, docencia o demostración. La interfaz no está preparada para su uso por parte de pacientes, personal clínico o usuarios sin formación. Su propósito actual es servir como apoyo visual y funcional en exposiciones, pruebas de concepto o sesiones de evaluación, en las que se ilustre el potencial del sistema de simplificación automática de informes médicos.

6.2.2. Requisitos de la plataforma

Antes de abordar el diseño de la plataforma, se identificaron una serie de requisitos que debía cumplir para garantizar su funcionalidad y utilidad como herramienta de apoyo dentro del Trabajo Fin de Grado. Estos requisitos se agrupan en dos categorías: funcionales y no funcionales.

6.2.2.1. Requisitos funcionales

Los requisitos funcionales describen las capacidades mínimas que la plataforma debe ofrecer desde el punto de vista del usuario:

- **Carga de informes clínicos:** el usuario debe poder introducir un informe de alta hospitalaria mediante la carga de un archivo compatible.
- **Simplificación automática:** la plataforma debe procesar el texto cargado utilizando el sistema desarrollado y generar una versión simplificada.
- **Visualización comparativa:** el usuario debe poder ver simultáneamente el texto original y el texto simplificado en una disposición clara y accesible.

6.2.2.2. Requisitos no funcionales

Los requisitos no funcionales hacen referencia a aspectos relacionados con la usabilidad, el rendimiento y las condiciones de desarrollo de la herramienta:

- **Facilidad de uso:** la interfaz debe ser intuitiva y no requerir conocimientos técnicos por parte del usuario.
- **Rendimiento adecuado:** la plataforma debe ofrecer una respuesta rápida (idealmente en menos de 5 segundos por informe procesado) para garantizar una experiencia fluida.
- **Compatibilidad y accesibilidad:** debe funcionar correctamente en los principales navegadores modernos (Chrome, Firefox, Edge) y adaptarse a distintos tamaños de pantalla.
- **Privacidad:** no se deben almacenar los textos introducidos ni resultados generados en el servidor. Todo el procesamiento debe realizarse en memoria y de forma efímera.

- **Modularidad:** la arquitectura debe facilitar futuras ampliaciones, como la integración de nuevos modelos de PLN, funciones de evaluación o gestión de usuarios.
- **Carácter demostrativo:** la plataforma no debe usarse con fines clínicos reales. Su uso está restringido a la presentación de resultados académicos y validación no oficial.

6.3. Diseño de la Interfaz

Para el diseño visual de la interfaz de usuario inicialmente se establecieron los principios de diseño para posteriormente realizar bocetos sobre la plataforma y la consecuente elaboración de wireframes, que constituyen bocetos de baja fidelidad y esquemas iniciales. Estos wireframes permitieron definir la estructura básica de la interfaz, la disposición de los elementos y el flujo de interacción sin entrar en detalles gráficos.

6.3.1. Principios de Diseño

La interfaz de usuario de la plataforma SIMPLIMED ha sido diseñada siguiendo los principios de simplicidad, claridad y accesibilidad. Se busca minimizar la carga cognitiva del usuario, facilitando la interacción con el sistema incluso para personas sin conocimientos técnicos. Para ello, se han aplicado las siguientes directrices:

- **Consistencia visual:** Se mantiene una paleta de colores coherente con tonos suaves, tipografía legible y disposición estructurada.
- **Accesibilidad:** El diseño es responsivo y compatible con tecnologías de asistencia. Se han tenido en cuenta contrastes adecuados y etiquetas descriptivas para todos los elementos interactivos.
- **Feedback inmediato:** Cada acción del usuario (subida de archivo, simplificación, etc.) está acompañada de una respuesta visual o textual que confirma el estado de la operación.
- **Minimización del esfuerzo del usuario:** El flujo de uso se reduce a tres pasos: subir el informe, visualizar la simplificación y descargar el resultado, evitando configuraciones o formularios innecesarios.

6.3.2. Wireframes

Los wireframes iniciales consistieron en bocetos esquemáticos para visualizar la estructura y funcionalidades básicas, estableciendo las bases del diseño de la interfaz.

6.3.2.1. Pantalla de subida de archivo

Este wireframe definía un área destinada a la carga de informes mediante archivo o texto pegado. La Figura 6.1 muestra el diseño esquemático inicial de esta pantalla, donde se puede observar la disposición de los elementos principales y la estructura general de la interfaz de carga.




Figura 6.1: Wireframe de la pantalla de subida de archivo

6.3.2.2. Pantalla de visualización comparativa

El wireframe para esta pantalla planteaba una distribución en dos columnas paralelas, donde se mostrarían el texto original y el texto simplificado. Como se presenta en la Figura 6.2, el diseño conceptual establece una clara separación entre el contenido original y simplificado, facilitando la comparación visual entre ambos textos.



Figura 6.2: Wireframe de la pantalla de visualización comparativa

6.4. Visualización de la implementación

El diseño final de la plataforma recoge las mejoras e iteraciones surgidas durante el desarrollo, combinando claridad, funcionalidad y accesibilidad. La interfaz mantiene la estructura de doble panel para la comparación textual, con un diseño limpio y moderno que facilita la lectura y exploración de los informes.

Para ilustrar el resultado obtenido, se incluyen a continuación dos capturas de pantalla que muestran la materialización de los conceptos de diseño previamente desarrollados, correspondientes a:

- La pantalla de subida de informes, donde el usuario puede cargar o introducir manualmente el texto.
- La pantalla de visualización comparativa, mostrando el informe original junto con su versión simplificada y el panel de abreviaciones.

La Figura **6.3** muestra la implementación final de la pantalla de subida de informes, donde se puede observar cómo el diseño final conserva los elementos esenciales planteados en los wireframes y mock-ups, pero incorpora refinamientos adicionales que mejoran la experiencia de usuario, incluyendo indicadores visuales más claros y una disposición optimizada de los elementos interactivos.




Figura 6.3: Implementación final de la pantalla de subida de archivo

Por su parte, la Figura 6.4 presenta la implementación final de la pantalla de visualización comparativa. Esta captura evidencia la materialización exitosa de los principios de diseño establecidos, con una interfaz que facilita la comparación entre textos, mantiene la consistencia visual y proporciona una experiencia de usuario intuitiva y accesible.



Figura 6.4: Implementación final de la pantalla de visualización comparativa

La evolución desde los wireframes iniciales hasta la implementación final demuestra un proceso de diseño iterativo y centrado en el usuario, donde cada etapa contribuyó a refinar tanto la funcionalidad como la estética de la plataforma SIMPLIMED.

6.5. Integración del backend

La comunicación entre el cliente y el servidor se establece a través de peticiones HTTP gestionadas por un backend desarrollado con **Node.js**¹ y el framework **Express**². Esta arquitectura permite la separación clara entre lógica de presentación y procesamiento, facilitando la escalabilidad y el mantenimiento del sistema.

El frontend interactúa con el backend mediante diferentes rutas y métodos HTTP, principalmente:

- **POST /upload**: recibe un archivo PDF desde el cliente utilizando el middleware `multer`. Este archivo se guarda temporalmente y se le asocia un identificador único mediante `uuid`. Tras la carga, se lanza un proceso de transformación sobre el documento.
- **GET /events/:id**: establece una conexión persistente utilizando Server-Sent Events (SSE) para recibir actualizaciones en tiempo real del progreso del procesamiento del archivo. El identificador del archivo permite vincular correctamente el canal de comunicación.
- **GET /exists/:id**: verifica si ya existe un resultado procesado para un archivo dado. Esta ruta es útil para evitar reprocesamientos innecesarios y permite al frontend redirigir directamente al visor si el contenido ya está disponible.
- **GET /result/:id**: devuelve el contenido procesado del archivo en formato texto plano, normalmente Markdown o texto simplificado, para ser mostrado directamente al usuario.
- **GET /preview/:id**: sirve una vista HTML específica que permite al usuario ver el resultado procesado, con capacidades de interacción o descarga.

El backend, además de estas rutas, gestiona el estado de los archivos (almacenamiento temporal, resultados y limpieza posterior) y se comunica con procesos externos de procesamiento documental.

6.6. Limitaciones y mejoras futuras

A pesar de haber cumplido satisfactoriamente los objetivos propuestos, la plataforma web desarrollada presenta ciertas limitaciones propias de su naturaleza académica

¹<https://nodejs.org/>

²<https://expressjs.com/>

y del alcance del Trabajo Fin de Grado. A continuación se describen las principales restricciones actuales y se proponen posibles líneas de mejora para futuros desarrollos.

6.6.1. Limitaciones

- **Uso estrictamente demostrativo:** la plataforma no está diseñada ni validada para un uso clínico real. No cumple con normativas de seguridad, protección de datos sanitarios o validación médica, por lo que su función se limita a la exploración de resultados en entornos controlados.
- **Dependencia del navegador y recursos locales:** algunas operaciones (como la visualización comparativa o la exportación de resultados) dependen de las capacidades del navegador del usuario y pueden no funcionar correctamente en dispositivos antiguos o con configuraciones específicas.

6.6.2. Mejoras futuras

- **Adaptación a un entorno clínico controlado:** como paso previo a su uso real, la plataforma podría evolucionar hacia un prototipo clínico seguro, cumpliendo estándares de interoperabilidad (HL7, FHIR), encriptación y anonimización de datos.
- **Interfaz interactiva y editable:** una futura versión podría permitir al usuario experto corregir, validar o refinar manualmente las simplificaciones y las explicaciones de abreviaciones, favoreciendo un enfoque colaborativo.
- **Historial de uso y gestión de informes:** añadir un sistema seguro de gestión temporal de sesiones e informes para facilitar la revisión y comparación de distintos resultados dentro de una misma sesión de trabajo.

Estas posibles extensiones permitirían transformar esta herramienta académica en un sistema más completo, robusto y potencialmente útil para profesionales sanitarios, sin perder de vista los requerimientos éticos, legales y técnicos propios del contexto médico.

Capítulo 7

Conclusiones

7.1. Resumen de los hallazgos

Este Trabajo Fin de Grado ha tenido como objetivo principal realizar una experimentación que permita evaluar la viabilidad de simplificar informes de alta hospitalaria en el ámbito de la cardiología mediante técnicas de procesamiento de lenguaje natural. Para ello, se ha diseñado un prototipo que integra modelos de lenguaje, inferencia por secciones y mecanismos de detección y expansión de abreviaturas, explorando distintas estrategias para adaptar el lenguaje técnico a un nivel comprensible para personas sin formación médica.

La experimentación llevada a cabo ha mostrado resultados prometedores, indicando mejoras en la claridad y accesibilidad de los informes. No obstante, los análisis realizados, incluyendo la revisión por parte de profesionales de la cardiología, ponen de manifiesto que dichos avances no resultan todavía suficientes para considerar la propuesta como una herramienta definitiva y completamente fiable para su uso real en el entorno clínico. Por este motivo, aunque se ha desarrollado una pequeña plataforma para ilustrar el funcionamiento del sistema, esta debe entenderse como un demostrador experimental y no como un producto final operativo.

En conjunto, los resultados obtenidos confirman que la línea de trabajo seguida presenta potencial para contribuir a la mejora de la comunicación médico-paciente, pero subrayan la necesidad de profundizar en la metodología, ampliar la validación y superar las limitaciones actuales antes de plantear su implementación práctica.

7.2. Principales contribuciones

A lo largo del desarrollo del proyecto se han generado un conjunto significativo de aportaciones técnicas, experimentales y metodológicas orientadas a facilitar la comprensión de informes de alta hospitalaria en el ámbito de la cardiología mediante técnicas de procesamiento del lenguaje natural. A continuación, se detallan las contribuciones más relevantes:

- **Plataforma web funcional para simplificación clínica:** Se ha implementado una plataforma interactiva que permite realizar, en tiempo real, la simplificación de informes clínicos mediante modelos de lenguaje de gran tamaño (VLM). Este sistema actúa como un demostrador tecnológico que integra múltiples componentes del pipeline propuesto (detección de secciones, expansión de abreviaciones, simplificación textual), permitiendo su evaluación y visualización por parte de usuarios no expertos.
- **Diccionario de abreviaciones clínicas:** Se ha compilado un diccionario contextualizado de abreviaciones médicas basado en el diccionario de siglas médicas de la SEDOM, incluyendo múltiples significados por término. Este recurso se ha estructurado en formato CSV compatible con flujos de trabajo en Python, y representa un componente fundamental para la detección y expansión automática de abreviaciones dentro del sistema.
- **Corpus clínico real anonimizado para experimentación:** Se ha trabajado con un conjunto de informes médicos reales del área de cardiología, que si bien no puede ser publicado por razones de confidencialidad, ha servido como base para entrenar, validar y evaluar los modelos propuestos.
- **Validación de hipótesis sobre la simplificación clínica:** Se han contrastado empíricamente varias hipótesis formuladas al inicio del proyecto, como la mejora de la calidad de la salida tras dividir los textos por secciones, la importancia de expandir abreviaciones para facilitar la comprensión, y la utilidad de explicar de forma simplificada los tratamientos farmacológicos. Los resultados obtenidos apoyan la relevancia de estas estrategias en el contexto clínico.
- **Diseño y validación de un conjunto experimental con modelos LLM:** Se ha llevado a cabo una extensa experimentación empleando múltiples variantes de modelos de lenguaje (incluyendo modelos grandes y modelos ligeros), centrada en validar hipótesis sobre la mejora de la simplificación mediante estrategias dirigidas. Esta evaluación ha incluido análisis cualitativos y revisión por parte de profesionales del ámbito médico.

- **Entrenamiento de dos modelos especializados:** Se han desarrollado y entrenado dos modelos ligeros con objetivos específicos: uno para el reconocimiento de medicamentos en textos clínicos, y otro orientado a la detección de abreviaciones médicas. Estos modelos han sido diseñados para integrarse en sistemas de preprocesamiento o simplificación, y constituyen un avance hacia soluciones más eficientes y personalizables.
- **Redacción y documentación del proceso completo:** El trabajo se acompaña de una memoria técnica que documenta de forma detallada el diseño, desarrollo, evaluación y análisis de todos los componentes del sistema. Esta memoria incluye reflexiones metodológicas, discusión crítica de los resultados y propuestas de mejora fundamentadas.

Cada uno de estos elementos contribuye a avanzar en la línea de investigación centrada en la accesibilidad del lenguaje médico, aportando recursos, herramientas y resultados que pueden ser reutilizados o ampliados en estudios posteriores.

7.3. Trabajo futuro

A partir de los resultados y limitaciones identificados, se proponen varias direcciones de trabajo para continuar y mejorar lo realizado:

- **Mejora de la precisión en la simplificación:** Aunque los resultados obtenidos son prometedores, los expertos clínicos señalan que aún existen fragmentos cuya simplificación resulta ambigua o incorrecta debido a la falta de conocimiento específico por parte del modelo. Para paliar esta limitación, se propone como trabajo futuro la incorporación de una arquitectura basada en recuperación aumentada por generación (*Retrieval-Augmented Generation*, RAG). Esta permitiría consultar una base documental durante la generación para aumentar la precisión semántica. No obstante, su implementación efectiva requeriría disponer de un corpus de cardiología suficientemente amplio y curado.
- **Extrapolación a otros ámbitos médicos:** Otra línea de trabajo consistiría en adaptar la metodología y herramientas desarrolladas a otros subdominios dentro de la medicina (por ejemplo, neumología, neurología o pediatría), evaluando en qué medida las hipótesis planteadas siguen siendo válidas y qué ajustes serían necesarios.
- **Transferencia a otros dominios técnicos:** Más allá del ámbito clínico, se considera viable extrapolar este enfoque a otros dominios donde la comprensión de

documentos técnicos representa una barrera, como el jurídico o el administrativo. Estos campos comparten la necesidad de simplificación y explicación accesible de textos densos y especializados.

- **Integración de módulos de *Question Answering* especializado:** Se propone implementar un sistema de preguntas y respuestas orientado a pacientes y estudiantes, que permita interactuar con fragmentos del informe médico para obtener aclaraciones personalizadas, simulando una consulta con un profesional sanitario. Esta funcionalidad puede mejorar sustancialmente la experiencia de comprensión más allá de la simplificación textual directa.
- **Diseño de métricas automáticas específicas:** Se identifica como necesidad prioritaria el diseño de métricas que permitan evaluar la calidad de la simplificación médica considerando la preservación de información clave, la adecuación del registro y la precisión semántica, además de la legibilidad tradicional. Para ello, sería recomendable entrenar modelos evaluadores centrados en el dominio de la cardiología.
- **Ampliación del corpus clínico anotado:** Finalmente, resulta fundamental contar con un mayor volumen de datos clínicos reales, revisados por profesionales, que sirvan de base para entrenar y validar modelos más robustos. La diversidad de estilos redactivos y estructuras asistenciales beneficiaría la generalización del sistema propuesto.

Estas líneas futuras abren nuevas posibilidades tanto de aplicación como de mejora científica, y permiten proyectar este trabajo como una base sólida para investigaciones posteriores en procesamiento del lenguaje en entornos sensibles y especializados.

Bibliografía

- [1] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need, 2023. URL <https://arxiv.org/abs/1706.03762>.
- [2] OECD. Survey of adult skills (piaac): 2023 country note – spain, 2023. URL <https://doi.org/10.1787/b263dc5d-en>. https://www.oecd.org/es/publications/2024/12/survey-of-adults-skills-2023-country-notes_df7b4a60/spain_8e025f40.html.
- [3] AENOR. *Lectura Fácil. Pautas y recomendaciones para la elaboración de documentos*. AENOR INTERNACIONAL SAU, Madrid, 2018.
- [4] Beatriz Botella-Gil, Isabel Espinosa-Zaragoza, Alba Bonet-Jover, Margot Medina, Lucas Molino Piñar, Paloma Moreda, Itziar González-Dios, María Teresa Martín Valdivia, and Ureña. Overview of clears at iberlef 2025: Challenge for plain language and easy-to-read adaptation for spanish texts. *Procesamiento del Lenguaje Natural*, 75, 2025.
- [5] Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. Efficient estimation of word representations in vector space, 2013. URL <https://arxiv.org/abs/1301.3781>.
- [6] Jeffrey Pennington, Richard Socher, and Christopher Manning. Glove: Global vectors for word representation. volume 14, pages 1532–1543, 01 2014. doi: 10.3115/v1/D14-1162.
- [7] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding, 2019. URL <https://arxiv.org/abs/1810.04805>.
- [8] Jeremy Howard and Sebastian Ruder. Universal language model fine-tuning for text classification, 2018. URL <https://arxiv.org/abs/1801.06146>.

- [9] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Aspell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. Language models are few-shot learners, 2020. URL <https://arxiv.org/abs/2005.14165>.
- [10] Xi Yang, Jiang Bian, William Hogan, and Yonghui Wu. Clinical concept extraction using transformers. *Journal of the American Medical Informatics Association : JAMIA*, 27, 10 2020. doi: 10.1093/jamia/ocaa189.
- [11] Cheng Peng, Xi Yang, Aokun Chen, Zehao Yu, Kaleb E Smith, Anthony B Costa, Mona G Flores, Jiang Bian, and Yonghui Wu. Generative large language models are all-purpose text analytics engines: Text-to-text learning is all your need, 2023. URL <https://arxiv.org/abs/2312.06099>.
- [12] Madhumita Sushil, Dana Ludwig, Atul J. Butte, and Vivek A. Rudrapatna. Developing a general-purpose clinical language inference model from a large corpus of clinical notes, 2022. URL <https://arxiv.org/abs/2210.06566>.
- [13] Omid Rohanian, Mohammadmahdi Nouriborji, Hannah Jauncey, Samaneh Kouchaki, Farhad Nooralahzadeh, Lei Clifton, Laura Merson, and David A. Clifton. Lightweight transformers for clinical natural language processing. *Natural Language Engineering*, 30(5):887–914, January 2024. ISSN 1469-8110. doi: 10.1017/S1351324923000542. URL <http://dx.doi.org/10.1017/S1351324923000542>.
- [14] Xi Yang, Jiang Bian, William Hogan, and Yonghui Wu. Clinical concept extraction using transformers. *Journal of the American Medical Informatics Association : JAMIA*, 27, 10 2020. doi: 10.1093/jamia/ocaa189.
- [15] Andriy Mulyar and Bridget T. McInnes. Mt-clinical bert: Scaling clinical information extraction with multitask learning, 2020. URL <https://arxiv.org/abs/2004.10220>.
- [16] Yikuan Li, Ramsey M. Wehbe, Faraz S. Ahmad, Hanyin Wang, and Yuan Luo. Clinical-longformer and clinical-bigbird: Transformers for long clinical sequences, 2022. URL <https://arxiv.org/abs/2201.11838>.
- [17] Laila Rasmy, Yang Xiang, Ziqian Xie, Cui Tao, and Degui Zhi. Med-bert: pre-trained contextualized embeddings on large-scale structured electronic health records for disease prediction, 2020. URL <https://arxiv.org/abs/2005.12833>.

- [18] Chao Pang, Xinzhuo Jiang, Krishna S Kalluri, Matthew Spotnitz, RuiJun Chen, Adler Perotte, and Karthik Natarajan. Cehr-bert: Incorporating temporal information from structured ehr data to improve prediction tasks, 2021. URL <https://arxiv.org/abs/2111.08585>.
- [19] H Cho, T Jun, Y Kim, H Kang, I Ahn, H Gwon, Y Kim, J Seo, H Choi, M Kim, J Han, G Kee, S Park, and S Ko. Task-specific transformer-based language models in health care: Scoping review. *JMIR Medical Informatics*, 12:e49724, 2024. doi: 10.2196/49724. URL <https://medinform.jmir.org/2024/1/e49724>.
- [20] Mustafa Karabacak and Konstantinos Margetis. Embracing large language models for medical applications: Opportunities and challenges. *Cureus*, 15(5): e39305, May 2023. doi: 10.7759/cureus.39305.
- [21] Kai He, Rui Mao, Qika Lin, Yucheng Ruan, Xiang Lan, Mengling Feng, and Erik Cambria. A survey of large language models for healthcare: from data, technology, and applications to accountability and ethics, 2025. URL <https://arxiv.org/abs/2310.05694>.
- [22] Robert Tinn, Hao Cheng, Yu Gu, Naoto Usuyama, Xiaodong Liu, Tristan Naumann, Jianfeng Gao, and Hoifung Poon. Fine-tuning large neural language models for biomedical natural language processing, 2021. URL <https://arxiv.org/abs/2112.07869>.
- [23] Aryo Pradipta Gema, Pasquale Minervini, Luke Daines, Tom Hope, and Beatrice Alex. Parameter-efficient fine-tuning of llama for the clinical domain, 2024. URL <https://arxiv.org/abs/2307.03042>.
- [24] Osman Alperen Koraş, Rabi Bahnan, Jens Kleesiek, and Amin Dada. Towards conditioning clinical text generation for user control, 2025. URL <https://arxiv.org/abs/2502.17571>.
- [25] Yuxian Gu, Xu Han, Zhiyuan Liu, and Minlie Huang. Ppt: Pre-trained prompt tuning for few-shot learning, 2022. URL <https://arxiv.org/abs/2109.04332>.
- [26] John Carroll, Guido Minnen, Yvonne Canning, Siobhan Devlin, and John Tait. Practical simplification of english newspaper text to assist aphasic readers. *Proc. of AAAI-98 Workshop on Integrating Artificial Intelligence and Assistive Technology*, 07 1998.
- [27] Beata Beigman Klebanov, Kevin Knight, and Daniel Marcu. Text simplification for information-seeking applications. In Robert Meersman and Zahir Tari, editors, *On the Move to Meaningful Internet Systems 2004: CoopIS, DOA, and ODBASE*,

- pages 735–747, Berlin, Heidelberg, 2004. Springer Berlin Heidelberg. ISBN 978-3-540-30468-5.
- [28] Sander Wubben, Emiel Krahmer, and Antal Van den Bosch. Sentence simplification by monolingual machine translation. volume 1, pages 1015–1024., 01 2012.
- [29] Robert-Mihai Botarleanu, Mihai Dascalu, Scott Andrew Crossley, and Danielle S. McNamara. Sequence-to-sequence models for automated text simplification. In Ig lbert Bittencourt, Mutlu Cukurova, Kasia Muldner, Rose Luckin, and Eva Millán, editors, *Artificial Intelligence in Education*, pages 31–36, Cham, 2020. Springer International Publishing. ISBN 978-3-030-52240-7.
- [30] Louis Martin, Benoît Sagot, Éric de la Clergerie, and Antoine Bordes. Controllable sentence simplification, 2020. URL <https://arxiv.org/abs/1910.02677>.
- [31] Aman Madaan, Amrith Setlur, Tanmay Parekh, Barnabas Poczós, Graham Neubig, Yiming Yang, Ruslan Salakhutdinov, Alan W Black, and Shrimai Prabhumoye. Politeness transfer: A tag and generate approach, 2020. URL <https://arxiv.org/abs/2004.14257>.
- [32] Carolina Scarton. Horacio saggion, automatic text simplification. synthesis lectures on human language technologies, april 2017. 137 pages, isbn:16270586809781627058681. *Natural Language Engineering*, 26:1–4, 11 2019. doi: 10.1017/S1351324919000603.
- [33] Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. Bleu: a method for automatic evaluation of machine translation. In *Proceedings of the 40th Annual Meeting on Association for Computational Linguistics*, ACL '02, page 311–318, USA, 2002. Association for Computational Linguistics. doi: 10.3115/1073083.1073135. URL <https://doi.org/10.3115/1073083.1073135>.
- [34] Chin-Yew Lin. Rouge: A package for automatic evaluation of summaries. page 10, 01 2004.
- [35] Wei Xu, Courtney Napoles, Ellie Pavlick, Quanze Chen, and Chris Callison-Burch. Optimizing statistical machine translation for text simplification. *Transactions of the Association for Computational Linguistics*, 4:401–415, 07 2016. ISSN 2307-387X. doi: 10.1162/tac1_a_00107. URL https://doi.org/10.1162/tac1_a_00107.
- [36] Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, and Yoav Artzi. Bertscore: Evaluating text generation with bert, 2020. URL <https://arxiv.org/abs/1904.09675>.

- [37] J. Peter Kincaid, Robert P. Fishburne Jr., Richard L. Rogers, and Brad S. Chissom. Derivation of new readability formulas (automated readability index, fog count and flesch reading ease formula) for navy enlisted personnel. Technical Report 56, Institute for Simulation and Training, 1975. URL <https://stars.library.ucf.edu/istlibrary/56>. Technical Report 56.
- [38] Sweta Agrawal and Marine Carpuat. Do text simplification systems preserve meaning? a human evaluation via reading comprehension, 2024. URL <https://arxiv.org/abs/2312.10126>.
- [39] Martin C. Were, Sergey Gorbachev, Jacob Cadwallader, James Kesterson, Xiaochun Li, J. Marc Overhage, and Jeffery Friedlin. Natural language processing to extract follow-up provider information from hospital discharge summaries. In *AMIA Annual Symposium Proceedings*, pages 872–876. American Medical Informatics Association, 2010.
- [40] Milton Corn, Kathleen A. Rudzinski, and Marilyn A. Cahn. Bridging the gap in medical informatics and health services research: workshop results and next steps. *Journal of the American Medical Informatics Association (JAMIA)*, 9(2):140–143, 2002. doi: 10.1197/jamia.m0971. URL <https://doi.org/10.1197/jamia.m0971>.
- [41] Suresh Kandula, Don Curtis, and Qing Zeng-Treitler. A semantic and syntactic text simplification tool for health content. In *AMIA Annual Symposium Proceedings*, pages 366–370. American Medical Informatics Association, 2010.
- [42] Ruqing Zhao, Xi Wang, Hongliang Dai, Pan Gao, and Piji Li. Medical report generation based on segment-enhanced contrastive representation learning, 2023. URL <https://arxiv.org/abs/2312.15869>.
- [43] Rocío Bartolomé Rodríguez, Ana Rosa Terroba Reinares, and Leonardo Campillos-Llanos. Clara-med simplified sentences, 2024.
- [44] Yubao Zhao, Jiaju Kang, Tian Zhang, Puyu Han, and Tong Chen. Ecg-chat: A large ecg-language model for cardiac disease diagnosis, 2025. URL <https://arxiv.org/abs/2408.08849>.
- [45] Sebastian Joseph, Kathryn Kazanas, Keziah Reina, Vishnesh J. Ramanathan, Wei Xu, Byron C. Wallace, and Junyi Jessy Li. Multilingual simplification of medical texts, 2023. URL <https://arxiv.org/abs/2305.12532>.
- [46] Yishu Wei, Xindi Wang, Hanley Ong, Yiliang Zhou, Adam Flanders, George Shih, and Yifan Peng. Enhancing disease detection in radiology reports through fine-tuning lightweight llm on weak labels, 2024. URL <https://arxiv.org/abs/2409.16563>.

- [47] Qianqian Xie, Edward J. Schenck, He S. Yang, Yong Chen, Yifan Peng, and Fei Wang. Faithful ai in medicine: A systematic review with large language models and beyond. *medRxiv*, 2023. doi: 10.1101/2023.04.18.23288752. URL <https://www.medrxiv.org/content/early/2023/07/01/2023.04.18.23288752>.
- [48] Yihao Hou, Christoph Bert, Ahmed Gomaa, Godehard Lahmer, Daniel Hoefler, Thomas Weissmann, Raphaela Voigt, Philipp Schubert, Charlotte Schmitter, Alina Depardon, Sabine Semrau, Andreas Maier, Rainer Fietkau, Yixing Huang, and Florian Putz. Fine-tuning a local llama-3 large language model for automated privacy-preserving physician letter generation in radiation oncology, 2024. URL <https://arxiv.org/abs/2408.10715>.
- [49] Yiduo Guo, Jie Fu, Huishuai Zhang, Dongyan Zhao, and Yikang Shen. Efficient continual pre-training by mitigating the stability gap. 2024. URL <https://api.semanticscholar.org/CorpusID:270688100>.
- [50] Jan Trienes, Sebastian Joseph, Jörg Schlötterer, Christin Seifert, Kyle Lo, Wei Xu, Byron C. Wallace, and Junyi Jessy Li. Infolossqa: Characterizing and recovering information loss in text simplification, 2024. URL <https://arxiv.org/abs/2401.16475>.
- [51] Saahil Jain, Ashwin Agrawal, Adriel Saporta, Steven QH Truong, Du Nguyen Duong, Tan Bui, Pierre Chambon, Yuhao Zhang, Matthew P. Lungren, Andrew Y. Ng, Curtis P. Langlotz, and Pranav Rajpurkar. Radgraph: Extracting clinical entities and relations from radiology reports, 2021. URL <https://arxiv.org/abs/2106.14463>.
- [52] Yan Jia, John McDermid, Tom Lawton, and Ibrahim Habli. The role of explainability in assuring safety of machine learning in healthcare, 2022. URL <https://arxiv.org/abs/2109.00520>.

Apéndice A

Análisis Visual y de Complejidad del Corpus Médico

Este apéndice presenta el análisis visual del corpus médico mediante nubes de palabras que revelan la terminología característica de cada sección, y un gráfico radar que evalúa la complejidad léxica a través de tres dimensiones: longitud media de palabra (complejidad morfológica), frases por texto (densidad sintáctica) y diversidad léxica TTR (riqueza vocabular). Las visualizaciones permiten identificar patrones terminológicos específicos y características lingüísticas distintivas del discurso médico especializado, proporcionando una base cuantitativa para la caracterización estilística del corpus.






Figura A.1: Nube de palabras - Sección Revisiones

A word cloud of medical terms in Spanish. The most prominent words are 'refiere' (green), 'urgencia' (blue), 'presenta' (blue), 'dolor' (blue), 'torácico' (blue), 'snea' (yellow), 'di' (yellow), 'lpm' (blue), 'esfuerzo' (blue), 'signos' (blue), 'exploración' (blue), 'anamnesis' (blue), 'paciente' (blue), 'episodio' (blue), 'normal' (blue), 'eupneico' (blue), 'repose' (blue), 'ingreso' (blue), 'cateterismo' (blue), 'mañana' (blue), 'apical' (blue), 'trastorno' (blue), 'blando' (blue), 'depreable' (blue), 'control' (blue), 'trata' (blue), 'anamnesis' (blue), 'explotación' (blue), 'actualmente' (blue), 'llegada' (blue), 'niega' (blue), 'planta' (blue), 'cardiología' (blue), 'toma' (blue), 'ortopnea' (blue), 'signos' (blue), 'tpv' (blue), 'urgencias' (blue), 'dolor' (blue), 'asintomático' (blue), 'mujer' (blue), 'años' (blue), 'edad' (blue), 'hace' (blue), 'semana' (blue), 'alta' (blue), 'perforado' (blue), 'eupneico' (blue), 'analítica' (blue), 'objetiva' (blue), 'anamnesis' (blue), 'varón' (blue), 'sensación' (blue), 'negativa' (blue), 'ligera' (blue), 'síncope' (blue), 'edemas' (blue), 'signos' (blue), 'esfuerzo' (blue), 'uc' (blue), 'refiere' (blue), 'objetivo' (blue), 'signos' (blue), 'situación' (blue), 'clínica' (blue), 'evolución' (blue), 'signos' (blue), 'vegetativo' (blue), 'triste' (blue), 'hace' (blue), 'signos' (blue), 'repose' (blue), 'cada' (blue), 'mañana' (blue), 'noche' (blue), 'acude' (blue), 'urgencias' (blue), 'ritmo' (blue), 'sinusal' (blue), 'exploración' (blue), 'mmhg' (blue).

Términos más frecuentes - Sección: Antecedentes



Términos más frecuentes - Sección: Juicio



IX

Términos más frecuentes - Sección: Motivo



Figura A.8: Nube de palabras - Sección Motivo de ingreso

Términos más frecuentes - Sección: Plan




Figura A.9: Nube de palabras - Sección Plan de actuación

Términos más frecuentes - Sección: Intervencion



Figura A.10: Nube de palabras - Sección Intervención/Procedimientos quirúrgicos


Análisis de complejidad léxica por sección del informe médico

Figura A.11: Análisis de complejidad léxica por sección mediante gráfico radar. Las tres dimensiones evaluadas son: longitud media de palabra, frases por texto y diversidad léxica (TTR).

Apéndice B

Especificaciones de *prompts* utilizados

B.1. *Prompt* utilizado en la estrategia de simplificación global

A continuación se presenta el *prompt* completo que se empleó para la estrategia de simplificación global del informe clínico descrito en la Subsección [4.2.1](#). Este *prompt* fue diseñado para que el modelo genere una versión simplificada del informe completo, manteniendo la precisión médica y adaptada a personas mayores o con bajo nivel de comprensión médica.

Eres un experto en simplificación de informes de alta de cardiología, dirigido principalmente a personas mayores con niveles de comprensión médica limitados.

Tu tarea es simplificar el siguiente informe de alta para que sea fácilmente comprensible, sin perder la precisión del contenido médico.

Por favor, proporciona una respuesta clara y concisa, eliminando cualquier complejidad o jerga innecesaria.

Además, explica cada término médico clave, en especial los relacionados con cardiología.

Es importante que tu respuesta sea comprensible, y que permita varias versiones simplificadas relevantes y creativas, siempre y cuando el significado original se mantenga fiel.

El informe de alta incluye los siguientes apartados: {Apartados}

La simplificación tiene que incluir únicamente estos campos sin ninguna información adicional y sin ningún campo más.

Por favor, simplifica este informe de alta y proporciona la versión simplificada:

B.2. Estructura instruccional de los *prompts* por sección

A continuación se presenta el diseño base del *prompt* utilizado en el enfoque seccional, acompañado de las anotaciones correspondientes a los elementos instructivos identificados en la Subsección [4.2.2](#). Cada número entre superíndices hace referencia a uno de los trece componentes que guían la formulación de los *prompts*, y que se han descrito previamente.

Prompt base:

Eres un experto en simplificación de informes de alta de cardiología¹, dirigido principalmente a personas mayores con niveles de comprensión médica limitados².

Tu tarea es simplificar la sección Antecedentes de un informe de alta para que sea fácilmente comprensible³, sin perder la precisión del contenido médico⁴.

Por favor, proporciona una respuesta clara y concisa⁵, eliminando cualquier complejidad o jerga innecesaria⁶ sin excederte en tu explicación⁷.

Es importante que tu simplificación mantenga un lenguaje formal y respetuoso adecuado para el público objetivo, en tercera persona⁸.

{ejemplo}

Es muy importante que, entre paréntesis, indiques el término original en la simplificación⁹.

Es importante que tu respuesta sea comprensible, generando una versión simplificada, relevante y creativa¹⁰, siempre y cuando el significado original se mantenga fiel¹¹.

El resultado le será directamente mostrado al paciente¹².

Por favor, simplifica esta sección y proporciona la versión simplificada de {sección}¹³.

A continuación se presenta la tabla con los elementos específicos añadidos por sección, considerando que todos incluyen por defecto [1–5] y [9–13]:

En los casos marcados con asterisco (*), se incorporaron matices orientados a reforzar la explicación de procedimientos diagnósticos o terapéuticos, con el fin de facilitar la comprensión y adherencia por parte del paciente.

B.3. *Prompt* de anotación de abreviaciones clínicas

A continuación se muestra el *prompt* exacto definido su uso en la Sección [4.3.1](#), diseñado con el apoyo del modelo o1, un razonador de la familia OpenAI, que permitió

Sección del informe	Elementos adicionales (además de [1–5, 9–13])
<i>Motivo de Ingreso</i>	[6, 7, 8]
<i>Antecedentes (personales/familiares)</i>	[6, 7, 8]
<i>Enfermedad Actual</i>	[8]
<i>Pruebas Complementarias</i>	[8, *]
<i>Evolución y Curso Clínico</i>	[8]
<i>Intervención Quirúrgica</i>	[8]
<i>Juicio Clínico</i>	[8]
<i>Tratamiento</i>	[7, 8, *]
<i>Plan de Actuación</i>	[8]
<i>Revisiones</i>	[]

Tabla. B.1: Elementos instructivos adicionales por sección (todos los *prompts* incluyen [1–5, 9–13] por defecto).

al modelo GPT-4o realizar la detección y anotación automática de todas las abreviaciones y símbolos médicos presentes en los informes clínicos. Este *prompt* incorpora reglas estrictas para asegurar la exhaustividad y coherencia del proceso de extracción, constituyendo la base para la generación del corpus anotado empleado en este trabajo.

A partir del siguiente texto médico, extrae **absolutamente todos** los términos que pertenezcan a las siguientes categorías. **Si hay alguna duda sobre si un término debe ser incluido, agrégalo en la categoría más probable en lugar de omitirlo.**

1. **Formas abreviadas** → Incluye **acrónimos, siglas, abreviaturas y unidades de medida** en un solo grupo
2. **Símbolos médicos** → Términos en mayúsculas que representan una entidad médica específica, pero que no son acrónimos, siglas ni abreviaturas

REGLAS OBLIGATORIAS:

- Incluye todos los términos posibles
- Si hay duda, añade el término
- Mantén mayúsculas/minúsculas exactamente como aparecen
- Responde en JSON con claves `formas_abreviadas` y `simbolos_medicos`
- Si una categoría no tiene términos, devuelve []

EJEMPLO DE USO:

Entrada:

ECG con dolor: RS, QRS estrecho, HBAI, descenso del ST 1 mm en V2, I, aVL, elevación del ST de 1.5 mm en cara inferior.

Analítica planta:

Ecocardiografía: VI no dilatado con función conservada. Hipoquinesia inferolateral. VD ligeramente dilatado con función conservada. No valvulopatías. No derrame pericárdico.

Analítica: Hb 15.5, creatinina 0.8, mdrd >90, CT 269, LDL 187, TGL 208, BT 12, BD 0.35, GPT 46, GOT 27, GGT normal, potasio 4.3, IST 31 %, ferritina 143, pcr normal, TSH normal, ntprobnp 439, A1c 8.2 %.

ECG planta al alta: RS, QRS estrecho, Q y T negativas en III, aVF.

Se realizó icp.

Salida JSON esperada:

```
{
  "formas_abreviadas": [
    "ICP", "ECG", "RS", "HBAI", "VI", "VD", "Hb",
    "CT", "LDL", "TGL", "BT", "BD", "GPT", "GOT",
    "GGT", "IST", "TSH", "A1c", "mm", "mmHg",
    "pcr", "ntprobnp"
  ],
  "simbolos_medicos": [
    "QRS", "ST", "aVL", "III", "aVF", "V2"
  ]
}
```

B.4. *Prompt* de anotación de medicamentos y principios activos

A continuación se muestra el *prompt* exacto utilizado para la anotación automática de medicamentos y principios activos en informes clínicos, como parte del diseño experimental desarrollado en esta investigación en la Subsección [4.4.1](#). El *prompt* fue elaborado con el apoyo del modelo *o1*, de la familia OpenAI, para guiar al modelo GPT-4o en la extracción exhaustiva y precisa de entidades farmacológicas, tanto comerciales como químicas. Este *prompt* define un conjunto de reglas estrictas que aseguran la coherencia, exhaustividad y validez del corpus anotado que sirvió como base para el entrenamiento del modelo especializado en detección de medicación.

A partir del siguiente texto médico, extrae **absolutamente todos** los términos que pertenezcan a las siguientes categorías. **Si hay alguna duda sobre si un término debe ser incluido, agrégalo en la categoría más probable, pero nunca lo omitas.**

1. **Medicamentos** → Nombres comerciales o genéricos de fármacos
Ejemplos: "Paracetamol", "Ibuprofeno", "Omeprazol"
2. **Principios activos** → Sustancias químicas responsables de la actividad farmacológica
Ejemplos: "Acido acetilsalicílico", "Metformina"

REGLAS OBLIGATORIAS:

- Si una categoría no tiene términos, devuelve una lista vacía ([])
- Incluye todos los términos que pertenezcan a estas categorías sin omitir ninguno
- Si hay duda, agrégalo en la categoría más probable
- Mantén los términos exactamente como aparecen en el texto, sin cambiar mayúsculas ni minúsculas
- Devuelve la respuesta en formato JSON válido, con dos claves: "medicamentos" y "principios_activos"

EJEMPLO DE USO:

Entrada:

*"El paciente fue tratado con **Paracetamol 500 mg** cada 8 horas para el manejo del dolor. Además, se prescribió **Amoxicilina 875 mg/125 mg** para la infección bacteriana. Se recomendó **Omeprazol 20 mg** antes del desayuno. Para la inflamación, se administró **Diclofenaco 75 mg/3 mL**. El paciente también utiliza **Salbutamol inhalado** para el asma. Se advirtió evitar el uso de **Acido acetilsalicílico** debido a antecedentes de gastritis."*

Salida JSON esperada:

```
{
  "medicamentos": [
    "Paracetamol",
    "Amoxicilina",
    "Omeprazol",
    "Diclofenaco",
    "Salbutamol"
  ],
  "principios_activos": [
    "Paracetamol",
    "Amoxicilina",
    "Omeprazol",
```

```

    "Diclofenaco",
    "Salbutamol",
    "Acido acetilsalicilico"
  ]
}

```

CONSIDERACIONES ADICIONALES:

- Incluye términos que puedan estar escritos en diferentes formatos
- Si un término incluye tanto el nombre del medicamento como la dosis (ej: "Paracetamol 500 mg"), extrae únicamente el nombre del fármaco
- Si un término no encaja claramente en ninguna categoría, inclúyelo en "principios_activos" si se trata de una sustancia farmacológicamente activa
- Asegúrate de que **todas las categorías aparecen en la salida**, incluso si están vacías ([])
- No cambies el formato ni capitalización de los términos detectados
- No incluyas categorías adicionales más allá de "medicamentos" y "principios_activos"

B.5. *Prompt* de extracción de información terapéutica

A continuación se presenta el *prompt* exacto utilizado para la extracción automática de información terapéutica a partir de fichas técnicas y prospectos de medicamentos obtenidos de la base de datos de la AEMPS definido en la Subsección [4.4.1](#). Este *prompt* fue aplicado mediante el modelo GPT-4o mini para procesar de forma sistemática los 14.611 medicamentos recopilados, generando el diccionario terapéutico estructurado empleado en el sistema de simplificación.

A partir del siguiente texto extraído de la ficha técnica y el prospecto de un medicamento, genera un JSON con el siguiente formato:

```

{
  "nombre": "<nombre del medicamento>",
  "uso_terapeutico": "<uso terap utico principal del medicamento>"
}

```

REGLAS OBLIGATORIAS:

1. **“nombre”**: Extrae el nombre comercial del medicamento tal como aparece en el texto. No uses el nombre del principio activo.
2. **“uso_terapeutico”**: Extrae el uso terapéutico principal del medicamento. En caso de haber múltiples indicaciones, resume la más relevante en una sola frase.

CONSIDERACIONES ADICIONALES:

- Mantén la terminología médica precisa pero comprensible
- Si el texto contiene múltiples indicaciones, prioriza la indicación principal o más común
- Asegúrate de que la respuesta sea un JSON válido
- El uso terapéutico debe ser conciso pero informativo

Apéndice C

Evaluaciones de Cardiólogos Expertos

Este apéndice contiene las evaluaciones completas realizadas por los cardiólogos expertos sobre los informes médicos simplificados generados por el sistema de IA desarrollado.

C.1. Evaluación del Experto 1

SUGERENCIAS GENERALES

En general, considero que el lenguaje generado por la IA no termina de ser lo suficientemente claro y accesible por la forma en la que se expresa y, en algunos casos que iré señalando a continuación, puede llevar a confundir al lector si éste no tiene conocimientos médicos.

Respecto a la clasificación en incorrecto, adecuado, creo que, siendo estrictos, los informes generados por la IA actualmente no son adecuados ya que, aunque se trate de un lenguaje simplificado, al tratarse de temas tan trascendentes como la salud de los pacientes, éstos deben ser muy exactos en todo lo que dicen.

No considero estrictamente necesario que el texto generado deba ser desestructurado como comenta el otro evaluador, pero coincido en que un lenguaje dirigido directamente al paciente en el que se le expliquen los aspectos principales del estado actual de la enfermedad, las pruebas que se han realizado y el objetivo de los fármacos que toma, lo haría más accesible para todos.

Como ejemplo, en algunos países europeos el especialista escribe una carta dirigida al paciente y su médico de atención primaria de la siguiente forma: *“Estimado/a ... Como bien sabe, usted está diagnosticado de ..., una enfermedad que se produce por Las pruebas realizadas durante el ingreso han sido ... que sirven para ... y en ellas hemos visto En base a estas pruebas, el diagnóstico actual es Los fármacos que deberá tomar a partir de ahora son ... que sirven para ... ”.*

También hay algunos aspectos en los informes generados que, en mi opinión, son redundantes, especialmente cuando se expresa un término técnico y posteriormente entre paréntesis se puntualiza su significado o viceversa. Quizás sería más sencillo para la comprensión del texto poner sólo la terminología generada por la IA.

C.1.1. Evaluaciones Específicas

19: ADECUADO

Motivo de Ingreso y Antecedentes: Aceptable. Alguna información es redundante, por ejemplo, fumadora (fuma cigarrillos), o el significado de las abreviaturas (considero que podrían ponerse directamente los términos generados por la IA).

Enfermedad actual: Ok.

Pruebas complementarias: Incorrecto. El ECG no es correcto; las dos últimas frases no son conclusiones que se deriven de ese electrocardiograma. Se deberían resumir el ecocardiograma y la coronariografía centrándose en los hallazgos patológicos.

Evolución y Curso Clínico: Ok.

Juicio clínico: Aceptable. Alguna información es redundante; simplificar el diagnóstico lo máximo posible. En este caso, las cuatro primeras frases forman parte del mismo diagnóstico.

Plan de Actuación, Tratamiento y Revisiones: Ok.

31: ADECUADO

Motivo de Ingreso y Antecedentes: Aceptable. Expresiones como “latidos irregulares” o “daño al corazón” transmiten gravedad al paciente.

Enfermedad actual: Ok.

Pruebas complementarias: Aceptable. Expresiones como “puede indicar un problema, pero no es claro” pueden confundir al paciente.

Intervención Quirúrgica / Procedimientos: Aceptable.

Juicio clínico: Aceptable. Simplificar los diagnósticos.

Tratamiento: Incorrecto. Lixiana no es un fármaco para la presión arterial ni para la insuficiencia cardíaca, es un anticoagulante. No creo que sea bueno clasificar los medicamentos, es suficiente con uno a uno mencionar para lo que sirven y cómo tomarlos.

50: INCORRECTO

Motivo de Ingreso y Antecedentes: Incorrecto. El paciente es consumidor de cocaína ocasional, la forma de expresión no es clara.

Enfermedad actual: Ok.

Pruebas complementarias: Incorrecto. La interpretación del ECG es errónea.

Evolución y Curso Clínico: Incorrecto. No es correcta la redacción, algunas palabras no existen, por ejemplo “repetarán”.

Intervención Quirúrgica: Aceptable. Simplificar diagnósticos.

Juicio clínico: Ok. Muy adecuado.

Plan de Actuación y Tratamiento: Incorrecto. No es correcta la redacción, algunas palabras no existen, por ejemplo “en el ínterin”.

61: ADECUADO

Motivo de Ingreso y Antecedentes: Ok.

Enfermedad actual: Aceptable. Falta exactitud. Hablar de “un problema cardíaco” tal vez sea demasiado genérico.

Pruebas complementarias: Aceptable. En la línea de lo comentado en informes previos, sería más adecuado sintetizar los resultados.

Evolución y Curso Clínico: Aceptable. Podría explicarse mejor lo que es la función del ventrículo izquierdo, por ejemplo, “la fuerza del corazón es normal”.

Juicio clínico: Aceptable. Las cuatro primeras frases forman parte del mismo cuadro.

Tratamiento y Plan de Actuación: Ok.

73: ADECUADO

Motivo de Ingreso y Antecedentes: Ok.

Enfermedad actual: Adecuado. Cambiar alguna terminología del informe original como “escozor en el pecho” por “picor en el pecho” probablemente no mejore la comprensión y pueda confundir al paciente.

Pruebas complementarias: Aceptable. Algunas interpretaciones son prescindibles y deberían sintetizarse, por ejemplo, el SPECT, que incluye aspectos técnicos que no son necesarios para la comprensión de la prueba.

Evolución y Curso Clínico: Aceptable. La redacción es mejorable.

Juicio clínico: Aceptable.

Tratamiento, Plan de Actuación y Revisiones: Aceptable.

82: INCORRECTO

Antecedentes: Incorrecto. SAM no es bloqueo de corazón. Flutter auricular es una arritmia, no un ataque de calor en el corazón.

Enfermedad actual: Ok.

Pruebas complementarias: Ok.

Juicio clínico: Incorrecto. No habría que explicar lo que significa “sin complicaciones”. Monocameral quiere decir que tiene un electrodo, no que tiene una cámara.

Tratamiento: Ok.

85: ADECUADO

Motivo de Ingreso y Antecedentes: Aceptable.

Enfermedad actual: Ok.

Pruebas complementarias: Aceptable.

Evolución y Curso Clínico: Aceptable.

Intervención Quirúrgica / Procedimientos: Ok.

Juicio clínico: Aceptable.

Tratamiento, Plan de Actuación y Revisiones: Ok.

94: ADECUADO

Motivo de Ingreso y Antecedentes: Aceptable.

Enfermedad actual: Ok.

Pruebas complementarias: Aceptable.

Juicio clínico: Aceptable. Mismos comentarios que en otros casos.

Tratamiento y Revisiones: Incorrecto. Inventa cosas.

C.2. Evaluación del Experto 2

SUGERENCIAS GENERALES

En general hay que tener en cuenta que la asignación a cada informe generado, entre INCORRECTO, ADECUADO, he sido muy benévolo, es decir, aunque la mayoría son asignados como ADECUADO, ninguno de ellos se acerca a la posibilidad de poder entregarlos a un paciente.

Sugerencias:

1. Creo que el informe debería referirse en segunda persona con lenguaje educado y formal al paciente (y no en tercera persona).

2. Debería tener una estructura mucho más cercana y no tan estructurada. Por ejemplo:

En lugar de:

“Antecedentes Personales: Mujer con: No antecedentes médicos conocidos. Hipertensión arterial (tensión alta). Parkinson (una enfermedad que afecta el movimiento). Fibrilación auricular no valvular.”

Esta forma de expresarlo: *“Antes del ingreso actual, usted ya estaba diagnosticada de hipertensión arterial y fibrilación auricular como enfermedades del sistema cardiovascular.”*

3. En general hay mucha información que es prescindible y que se incluye tal y como está genera confusión. Por ejemplo: “Tratamiento: No toma ningún medicamento.” Está copiado del informe original. Esta información no es necesaria en el informe simplificado.

4. Hay apartados en los que debería hablarse en pasado. Son procedimientos o aspectos que ya ocurrieron. Por tanto, para una mejor comprensión creo que debería utilizarse en tiempo verbal adecuado (aún cuando en el informe original estén en presente).

5. Creo que prescindiría del apartado Tratamiento Previo, Tratamiento Habitual

6. En general, me pregunto si el formato global del informe resultado debe ser este o debería plantearse como un informe que vaya al grano. En el que realmente se haga entender al paciente por qué ha ingresado, qué se le ha hecho, cuál es el diagnóstico final y qué tratamiento debe hacer y cómo. Esto implicaría una labor MAYORITARIAMENTE de RECORTE de texto del informe original y MUY POCO de INTERPRETACIÓN. En resumen, que escriba poco (que es de lo que se trata) porque si es así se equivocará poco.

C.2.1. Evaluaciones Específicas

19: ADECUADO

Motivo de Ingreso y Antecedentes: Ok

Enfermedad actual: Aceptable. Evitar terminología técnica (ej., disnea paroxística nocturna)

Pruebas complementarias: Incorrecto. En general hay que simplificar mucho, centrándose en hallazgos patológicos (no aportar los normales); el ECG se ha interpretado mal.

Evolución y Curso Clínico: Ok

Juicio clínico: Aceptable. Lo ideal sería integrar todos los términos en una frase que el paciente pudiera entender, y no dar múltiples líneas de diagnóstico, cuya conexión a priori es difícil de establecer para un paciente.

Plan de Actuación, Tratamiento y Revisiones: Ok (es mejorable).

31: ADECUADO

Motivo de Ingreso y Antecedentes: Ok

Enfermedad actual: Ok

Pruebas complementarias: Aceptable. Sería necesario simplificar más.

Intervención Quirúrgica / Procedimientos: Aceptable

Juicio clínico: Aceptable. Lo ideal sería integrar todos los términos en una frase que el paciente pudiera entender.

Tratamiento: Incorrecto. Hay datos que son incorrectos (hay información que no se incluye y por otro lado información incluida incorrecta).

50: ADECUADO

Motivo de Ingreso y Antecedentes: Ok

Enfermedad actual: Ok. Estaría mejor más simplificado.

Pruebas complementarias: Aceptable. La interpretación del ECG es errónea. En general no debería incluirse interpretación tan detallada del ECG. Debería limitarse a frases tipo, como por ejemplo “El ritmo del corazón era normal” o “El corazón estaba latiendo de manera irregular (fibrilación auricular) a una velocidad de 60 latidos por minuto”. Cuando existan alteraciones más allá del ritmo, limitarse a expresar “Además, el ECG mostraba hallazgos que podrían indicar algún problema de suministro de oxígeno al corazón”.

Evolución y Curso Clínico: Incorrecto. No es correcta la redacción.

Intervención Quirúrgica: Aceptable. Deberían limitarse los comentarios a los hallazgos anómalos.

Juicio clínico: Ok. Este es un ejemplo de diagnóstico que debería repetirse en todos los informes. Breve (una-dos líneas), conciso (al grano) y con su explicación asociada.

Plan de Actuación y Tratamiento: Aceptable. Hay algún comentario que no se ajusta a la realidad.

61: ADECUADO

Motivo de Ingreso y Antecedentes: Ok

Enfermedad actual: Aceptable. Creo que requiere un mayor grado de interpretación por la IA y no ceñirse tanto a los términos originales (porque al final no está siendo correcto lo que se redacta). No se si esto es solucionable en el estadio en el que nos encontramos con el proyecto.

Pruebas complementarias: Aceptable. La interpretación del ECG es errónea. En general no debería incluirse interpretación tan detallada del ECG. Debería limitarse a frases tipo, como por ejemplo “El ritmo del corazón era normal” o “El corazón estaba latiendo de manera irregular (fibrilación auricular) a una velocidad de 60 latidos por minuto”. Cuando existan alteraciones más allá del ritmo, limitarse a expresar “Además, el ECG mostraba hallazgos que podrían indicar algún problema de suministro de oxígeno al corazón”.

Evolución y Curso Clínico: Ok

Juicio clínico: Ok. Quizás simplificar toda la líneas de diagnósticos, haciéndolo todo más conexo.

Tratamiento y Plan de Actuación: Ok

73: INCORRECTO

Motivo de Ingreso y Antecedentes: Ok

Enfermedad actual: Ok

Pruebas complementarias: Aceptable. Algunas interpretaciones son prescindibles.

Evolución y Curso Clínico: Aceptable.

Juicio clínico: Incorrecto. La terminología empleada es poco concreta, deja dudas y además múltiples líneas de diagnóstico.

Tratamiento, Plan de Actuación y Revisiones: MUY INCORRECTO. Hay muchas que no aparecen en el informe original que da la sensación de que son inventadas en el resultado, y al revés, hay cosas del original que no aparecen en el resultado.

82: ADECUADO

Antecedentes: Aceptable.

Enfermedad actual: Aceptable.

Pruebas complementarias: Ok.

Juicio clínico: Aceptable.

Tratamiento: Aceptable.

85: INCORRECTO-ADECUADO

Motivo de Ingreso y Antecedentes: Ok.

Enfermedad actual: Aceptable. Se usa acrónimo no explicado.

Pruebas complementarias: Incorrecto. Demasiada interpretación.

Evolución y Curso Clínico: Incorrecto. Mal estructurado. Creo que en este caso podría ser porque el informe original no está del todo bien redactado.

Intervención Quirúrgica / Procedimientos: Ok.

Juicio clínico: Aceptable. Todo es correcto, pero muchas líneas de diagnóstico. Creo que habría que ir al grano y dar el diagnóstico por el que este paciente ha ingresado (Y NO TODOS LOS DIAGNÓSTICOS QUE SE HA INCLUIDO EN EL APARTADO).

Tratamiento, Plan de Actuación y Revisiones: Ok.

94: ADECUADO

Motivo de Ingreso y Antecedentes: Aceptable.

Enfermedad actual: Ok.

Pruebas complementarias: Aceptable. En este apartado, por error, en el original lo que se ha incluido es un PROCEDIMIENTO, no una prueba complementaria. Me pregunto si en el resultado la IA debería darse cuenta de esto, y titularlo como INTERVENCIÓN QUIRÚRGICA / PROCEDIMIENTOS

Juicio clínico: Aceptable. Mismos comentarios que en otros casos.

Tratamiento y Revisiones: Incorrecto. Inventa cosas, que si estuvieran bien, sería ideal. Pero son incorrectas.